

N° d'ordre/.....



Université Cadi Ayyad
École Nationale des Sciences Appliquées de Safi
Département Génie Informatique, Réseaux et
Télécommunications (IRT)



Mémoire de projet de fin d'études

Pour l'obtention du diplôme :

Ingénieur d'État en Informatique et Intelligence Artificielle

Option : **Ingénierie de Données et Intelligence Artificielle**

Conception et Développement d'un Système de Suivi et de Gestion des Rejets des Fichiers sur S3 via Databricks et Power BI

Réalisé par :

M. Yasser SOROURI

Effectué à : CGI



Encadré à l'ENSA par :

Mme. Asmaa KHOUIA

Professeur à ENSA de Safi

Encadré à CGI par :

M. Youness ATKI

GO MA Application Manager

Soutenu le 02 Juillet 2025, devant le jury composé de :

Mme. Asmaa KHOUIA	: Professeur à ENSA de Safi
M. Jamal EZZAHAR	: Professeur à ENSA de Safi
M. Driss HARZALLA	: Professeur à ENSA de Safi
M. Mohammed MADIAFI	: Professeur à ENSA de Safi

Année universitaire : 2024-2025



Dédicace:

À mes chers parents,

Vous êtes la source de ma détermination et de ma persévérance. Votre amour inconditionnel et vos sacrifices incessants ont tracé la voie de mon succès. Ce travail est le fruit de votre encouragement constant et de votre soutien sans faille. Vous êtes mes piliers, mes guides et mes plus grands héros. Cette dédicace est un témoignage de ma gratitude éternelle envers vous.

À ma chère sœur et à mon cher frère,

Votre existence a été la lumière qui a insufflé une motivation sans pareille dans tout ce que j'ai entrepris. Votre soutien inconditionnel et votre présence bienveillante ont été des piliers solides qui m'ont permis de persévérer et d'aller au-delà de mes limites.

À ma grande famille,

Votre soutien infaillible a été ma principale motivation pour atteindre ces objectifs. Chaque rire partagé, chaque moment précieux, a renforcé ma détermination à réussir. Votre amour et votre joie ont illuminé mon chemin, et cette dédicace est un témoignage de ma gratitude infinie.

À mes chers amis,

Vous qui avez traversé avec moi les tumultes de ce voyage, vous avez été mes compagnons de route, mes partenaires de réflexion et mes sources inépuisables de joie et de soutien. Vos rires, vos encouragements et vos conseils précieux ont rendu ce voyage mémorable. Cette dédicace est une reconnaissance sincère de notre amitié solide et de nos souvenirs partagés.





Remerciements :

Tout d'abord, je tiens à exprimer ma profonde gratitude à Allah le Tout-Puissant, qui m'a constamment guidé et soutenu tout au long de cette expérience et m'a donné le courage et la patience nécessaires pour mener ce travail à son terme.

Je souhaite également remercier mon encadrante interne, **Mme. KHOUIA Asmaa**, pour sa disponibilité et son accompagnement durant mon projet de fin d'études, pour ses orientations précieuses, son soutien constant et ses conseils éclairés.

J'exprime ma sincère gratitude à **Mme. LAGHOUATI Fatima-Zohra**, Directrice Consulting Delivery, pour avoir accepté ma demande de stage, pour son accueil chaleureux, sa disponibilité constante et les opportunités précieuses qu'elle m'a offertes.

Je tiens également à remercier **Mme. REGRAGUI Chaymae**, Project Manager, ainsi que **M. ATKI Youness**, TECH Lead, pour m'avoir offert l'opportunité de participer à ce projet, pour leur accompagnement tout au long de mon stage. Leur vision stratégique et leur expertise ont créé un environnement propice à mon développement professionnel. Je leur suis profondément reconnaissant d'avoir pu travailler avec des personnes aussi compétentes.

Je désire aussi exprimer ma reconnaissance envers l'équipe avec laquelle j'ai eu le plaisir de collaborer durant ce projet. Leur soutien a été inestimable dans mon apprentissage et a constitué une source constante de motivation pour évoluer dans un environnement aussi stimulant. Je suis very grateful for their engagement and their help continue.

Je remercie chaleureusement les membres du jury, **M. EZZAHAR Jamal**, **M. HARZALLA Driss** et **M. MADIAFI Mohammed**, pour avoir accepté de consacrer leur temps à l'évaluation de mon travail.

J'exprime également ma reconnaissance envers le coordinateur de filière, **M. MADIAFI Mohammed**, pour son soutien administratif et logistique. Sa disponibilité et son engagement ont grandement facilité mon parcours au sein de l'ENSA.

Je souhaite adresser ma gratitude à l'ensemble de l'équipe pédagogique et administrative de l'ENSA. Grâce à leurs efforts continus pour offrir une formation de qualité, j'ai pu acquérir les connaissances et compétences nécessaires à la réalisation de mon projet de fin d'études.

Enfin, je tiens à remercier du fond du cœur mes parents, ainsi que toutes les personnes qui, de près ou de loin, ont contribué à la réalisation de ce travail. Leur soutien moral, leurs encouragements et leurs conseils ont été d'une aide précieuse tout au long de cette aventure.





Résumé:

Ce rapport présente le travail que j'ai réalisé dans le cadre de mon projet de fin d'études chez CGI Technologies et Solutions Maroc, axé sur les domaines du Cloud Computing et de l'ingénierie des données.

Intitulé « **Conception et Développement d'un Système de Suivi et de Gestion des Rejets des Fichiers sur S3 via Databricks et Power BI** », ce projet s'inscrit dans une initiative plus large appelée « **Refonte monétique de l'Exadata/Oracle vers AWS/Databricks** », pilotée par le Service Delivery Manager (SDM). Cette initiative vise à moderniser l'infrastructure existante en centralisant la gestion des données issues de plusieurs projets, tout en assurant une meilleure gouvernance et accessibilité de ces données.

Dans ce contexte, j'ai participé à la mise en place d'une architecture cloud moderne reposant sur les services d'AWS. Amazon S3 a été utilisé comme Data Lake, Databricks comme plateforme unifiée de traitement et de gouvernance des données, et Delta Lake pour assurer la fiabilité, la scalabilité et la traçabilité des traitements. J'ai structuré les données selon une architecture en couches — Bronze, Silver et Gold — afin d'en faciliter la réutilisation dans les différents cas d'usage métiers.

Ma contribution principale a consisté à développer un système de monitoring automatisé capable de suivre l'état des fichiers entrants dans le hub de données. Ce système, conçu avec Databricks et visualisé via Power BI, permet d'identifier quotidiennement les fichiers acceptés ou rejetés, facilitant ainsi la supervision proactive des flux de données et la détection des anomalies.

Mots clés : Monitoring, Cloud, AWS, Databricks, Power BI





Abstract:

This report outlines the work I carried out as part of my end-of-studies internship at CGI Technologies et Solutions Maroc, focusing on the fields of Cloud Computing and Data Engineering.

The project, entitled « **Design and Development of a Monitoring and Rejection Management System for Files on S3 using Databricks and Power BI** », is part of a broader initiative named « **Monetary System Migration from Exadata/Oracle to AWS/Databricks** », led by the Service Delivery Manager (SDM). The aim of this initiative is to modernize the existing infrastructure by centralizing data management across multiple projects while improving data governance and accessibility.

In this context, I contributed to the implementation of a modern cloud architecture based on AWS, using Amazon S3 as the Data Lake, Databricks as the unified platform for data processing and governance, and Delta Lake to ensure reliability, scalability, and traceability of data processing. I structured the data into a layered architecture — Bronze, Silver, and Gold — to facilitate efficient reuse by various business use cases.

My main contribution involved developing an automated monitoring system to track the status of incoming files within the data hub. This system, built using Databricks and visualized through Power BI, enables proactive identification of accepted or rejected files on a daily basis, thus improving the supervision and quality of data flows.

Keywords : Monitoring, Cloud, AWS, Databricks, Power BI





ملخص :

يلخص هذا التقرير العمل المنجز في إطار مشروع نهاية الدراسة لدينا لدى شركة سي جي أي تكنولوجيا أند سوليوشنز المغرب ، والذي يركز على مجالي الحوسبة السحابية وهندسة البيانات.

يحمل المشروع عنوان تصميم وتطوير نظام لمتابعة وإدارة رفض الملفات على منصة إس ٣ باستخدام داتابريكس وباور بي أي، ويأتي في إطار مبادرة أوسع بعنوان إعادة تصميم النظام النقدي الإلكتروني من منصة إكساداتا أوراكل إلى بيئة إيه دبليو إس و داتابريكس التي يقودها إس دي إم . وتهدف هذه المبادرة إلى تحديث البنية التحتية الحالية من خلال مركزية إدارة البيانات القادمة من عدة مشاريع، مع تحسين حوكمتها وسهولة الوصول إليها.

وفي هذا السياق، عمل الفريق على تنفيذ بنية سحابية حديثة تعتمد على إيه دبليو إس ، باستخدام أمازون إس ٣ كبحيرة بيانات و داتابريكس كمنصة موحدة لمعالجة البيانات وحوكمتها، و بحيرة البيانات لضمان موثوقية البيانات وقابليتها للتوسع وقابلية تتبع معالجتها. وقد تم تنظيم البيانات في عدة طبقات طبقة البرونز ، طبقة الفضة ، و طبقة الذهب لتسهيل إعادة استخدامها من قبل مختلف المشاريع.

أما مساهمتنا نحن، فقد تمثلت في تطوير نظام مراقبة آلي يتابع حالة الملفات التي تصل يومياً إلى مركز البيانات. وقد تم تنفيذ هذا النظام باستخدام داتابريكس مع عرض النتائج عبر باور بي أي ، مما يتيح التعرف بشكل استباقي على الملفات المقبولة أو المرفوضة، ويسهل بالتالي مراقبة تدفق البيانات بشكل أفضل.

الكلمات المفتاح : المتابعة ، السحابة ، إيه دبليو إس ، داتابريكس ، باور بي أي



Liste des abréviations

Abréviation	Signification
CGI	Conseillers en gestion et informatique
SQL	Structured Query Language
PL/SQL	Procedural Language for SQL
AWS	Amazon Web Services
S3	Amazon Simple Storage Service
ETL	Extract Transform Load
BI	Business Intelligence
API	Application Programming Interface
ACID	Atomicity, Consistency, Isolation, and Durability
IaC	Infrastructure as Code
STD	Schéma Technique de Données
MEP	Mise en production
BO	BusinessObjects
IAM	Identity and Access Management
RTO	Recovery Time Objective
AMS	American Management Système
ESN	Entreprise de Services du Numérique
TMA	Tierce Maintenance Applicative
BPO	Business Process Outsourcing
STD	Schéma Technique de Données
KPI	Key Performance Indicator

Table des figures

1.1	Logo de CGI [19]	13
1.2	Les différents services du groupe CGI [5]	14
1.3	Clients de CGI par secteur	15
1.4	L'équipe MCM BI	16
1.5	La Méthodologie Agile[13]	19
1.6	Processus Scrum[15]	20
1.7	Microsoft Teams[10]	20
1.8	Diagramme Gantt du projet	21
2.1	Le Cloud Computing[6]	23
2.2	Les types de déploiement du Cloud[7]	24
2.3	Les Modèles de Services du Cloud[16]	25
2.4	Azure[3]	25
2.5	AWS[1]	26
2.6	GCP[12]	26
2.7	Data Engineering[8]	27
2.8	Logo Databricks[9]	30
2.9	Architecture Medallion[14]	31
2.10	Apache Spark[20]	32
3.1	Architecture précédente (FleetCard - Oracle Exadata, PL/SQL, BO/Power BI)	36
3.2	Phasage du projet DataHubMSP	37
3.3	Migration de FleetCard vers l'écosystème AWS	38
3.4	Figure 4 : Architecture fonctionnelle actuelle (Ingestion, DataHubMSP, Exposition)	39
4.1	Diagramme d'Activité du Notebook - Suivi des fichiers	45
4.2	Modèle sémantique - Suivi des fichiers 1/2	46
4.3	Modèle sémantique - Suivi des fichiers 2/2	46
4.4	Diagramme d'Activité du Notebook - Gestion des rejets de fichiers	48
4.5	Modèle sémantique - Suivi des rejets	49
4.6	Diagramme d'Activité du Notebook - Suivi des jobs databricks	52
4.7	Modèle sémantique - Suivi des jobs databricks	53
4.8	Modèle sémantique - Suivi des transactions	55
5.1	Logo de Databricks[9]	57
5.2	Logo Amazon Simple Storage Service[2]	57
5.3	Logo Power BI[17]	58
5.4	Logo SQL	58
5.5	Logo Pyspark[18]	58
5.6	Logo DAX[17]	59
5.7	Extrait de la table <code>file_tracking</code> sur Databricks	59
5.8	Extrait de la table <code>quarantine_monitoring</code> sur Databricks	60

5.9	Extrait de la table <code>jobs_monitoring</code> sur Databricks	60
5.10	Extrait de la table <code>t1plus_monitoring</code> sur Databricks	61
5.11	Vue d'ensemble des arrivées de fichiers	62
5.12	Vue d'ensemble de la décompression des fichiers MasterData	62
5.13	Suivi des fichiers inattendus et à schéma invalide	63
5.14	Suivi journalier des fichiers sur 7 jours	64
5.15	Métriques de rejets	65
5.16	Contrôle de qualité	65
5.17	Suivi des rejets	66
5.18	Page principal	67
5.19	Page des détails	68
5.20	Page de suivi quotidien	68
5.21	Aperçu du tableau de bord	69

Liste des tableaux

2.1	Benchmark des solutions de stockage cloud pour le Data Lake	33
2.2	Benchmark Databricks vs Snowflake dans le contexte du projet DataHubMSP .	34
3.1	Tableau comparatif entre l'architecture AS-IS et TO-BE	40
4.1	Description des colonnes de la table de suivi des fichiers	43
4.2	Description des colonnes de la table de configuration des fichiers	44
4.3	Description des colonnes de la table de synthèse	48
4.4	Description des colonnes de la table des jobs	51
4.5	Description des colonnes de la table de mapping	51

Table des matières

Liste des abréviations	6
Liste des tableaux	9
Table des figures	10
Introduction	12
1 CONTEXTE GÉNÉRAL DU PROJET	13
1.1 Présentation de l'organisme : Le groupe CGI	13
1.1.1 Activités de l'entreprise	13
1.1.2 Les clients de CGI par secteur	14
1.1.3 CGI au Maroc	15
1.1.4 CGI Rabat	16
1.2 Cadre du projet	16
1.2.1 Présentation du client	17
1.2.2 Contexte du Projet	17
1.2.3 Motivation et problématique	18
1.3 Conduite du projet	18
1.3.1 Méthodologie : Scrum	19
1.3.2 Planification du projet	19
2 CONCEPTS FONDAMENTAUX	23
2.1 Cloud Computing	23
2.1.1 Définition du Cloud	23
2.1.2 Les types du déploiement du Cloud	24
2.1.3 Modèles de Services Cloud	24
2.1.4 Les fournisseurs du Cloud Computing	25
2.1.5 Justification du Choix d'AWS	26
2.2 Data Engineering	27
2.2.1 Définition et rôle du Data Engineer	27
2.2.2 Écosystème technologique du Data Engineering	27
2.2.3 Les pipelines de données : ETL vs ELT	28
2.2.4 Qualité, fiabilité et gouvernance des données	28
2.3 L'ingénierie des données dans le Cloud	28
2.3.1 Avantages du cloud pour l'ingénierie des données	28
2.3.2 Architectures cloud modernes : Data Lake, Data Warehouse, Lakehouse	29
2.3.3 Approche Cloud-Native du Data Engineering	29
2.4 Présentation de Databricks	29
2.4.1 Origine et positionnement	29
2.4.2 Delta Lake et le paradigme Lakehouse	29

2.4.3	L'architecture Medallion : structuration des données dans le Lakehouse	30
2.4.4	Notebooks collaboratifs et exécution distribuée avec Apache Spark	31
2.5	Justification des choix technologiques	32
2.5.1	Pourquoi le cloud AWS ?	32
2.5.2	Pourquoi Databricks ?	33
3	ANALYSE ET ETUDE PREALABLE	35
3.1	Architecture existante (AS-IS)	35
3.1.1	Contexte de l'ancienne solution	35
3.1.2	Description de l'architecture existante	35
3.1.3	Illustration de l'architecture	36
3.1.4	Limites et problématiques identifiées	36
3.2	Architecture cible (TO-BE)	36
3.2.1	Introduction à la nouvelle solution	36
3.2.2	Phasage du projet DataHubMSP	37
3.2.3	Migration de l'application FleetCard vers AWS	37
3.2.4	Architecture technique actuelle	38
3.3	Analyse comparative et benchmark	40
4	CONCEPTION ET ÉTUDE TECHNIQUE	42
4.1	Suivi des fichiers	42
4.1.1	Notebook Databricks	42
4.1.2	Modélisation des données	42
4.1.3	Architecture de la modélisation	44
4.1.4	Dashboard Power BI	45
4.2	Suivi global des rejets	47
4.2.1	Notebook Databricks	47
4.2.2	Modélisation des données	47
4.2.3	Architecture de la modélisation	48
4.2.4	Dashboard Power BI	49
4.3	Suivi des jobs databricks	50
4.3.1	Notebook Databricks	50
4.3.2	Modélisation des données	50
4.3.3	Architecture de la modélisation	51
4.3.4	Dashboard Power BI	52
4.4	Suivi des transactions	54
4.4.1	Notebook Databricks	54
4.4.2	Dashboard Power BI	54
4.4.3	Relations entre tables	56
4.5	Conclusion	56
5	RÉALISATION ET VALIDATION DE LA SOLUTION	57
5.1	Outils utilisés	57
5.1.1	Environnement de développement	57
5.1.2	Langages	58
5.2	Résultats	59
5.2.1	Tables générées sur Databricks	59
5.2.1.1	Suivi de l'arrivée des fichiers	59
5.2.1.2	Suivi des fichiers rejetés	59
5.2.1.3	Suivi des jobs databricks	60
5.2.1.4	Suivi des transactions	61

5.2.2	Dashboards Power BI	61
5.2.2.1	Dashboard 01 - Suivi de l'arrivée des fichiers	61
5.2.2.2	Dashboard 02 - Suivi des fichiers rejetés	64
5.2.2.3	Dashboard 03 - Suivi des jobs databricks	67
5.2.2.4	Dashboard 04 - Suivi des transactions	69
5.3	Mise en production et exploitation de la solution	70
5.4	Conclusion	70

Conclusion et Perspectives	71
-----------------------------------	-----------

Webographie et Bibliographie	72
-------------------------------------	-----------

Introduction

Aujourd'hui, la gestion et la qualité des données représentent un enjeu majeur pour les entreprises. Avec l'augmentation du volume de fichiers échangés chaque jour entre différents systèmes, il devient essentiel de mettre en place des mécanismes de contrôle et de validation efficaces. Cette nécessité est d'autant plus cruciale dans les environnements modernes basés sur des data lakes, où les données proviennent de sources variées, sous des formats multiples et à des fréquences diverses.

C'est dans ce contexte que j'ai réalisé mon stage de fin d'études au sein de **CGI**, dans le cadre d'un projet de **refonte du système monétique**. Ce projet visait à migrer les traitements existants sur des bases de données traditionnelles comme **Exadata/Oracle** vers des solutions cloud plus modernes, notamment **AWS** et **Databricks**.

Ma mission principale a consisté à concevoir et développer un système de suivi automatisé des fichiers déposés dans un data lake AWS (S3). L'objectif était de détecter l'arrivée des fichiers, de valider leur contenu en fonction d'un schéma bien défini (délimiteur, encodage, nombre de colonnes, structure...), et d'identifier les fichiers incorrects afin de les rejeter ou de les signaler.

L'ensemble du traitement a été réalisé sur la plateforme Databricks, en utilisant Spark (PySpark) pour l'exécution distribuée des traitements, et Delta Lake pour garantir un stockage fiable des données. J'ai mis en place des tables de configuration et de suivi permettant de définir les règles attendues selon le type de fichier, ainsi que d'enregistrer les résultats détaillés de chaque étape du traitement. Enfin, afin de rendre ces résultats accessibles et facilement interprétables, j'ai développé des **dashboards Power BI**, offrant une visualisation en temps réel de l'état des fichiers, de la qualité des données, et du fonctionnement global des processus de suivi et des rejets.

Je détaillerai dans les sections suivantes l'ensemble des éléments liés à sa mise en œuvre. Ce rapport est structuré en cinq grandes parties :

- **La première partie** présente l'entreprise d'accueil, CGI, ainsi que le cadre général de mon stage et la méthode de développement adoptée.
- **La deuxième partie** propose un rappel des concepts fondamentaux liés au Cloud Computing et au Data Engineering, nécessaires à la compréhension du projet.
- **La troisième partie** traite de l'analyse de l'existant et de la définition des besoins fonctionnels et techniques.
- **La quatrième partie** décrit l'architecture cible et les choix techniques effectués, en détaillant les solutions mises en place pour le suivi et la gestion des rejets.
- **Enfin, la cinquième partie** retrace les différentes étapes de réalisation du projet, en présentant les résultats obtenus, les outils développés, ainsi que les tableaux de bord Power BI conçus pour le suivi des traitements.

Chapitre 1

CONTEXTE GÉNÉRAL DU PROJET

Dans ce chapitre, nous introduisons le contexte général du projet en présentant le groupe CGI, ainsi que le cadre du projet. Nous aborderons les principaux éléments relatifs à l'organisation, les clients, et la méthodologie adoptée pour la conduite du projet.

1.1 Présentation de l'organisme : Le groupe CGI

Le groupe CGI a été fondé en 1976 à Québec, Canada, par Serge Godin et André Imbeau. Aujourd'hui, CGI est l'une des plus grandes entreprises mondiales de services en technologies de l'information et en management, employant environ 90 000 professionnels dans plus de 40 pays. CGI propose une gamme complète de services, y compris des conseils stratégiques en TI, l'intégration de systèmes, la gestion des infrastructures, et des services d'externalisation des processus d'affaires. L'entreprise se distingue par son approche centrée sur les résultats et guidée par les faits pour maximiser le rendement des investissements de ses clients.



FIGURE 1.1 – Logo de CGI [19]

Depuis sa création, CGI a connu une croissance rapide, principalement grâce à une série d'acquisitions stratégiques. Parmi les acquisitions notables, on compte la société américaine AMS en 2004, la société européenne Logica en 2012, et plus récemment Acando, une firme suédoise, en 2019. Ces acquisitions ont permis à CGI d'élargir son empreinte géographique et d'ajouter de nouvelles compétences à son portefeuille de services. [19]

1.1.1 Activités de l'entreprise

CGI propose une gamme complète de services, de solutions et d'expertises pour aider ses clients à accélérer la transformation de leurs activités. L'entreprise offre ses services dans plusieurs secteurs économiques majeurs, représentant plus de 90% des dépenses mondiales en IT.

La figure ci-dessous illustre les différents services du groupe CGI :



FIGURE 1.2 – Les différents services du groupe CGI [5]

Voici les principaux secteurs d'intervention de CGI :

- **Services financiers** : CGI aide les institutions financières, dont la majorité des plus grandes banques et des principaux assureurs, à réduire leurs coûts, à accroître leur efficacité et à améliorer leur service à la clientèle.
- **Gouvernements** : CGI offre du soutien à plus de 2 000 organisations gouvernementales pour réduire leurs coûts, améliorer leur efficacité ainsi que la qualité et la responsabilité des services publics tout en favorisant un engagement accru des citoyens.
- **Santé** : CGI aide plus de 1000 établissements de santé, hôpitaux et ministères de la santé à travers le monde, à mettre en œuvre des solutions TI pour améliorer les soins, les activités et les résultats.
- **Secteur manufacturier, distribution et détail** : CGI contribue à la transformation des activités de plus de 2 000 clients en améliorant leur efficacité et leur loyauté, en réduisant leurs coûts et en stimulant leur croissance durable.
- **Télécommunications et services publics** : CGI aide 6 des 10 principaux fournisseurs mondiaux de services de télécommunications et 9 des 10 plus importants services publics en Europe à diversifier leurs sources de revenus, et à améliorer leur productivité et leurs services.
- **Pétrole et gaz** : CGI accompagne ses clients, dont 3 des 6 plus importantes entreprises pétrolières, à obtenir une valeur accrue de chacun des aspects de leur chaîne d'approvisionnement.
- **Autres secteurs** : CGI est également active dans des domaines tels que les communications et médias, l'énergie, les services aux consommateurs et aux entreprises, l'industrie spatiale, le transport et la logistique, et les sciences de la vie.

1.1.2 Les clients de CGI par secteur

Voici quelques clients et projets gérés par CGI dans divers secteurs d'activité :



FIGURE 1.3 – Clients de CGI par secteur

Dans le secteur manufacturier, elle compte plus de 700 clients, y compris Michelin, Airbus, et Toyota, couvrant des ressources naturelles et l'industrie automobile. Le secteur du pétrole et du gaz inclut des entreprises comme ExxonMobil et Total, avec des services en production et distribution.

Pour le commerce de détail et les services aux consommateurs, CGI a plus de 800 clients, dont L'Oréal et Carrefour, couvrant le commerce de détail et les biens de consommation. Le secteur du transport et de la logistique comprend plus de 200 clients, tels que DHL et Lufthansa, s'occupant des services postaux et logistiques. Enfin, le secteur des services publics inclut plus de 450 clients, comme ENGIE et Neoenergia, se concentrant sur l'eau, l'électricité et le gaz.

1.1.3 CGI au Maroc

CGI Maroc est reconnu comme le principal fournisseur francophone de services IT sur le continent africain. Collaborant avec plus de 35 clients actifs, dont plusieurs grandes entreprises françaises, CGI Maroc joue un rôle essentiel dans le développement de l'IT et de l'innovation. Depuis le début de ses activités en 2004, et le lancement de ses opérations locales en 2009, CGI Maroc n'a cessé de croître. Actuellement, l'entreprise possède trois bureaux situés à Rabat, Casablanca et Fès, fournissant à la fois des services offshore et des solutions destinées au marché local. CGI Maroc détient les certifications ISO 9001 et ISO 27001, garantissant des standards élevés de qualité et de sécurité. Les principaux services proposés incluent :

- **BPO** : Externalisation de certaines activités de l'entreprise vers un prestataire extérieur.
- **Intégration** : Amélioration des performances des organisations grâce aux services d'intégration de systèmes.
- **TMA** : Maintenance des logiciels assurée par une expertise externe en technologies de l'information et de la communication.

En 2018, CGI a inauguré un nouveau centre d'excellence à Fès Shore. Ce centre vise à doubler ses effectifs pour atteindre 250 à 300 employés, renforçant ainsi la capacité de CGI à fournir des services industrialisés, intégrés, agiles et innovants. Ces centres d'excellence sont conçus pour

offrir une forte valeur ajoutée en termes de compétitivité et d'excellence opérationnelle.

Pour répondre à la demande croissante de talents numériques, CGI Maroc a lancé U'DEV, l'École du Développeur, en partenariat avec Euromed et l'ANAPEC. Cette initiative offre une formation gratuite et rémunérée en alternance, avec la garantie d'un emploi en CDI à l'issue du programme. U'DEV est la première école de ce type créée par une ESN, démontrant l'engagement de CGI dans le développement des compétences locales en personnalisant le cursus pédagogique et en finançant la formation des étudiants.[4]

1.1.4 CGI Rabat

Le bureau de CGI à Rabat est un élément stratégique des opérations nearshore de l'entreprise. Situé dans une zone clé, il joue un rôle crucial dans la coordination des services IT offerts aux clients locaux et internationaux. CGI Rabat se distingue par son expertise en gestion de projets complexes et en innovation technologique, contribuant ainsi à la transformation numérique des entreprises clientes. Le centre de Rabat est également impliqué dans divers projets de développement de logiciels, d'intégration de systèmes et de solutions cloud, consolidant sa position en tant que centre d'excellence technologique.

Nous avons effectué notre stage de projet de fin d'études (PFE) chez CGI Rabat au sein de l'équipe **MCM BI**. L'équipe MCM BI de CGI Rabat est spécialisée dans la Business Intelligence et l'ingénierie des données. Elle joue un rôle clé dans le développement de solutions analytiques innovantes à destination des équipes métiers.

Elle est organisée selon la structure suivante :




FIGURE 1.4 – L'équipe MCM BI

1.2 Cadre du projet

Dans cette section, nous allons d'abord présenter le client, puis exposer le contexte du projet. Ensuite, nous détaillerons la motivation, la problématique et les objectifs associés.

1.2.1 Présentation du client

Le client est l'une des plus grandes entreprises énergétiques intégrées au niveau mondial, avec une présence significative dans toutes les branches de l'industrie énergétique, y compris l'exploration, la production, le raffinage, le transport, et la distribution de pétrole, de gaz naturel et d'énergies renouvelables. Fondée en 1924 et basée à Paris, en France, Le client a évolué pour devenir un leader mondial dans la transition énergétique, avec un engagement fort envers le développement durable et la réduction de l'empreinte carbone.

Le client opère à l'échelle mondiale à travers plusieurs segments clés :

- **Exploration et Production** : Le client est actif dans l'exploration et la production de pétrole et de gaz naturel dans divers bassins à travers le monde.
- **Raffinage et Chimie** : L'entreprise possède et exploite des raffineries et des installations chimiques qui convertissent le pétrole brut en produits finis et en produits chimiques spécialisés.
- **Énergies Renouvelables et Solutions Bas Carbone** : Le client investit de manière significative dans les énergies renouvelables telles que le solaire, l'éolien, et l'hydrogène, ainsi que dans des solutions innovantes visant à réduire l'empreinte carbone de ses activités.
- **Distribution et Commercialisation** : À travers ses réseaux de distribution, Le client fournit des produits pétroliers et des services énergétiques à des millions de consommateurs à travers le monde.

Le client s'est engagé à jouer un rôle moteur dans la transition vers une économie bas carbone. L'entreprise cherche activement à diversifier son portefeuille énergétique en investissant dans des technologies propres et des solutions innovantes qui favorisent la durabilité environnementale tout en répondant aux besoins énergétiques mondiaux croissants.

En tant que leader du secteur, Le client consacre des ressources importantes à la recherche et au développement de nouvelles technologies énergétiques. Cela comprend des efforts continus pour améliorer l'efficacité énergétique, développer des alternatives durables aux carburants fossiles traditionnels, et explorer de nouvelles sources d'énergie propre.

1.2.2 Contexte du Projet

Pour réussir ce projet de suivi des fichiers et de gestion des fichiers rejetés, il est essentiel de bien comprendre le contexte global dans lequel il s'inscrit. L'entreprise mène actuellement une refonte de son architecture monétique, avec pour objectif de migrer l'ensemble des traitements critiques depuis la plateforme Exadata vers une infrastructure cloud basée sur AWS. Cette transformation implique de nombreux changements dans les flux de données, les formats de fichiers et les outils utilisés.

Dans ce cadre, la mise en place d'une solution centralisée et automatisée de monitoring s'est imposée comme une nécessité. Elle permet de contrôler efficacement les fichiers transitant au sein de la nouvelle infrastructure data, qu'ils proviennent de sources internes ou externes, et qui sont traités via des technologies comme Databricks et AWS S3. Les enjeux de ce projet sont majeurs : détecter rapidement les anomalies, comprendre les causes des rejets, garantir l'intégrité des données mises à disposition des équipes métiers, et fournir des indicateurs fiables à travers des tableaux de bord interactifs sous Power BI.

1.2.3 Motivation et problématique

Dans les environnements monétiques modernes, la donnée joue un rôle stratégique dans le bon déroulement des opérations critiques. Cependant, la diversité des flux, la sensibilité des traitements, et l'absence d'outils de supervision centralisés compliquent la gestion fiable et sécurisée des fichiers. Ce constat est d'autant plus prégnant dans le cadre du projet de refonte monétique, qui vise à migrer l'infrastructure existante, historiquement hébergée sur Oracle Exadata, vers des solutions cloud modernes telles qu'AWS.

L'architecture actuelle présente des limitations importantes en termes de scalabilité, de flexibilité et de capacité d'intégration avec les outils cloud. Les traitements, souvent rigides et peu automatisés, ne permettent pas une traçabilité fine ni une détection proactive des anomalies. Cette situation engendre des risques opérationnels, notamment en cas de fichiers rejetés ou de retards non détectés dans les chaînes de traitement.

Par ailleurs, le manque d'accessibilité à l'information pour les profils non techniques freine la réactivité des équipes métier, qui doivent souvent solliciter les équipes techniques pour obtenir des indicateurs de suivi, comme la disponibilité ou la conformité des fichiers.

Notre intervention s'inscrit dans cette démarche de transformation en apportant une solution robuste et automatisée pour :

- Superviser en temps réel l'arrivée et le traitement des fichiers monétiques dans le cloud.
- Identifier et tracer les fichiers rejetés avec leurs causes précises.
- Alimenter plusieurs tables de suivi et de gestion des rejets, permettant une historisation fine et segmentée des statuts de traitement.
- Offrir une visualisation claire et accessible via Power BI afin de permettre aux utilisateurs métier de suivre l'état des flux de manière autonome.

Ce projet s'inscrit pleinement dans l'ambition de modernisation du système d'information monétique. Il illustre la mise en œuvre concrète des bonnes pratiques d'ingénierie des données dans un contexte critique, en s'appuyant sur une architecture cloud sécurisée, scalable, et orientée observabilité. Il constitue également une étape clé vers une gouvernance des données plus forte, un meilleur pilotage métier, et une exploitation fiable et efficiente des traitements monétiques dans l'environnement AWS.

1.3 Conduite du projet

La conduite d'un projet implique une série d'étapes méthodiques et bien structurées afin de garantir la réussite et l'atteinte des objectifs fixés. Tout commence par la définition claire des objectifs et des attentes, suivie d'une planification rigoureuse qui inclut l'élaboration d'un calendrier détaillé et la répartition des tâches. La gestion des ressources humaines et matérielles est cruciale pour assurer que chaque membre de l'équipe comprend son rôle et dispose des outils nécessaires pour accomplir ses missions. La communication efficace et régulière est essentielle pour maintenir la cohésion et résoudre rapidement les éventuels problèmes. Le suivi et l'évaluation continue des progrès permettent d'ajuster les stratégies en temps réel pour rester aligné sur les objectifs. Enfin, la phase de clôture consiste à évaluer les résultats, à documenter les leçons apprises et à célébrer les succès pour renforcer la motivation et préparer les futurs projets.

Pour ces raisons, de plus en plus d'entreprises se tournent vers les méthodes Agiles, qui ont largement prouvé leur efficacité. Des études ont montré que les projets utilisant des méthodologies Agiles ont un taux de réussite nettement supérieur à ceux utilisant des approches

traditionnelles comme le Waterfall ou le cycle en V, en particulier dans le secteur des technologies de l'information.

Agile repose sur quatre valeurs clés et douze principes fondamentaux. Contrairement à une méthode fixe, Agile est une philosophie flexible avec plusieurs mises en œuvre possibles. Chaque méthode Agile interprète et applique ces valeurs et principes selon sa propre approche, en développant une terminologie et des pratiques uniques, tout en adhérant aux principes essentiels de l'Agilité.




FIGURE 1.5 – La Méthodologie Agile[13]

CGI est une organisation agile qui met en œuvre l'approche et la promeut auprès de ses clients.

Beaucoup de méthodes agiles existent avec Scrum et Lean étant les célèbres.

1.3.1 Méthodologie : Scrum

Scrum est un cadre méthodologique Agile largement utilisé pour la gestion de projet, particulièrement dans le domaine du développement logiciel. Il se distingue par son approche itérative et incrémentale qui favorise la flexibilité et l'adaptabilité. L'équipe Scrum est structurée autour de trois rôles principaux : le Product Owner, le Scrum Master et l'équipe de développement. Le Product Owner est responsable de la vision du produit et de la priorisation des tâches dans le backlog. Le Scrum Master, quant à lui, veille à ce que les principes de Scrum soient respectés et aide à éliminer les obstacles rencontrés par l'équipe. Enfin, l'équipe de développement se concentre sur la création des incréments de produit à chaque sprint, une période de travail de deux à quatre semaines. Les événements clés de Scrum, tels que la planification de sprint, le daily stand-up, la revue de sprint et la rétrospective, permettent de maintenir une communication constante et d'assurer une amélioration continue du processus et du produit.

1.3.2 Planification du projet

Le projet a été géré selon la méthodologie Scrum, mettant l'accent sur la flexibilité et la collaboration entre les membres de l'équipe. Des réunions quotidiennes ont été planifiées à travers Microsoft Teams, réunissant les membres de l'équipe et le Scrum Master. Ces sessions ont permis à chacun de partager les progrès réalisés la journée précédente et de signaler tout problème ou obstacle rencontré.




FIGURE 1.6 – Processus Scrum[15]



FIGURE 1.7 – Microsoft Teams[10]

La planification du projet s'est déroulée en plusieurs phases. Elle a commencé par la mise en place de l'Infrastructure as Code (IaC) pour automatiser le déploiement des ressources sur AWS. Ensuite, les traitements nécessaires ont été développés sur Databricks afin d'assurer le suivi et la gestion des fichiers. Des tableaux de bord Power BI ont été créés pour visualiser les indicateurs de suivi et les fichiers rejetés.




FIGURE 1.8 – Diagramme Gantt du projet

Le diagramme illustre la planification du projet de suivi et de gestion des fichiers rejetés s'est structurée autour de six sprints distincts. Chaque sprint représente une étape clé dans le déploiement de la solution.

- **Sprint 01 : Mise en place de l'infrastructure AWS** Ce sprint initial s'est concentré sur la création des ressources nécessaires via l'approche Infrastructure as Code (IaC), assurant un environnement stable et automatisé.
- **Sprint 02 : Développement des traitements Databricks** Durant cette phase, les scripts de traitement ont été codés pour analyser les fichiers entrants, détecter les erreurs et consigner les rejets.
- **Sprint 03 : Création des dashboards Power BI** Ce sprint a permis la mise en place de tableaux de bord interactifs facilitant le suivi des flux de données et des fichiers rejetés, à destination des équipes métiers.
- **Sprint 04 : Phase de tests et validation** Cette étape a consisté à valider les différents cas d'usage à travers des jeux de données réels, en s'assurant de la robustesse des traitements et de la pertinence des visualisations.
- **Sprint 05 : Passage en production** Le sprint final a été consacré au déploiement de l'ensemble de la solution dans l'environnement de production, rendant le système pleinement opérationnel.

Cette planification par sprints a permis de structurer le projet de manière organisée et séquentielle, assurant ainsi une gestion efficace des tâches et une transition en douceur vers le cloud Azure.

Conclusion

Ce chapitre a fourni une vue d'ensemble complète du groupe CGI, y compris ses activités, ses clients par secteur, et sa présence au Maroc, particulièrement à Rabat. Il a également exposé le cadre du projet, en présentant le client, le contexte, les motivations et les problématiques. La méthodologie Scrum a été adoptée pour la conduite du projet, soulignant l'importance de la planification méthodique pour garantir le succès du projet.

Chapitre 2

CONCEPTS FONDAMENTAUX

Ce chapitre présente les concepts fondamentaux nécessaires à la compréhension du projet, y compris le Cloud Computing, le Data Engineering, et les différentes architectures.

2.1 Cloud Computing

2.1.1 Définition du Cloud

Le Cloud Computing désigne l'utilisation d'infrastructures informatiques distantes accessibles via Internet pour le stockage, la gestion, l'analyse de données et l'exécution de programmes. Il permet aux utilisateurs d'accéder à des ressources informatiques telles que le stockage de données, la puissance de calcul et les logiciels, hébergés sur des serveurs situés dans des centres de données gérés par des tiers externes.

Le Cloud Computing offre plusieurs avantages et caractéristiques essentiels :




FIGURE 2.1 – Le Cloud Computing[6]

- **Élasticité et scalabilité** : Les utilisateurs peuvent rapidement ajuster les ressources du Cloud en fonction de la demande, permettant une montée en charge facile et une réduction lorsque les besoins diminuent.
- **Mise en commun des ressources** : Les fournisseurs de services Cloud regroupent des ressources informatiques telles que la puissance de traitement, le stockage et le réseau, optimisant ainsi leur utilisation par plusieurs clients simultanément.

- **Paiement à l'usage** : Les modèles de tarification basés sur la consommation permettent aux utilisateurs de ne payer que pour les ressources qu'ils utilisent réellement, optimisant ainsi les coûts opérationnels.
- **Libre-service et automatisation** : Grâce à des interfaces en libre-service et des API, les utilisateurs peuvent provisionner, configurer et gérer leurs ressources informatiques sans intervention manuelle du fournisseur de services Cloud.
- **Sécurité renforcée** : Les fournisseurs de Cloud mettent en œuvre des mesures de sécurité avancées telles que le chiffrement des données, la gestion des identités et l'accès, et des certifications de conformité, offrant ainsi un environnement sécurisé pour les données et les applications.

Dans de nombreux secteurs, le Cloud Computing est largement utilisé pour diverses états de figures, notamment le traitement des données, le développement d'applications, l'apprentissage automatique, l'intelligence artificielle,... etc.

2.1.2 Les types du déploiement du Cloud

Il existe plusieurs types de déploiement du Cloud adaptés à différents besoins :




FIGURE 2.2 – Les types de déploiement du Cloud[7]

- **Cloud public** : Accessible à tous les utilisateurs via Internet, partageant efficacement les ressources entre les clients. Exemples : Amazon Web Services (AWS), Microsoft Azure, Google Cloud.
- **Cloud privé** : Utilisé exclusivement par une seule organisation, souvent pour des raisons de sécurité et de conformité.
- **Cloud hybride** : Combinaison de plusieurs types de Cloud (public, privé ou communautaire) pour répondre à des besoins spécifiques tels que la sécurité renforcée ou la flexibilité.
- **Cloud communautaire** : Partagé par plusieurs organisations ayant des intérêts communs, comme les organismes gouvernementaux ou les associations industrielles.

2.1.3 Modèles de Services Cloud

Les modèles de services Cloud principaux sont :

- **Infrastructure as a Service (IaaS)** : Offre des ressources informatiques virtualisées comme des machines virtuelles, des réseaux et du stockage, permettant aux utilisateurs de déployer leurs propres applications et systèmes d'exploitation.
- **Platform as a Service (PaaS)** : Fournit une plateforme pour développer, exécuter et gérer des applications sans se soucier de l'infrastructure sous-jacente.

- **Software as a Service (SaaS)** : Propose des applications logicielles hébergées en ligne, accessibles via un navigateur web, sans nécessité d'installation locale.




FIGURE 2.3 – Les Modèles de Services du Cloud[16]

2.1.4 Les fournisseurs du Cloud Computing

Les principaux fournisseurs de services Cloud incluent AWS, Microsoft Azure et Google Cloud Platform. Chacun offre une gamme étendue de services adaptés aux besoins variés des entreprises, depuis le stockage et le calcul jusqu'à l'intelligence artificielle et l'analyse de données.

D'autres acteurs importants comme IBM Cloud, Oracle Cloud Infrastructure, Alibaba Cloud et Salesforce Cloud proposent également des solutions spécialisées dans différents domaines, offrant ainsi aux entreprises un large choix selon leurs besoins spécifiques en informatique Cloud.

- **Microsoft Azure** est un fournisseur de Cloud de premier plan, qui propose un ensemble complet de services de Cloud ainsi qu'une interaction étroite avec les technologies Microsoft actuelles. Azure est généralement choisi par les entreprises qui souhaitent une transition en douceur vers l'informatique dématérialisée, en raison de son expérience dans le domaine des logiciels d'entreprise ;



FIGURE 2.4 – Azure[3]

- **AWS** est largement considéré comme le leader du secteur, fournissant une suite complète de services Cloud allant du stockage et du calcul à l'intelligence artificielle et à l'internet

des objets. Il s'agit d'une alternative populaire pour les entreprises de toutes tailles en raison de son énorme infrastructure mondiale, de son échelle et de son expérience ;



FIGURE 2.5 – AWS[1]

- **Google Cloud Platform** se développe progressivement et s'impose comme un concurrent de taille dans le domaine du Cloud. Les capacités sophistiquées d'intelligence artificielle et d'analyse de données de Google Cloud attirent les entreprises désireuses d'utiliser ces technologies pour stimuler l'innovation et faire des choix fondés sur les données.



FIGURE 2.6 – GCP[12]

2.1.5 Justification du Choix d'AWS

La sélection d'Amazon Web Services comme plateforme cloud pour notre projet de refonte monétique repose sur une analyse approfondie des exigences techniques et réglementaires du secteur bancaire. AWS s'est imposé comme la solution la plus adaptée grâce à son écosystème complet dédié aux workloads financiers critiques, combinant sécurité avancée, performance scalable et interopérabilité avec notre architecture existante.

Du point de vue sécurité, essentiel pour des données monétiques sensibles, AWS offre des certifications spécifiques (PCI-DSS, SOC) et des services dédiés comme KMS (Key Management Service) pour le chiffrement des données et IAM pour la gestion fine des accès. Ces fonctionnalités répondent parfaitement aux strictes exigences de conformité bancaire tout en simplifiant les audits réguliers.

Sur le plan technique, la complémentarité entre les services AWS a été déterminante. Amazon S3 fournit un stockage haute disponibilité pour les fichiers transactionnels, tandis qu'AWS Glue permet d'orchestrer efficacement nos pipelines ETL. Cette intégration native avec Databricks, notre plateforme de traitement principale, facilite considérablement l'exécution des jobs PySpark à grande échelle.

L'aspect économique a également joué un rôle clé dans la décision. Le modèle de paiement à l'usage d'AWS, combiné à des capacités d'auto-scaling, permet d'optimiser les coûts pour des charges de travail variables typiques des traitements monétiques, évitant ainsi le surdimensionnement coûteux des infrastructures traditionnelles.

Face aux alternatives cloud, AWS présente des avantages distincts. Si Azure excelle dans les environnements Microsoft, son offre pour le traitement distribué de données massives reste moins mature qu'AWS pour nos cas d'usage PySpark. Quant à Google Cloud, malgré ses atouts en machine learning, son écosystème s'intègre moins bien avec nos systèmes hérités et l'approche de migration progressive depuis Exadata.

En définitive, le choix d'AWS s'appuie sur sa capacité unique à répondre simultanément aux impératifs de sécurité bancaire, aux besoins de performance pour le traitement distribué, et à l'intégration transparente avec notre stack technique (Databricks, Power BI). Cette plateforme offre le meilleur équilibre entre innovation cloud et stabilité opérationnelle requise pour les systèmes monétiques critiques.

2.2 Data Engineering

Le *Data Engineering* ou l'ingénierie des données est une discipline clé dans les systèmes d'information modernes. Elle consiste à concevoir, construire et maintenir des systèmes permettant de collecter, transformer, stocker et rendre accessible la donnée de manière fiable, sécurisée et performante.




FIGURE 2.7 – Data Engineering[8]

2.2.1 Définition et rôle du Data Engineer

Le rôle du *Data Engineer* est de construire l'infrastructure de traitement des données à grande échelle. Il développe des pipelines de données automatisés et optimisés pour assurer l'acquisition, la transformation, le nettoyage, l'enrichissement et la mise à disposition des données aux différents utilisateurs finaux, notamment les *Data Analysts*, *Data Scientists* ou applications métiers.

2.2.2 Écosystème technologique du Data Engineering

Le domaine du Data Engineering repose sur un ensemble d'outils et de technologies permettant de répondre à différents besoins. Parmi les plus courants, on retrouve :

- **Systèmes de stockage** : S3, BigQuery, Snowflake.

- **Moteurs de traitement** : Apache Spark, Databricks, Apache Flink, Beam.
- **Outils d'orchestration** : Airflow, Azure Data Factory, Databricks Workflows.
- **Bases de données** : PostgreSQL, Cassandra, MongoDB.
- **Outils de streaming** : Kafka, Spark Structured Streaming, Kinesis.

2.2.3 Les pipelines de données : ETL vs ELT

Les pipelines de données sont les fondations du Data Engineering. Deux approches dominent :

- **ETL (Extract, Transform, Load)** : les données sont extraites des sources, transformées avant le chargement dans le système cible (data warehouse, data lake).
- **ELT (Extract, Load, Transform)** : les données sont extraites et chargées telles quelles dans un environnement de stockage (souvent un data lake ou lakehouse), puis transformées à la demande ou de manière différée.

L'approche ELT est de plus en plus privilégiée dans les architectures modernes, notamment en raison de la montée en puissance des moteurs de traitement comme **Apache Spark** et **Databricks**.

2.2.4 Qualité, fiabilité et gouvernance des données

Un aspect essentiel du travail de l'ingénieur data est d'assurer la qualité et la fiabilité des données. Cela implique :

- La détection des anomalies (valeurs manquantes, doublons, incohérences),
- La validation des schémas et le contrôle des formats attendus,
- La mise en place de métriques de suivi de la qualité (nombre de lignes, conformité, taux de rejet),
- Le suivi de la traçabilité (*data lineage*) et la gestion des accès via des politiques de sécurité,
- L'automatisation des traitements et leur surveillance via des workflows robustes.

La gouvernance des données devient ainsi une composante incontournable de l'ingénierie des données, surtout dans des contextes où les réglementations imposent des standards de gestion stricts.

2.3 L'ingénierie des données dans le Cloud

Avec l'explosion des volumes de données et la nécessité d'une haute scalabilité, le cloud computing s'est imposé comme une plateforme incontournable pour l'ingénierie des données. Il permet de disposer d'infrastructures flexibles, d'outils managés, et d'une capacité d'adaptation rapide aux charges de travail, tout en réduisant les coûts liés à la maintenance.

2.3.1 Avantages du cloud pour l'ingénierie des données

Le recours au cloud dans les projets de traitement des données présente plusieurs avantages :

- **Scalabilité automatique** : les ressources s'adaptent dynamiquement à la charge (scale up/down).
- **Disponibilité mondiale** : les services sont accessibles dans différentes régions et zones géographiques.

- **Services managés** : réduction de l'effort opérationnel (gestion de clusters, sécurité, monitoring).
- **Paiement à l'usage** : facturation basée sur la consommation réelle.
- **Intégration facile avec des services d'IA/ML, de BI et de sécurité.**

2.3.2 Architectures cloud modernes : Data Lake, Data Warehouse, Lakehouse

- **Data Warehouse** : stocke des données structurées pour des usages analytiques. Exemples : BigQuery, Snowflake, Amazon Redshift.
- **Data Lake** : stocke des données brutes (structurées, semi-structurées, non structurées) à bas coût. Exemples : AWS S3, Azure Data Lake Storage.
- **Lakehouse** : combine les avantages du data lake et du data warehouse. Il permet des analyses performantes sur des données brutes, avec des fonctionnalités ACID et un moteur de requête rapide. Exemple : **Databricks avec Delta Lake**.

2.3.3 Approche Cloud-Native du Data Engineering

Les grands fournisseurs de cloud offrent des services spécifiques pour la gestion des données :

- **AWS** : AWS Glue, S3, Kinesis, Redshift.
- **Azure** : Azure Data Factory, Azure Synapse Analytics, Databricks.
- **GCP** : Cloud Dataflow, BigQuery, Cloud Composer, Dataproc.

Ces services permettent de mettre en œuvre des pipelines de données modernes en mode **serverless** ou **managé**, avec des capacités d'intégration, d'orchestration et de surveillance optimisées.

2.4 Présentation de Databricks

2.4.1 Origine et positionnement

Databricks est une plateforme analytique de nouvelle génération fondée en 2013 par *les créateurs d'Apache Spark* au sein de l'université de Berkeley. Leur objectif initial était de proposer une solution unifiée permettant d'exploiter les capacités de traitement distribué de Spark tout en offrant un environnement accessible, collaboratif et adapté aux besoins croissants de l'ingénierie des données, de la science des données et du machine learning.

Positionnée comme une plateforme d'analyse unifiée, Databricks répond aux exigences des entreprises modernes en matière de traitement massif des données (*big data*), tout en facilitant le développement de modèles analytiques et d'IA à l'échelle.

2.4.2 Delta Lake et le paradigme Lakehouse

Au cœur de l'architecture Databricks se trouve **Delta Lake**, une technologie open source développée par Databricks qui introduit des transactions ACID, la gestion des versions et le traitement unifié des données brutes et transformées dans un data lake.

Cela a conduit à l'émergence du paradigme **Lakehouse**, qui combine les avantages des data



FIGURE 2.8 – Logo Databricks[9]

lakes (souplesse, stockage à bas coût, ingestion de données non structurées) et des data warehouses (intégrité, performance, gestion fine des données).

Les principaux avantages de Delta Lake sont :

- **Garantie ACID** : les opérations de lecture et d'écriture sont sûres et fiables.
- **Schema Enforcement et Evolution** : vérification du schéma attendu et adaptation aux changements.
- **Time Travel** : possibilité d'accéder aux versions précédentes d'une table.
- **Performances accrues** : via les fichiers au format optimisé **Parquet**, l'indexation, et le **Z-Ordering**.

2.4.3 L'architecture Medallion : structuration des données dans le Lakehouse

Dans le prolongement du paradigme Lakehouse, Databricks propose une approche structurée de la gestion des données à travers le concept d'architecture Medallion. Cette architecture repose sur une division des données en plusieurs couches logiques, chacune ayant un objectif spécifique en termes de qualité, de transformation, et d'usage analytique :

- **Bronze (Données brutes)** : cette couche contient les données *raw* ingérées telles quelles depuis les sources (fichiers, API, bases de données, etc.), sans transformation majeure. Elle permet de conserver un historique complet et fidèle de l'information.
- **Silver (Données nettoyées et enrichies)** : les données sont nettoyées, validées (conformité au schéma), filtrées et parfois enrichies (jointures, décodage de dimensions, etc.). Cette couche vise à fournir une donnée fiable, prête pour les analyses standardisées.
- **Gold (Données agrégées et prêtes pour la BI)** : les données sont transformées pour répondre à des cas d'usage métier spécifiques (indicateurs, tableaux de bord, rapports). Elles sont généralement agrégées et optimisées pour la consommation par des outils BI ou ML.

Cette architecture en couches permet de :

- Structurer les traitements de données de manière modulaire, traçable et reproductible.

— Faciliter la gouvernance et la qualité des données.

— Accélérer les analyses métier grâce à des jeux de données pré-calculés et fiables.

Elle s'intègre naturellement avec les tables Delta et le moteur Spark, et peut être orchestrée via les *Jobs*, *Workflows* ou outils d'orchestration externes.




FIGURE 2.9 – Architecture Medallion[14]

2.4.4 Notebooks collaboratifs et exécution distribuée avec Apache Spark

L'un des éléments les plus différenciateurs de Databricks est l'intégration directe d'environnements de développement collaboratifs via des **notebooks interactifs**. Ces derniers permettent d'écrire du code en Python, SQL, Scala ou R, avec un rendu visuel immédiat et des visualisations intégrées. Ces notebooks favorisent le travail collaboratif en temps réel, avec la possibilité de commenter, versionner et partager les analyses de manière fluide. Ils constituent ainsi un outil central pour le prototypage rapide, le data storytelling et la reproductibilité des expériences analytiques.

Par ailleurs, l'exécution des traitements repose sur le moteur **Apache Spark**, optimisé par Databricks pour une performance maximale. Ce moteur permet :

- L'exécution distribuée des traitements sur des clusters Spark.
- L'analyse rapide de gros volumes de données, en mémoire.
- La parallélisation automatique des jobs selon les partitions de données.
- La prise en charge des pipelines batch, interactifs et en streaming.
- L'élasticité du calcul en fonction des besoins, avec une gestion dynamique des ressources.

- L'intégration fluide avec des sources de données variées comme Delta Lake, Azure Data Lake ou S3.

Cette combinaison de notebooks collaboratifs et d'un moteur de traitement puissant permet aux équipes d'ingénierie de travailler de manière agile, reproductible et scalable, tout en garantissant la traçabilité et la reproductibilité des résultats.



FIGURE 2.10 – Apache Spark[20]

2.5 Justification des choix technologiques

2.5.1 Pourquoi le cloud AWS ?

Le choix du cloud AWS ne découle pas directement d'une décision technique de CGI, mais s'aligne sur les orientations stratégiques du client. En effet, ce dernier adopte une politique multi-cloud, consistant à répartir ses données entre plusieurs fournisseurs cloud (notamment AWS et Azure), afin d'éviter la dépendance à un unique acteur et de garantir une meilleure résilience.

Dans le cadre du projet DataHubMSP, l'environnement AWS a été retenu pour héberger l'ensemble de l'architecture cible. Ce choix s'explique par :

- **La présence historique du client sur AWS** pour d'autres projets similaires.
- **L'uniformisation des outils de sécurité, d'accès et de déploiement** au sein de leur environnement AWS.
- **La compatibilité native avec Databricks**, qui permet une mise en œuvre fluide sur ce cloud provider.

Pourquoi un Data Lake sur S3 ?

Le choix d'Amazon S3 comme solution de stockage du Data Lake repose sur une comparaison des critères techniques et opérationnels avec d'autres solutions cloud leaders (comme Azure Data Lake Storage - ADLS ou Google Cloud Storage - GCS). Le tableau suivant illustre les éléments déterminants ayant motivé cette sélection :

Critère	Amazon S3	Azure ADLS Gen2	Google Cloud Storage
Coût	Tarification simple et économique à l'usage	Légèrement plus coûteux en mode haute performance	Équivalent à S3 selon les régions
Interopérabilité	Compatible avec tous les moteurs open source (Spark, Hive, Presto)	Optimisé pour Azure Synapse / Databricks	Très intégré à BigQuery et Dataflow
Performances	Très bonnes performances sur les lectures parallèles	Très performantes avec ADLS Gen2 + Databricks	Bonne latence, mais parfois moins optimisée pour Spark
Séparation stockage/calcul	Oui, architecture pleinement dissociée	Oui, avec ADLS Gen2	Oui
Compatibilité Delta Lake	Native (Databricks sur AWS)	Compatible via Databricks	Compatible via Databricks
Intégration avec l'environnement client	Déjà en place et validée	Partiellement utilisée	Pas utilisée

TABLE 2.1 – Benchmark des solutions de stockage cloud pour le Data Lake

Ce benchmark démontre qu'Amazon S3 répond non seulement aux exigences techniques (performance, compatibilité Delta Lake, coût), mais s'intègre également naturellement dans l'écosystème AWS déjà adopté par le client. De plus, sa compatibilité native avec Databricks en fait un choix optimal pour le déploiement de l'architecture Medallion.

2.5.2 Pourquoi Databricks ?

Dans le cadre du projet DataHubMSP, Databricks a été choisi comme plateforme de traitement des données et d'orchestration des pipelines. Ce choix repose sur les besoins suivants :

- **Unification des traitements batch, streaming et analytiques** au sein d'une même plateforme.
- **Traitement de gros volumes de données** via un moteur distribué basé sur Apache Spark.
- **Prise en charge native du format Delta Lake** pour garantir fiabilité et gouvernance des données dans le Data Lake.
- **Orchestration simple via Databricks Jobs et Workflows.**
- **Environnement collaboratif** à travers les notebooks partagés, multi-langages (SQL, Python, etc.).

Cependant, d'autres solutions ont également été considérées, notamment **Snowflake**, qui représente un acteur majeur dans le monde des plateformes analytiques modernes. Le tableau ci-dessous présente un benchmark comparatif entre Databricks et Snowflake, basé sur les critères du projet.

Critère	Databricks	Snowflake
Moteur de calcul	Apache Spark (traitement distribué in-memory)	Moteur SQL propriétaire optimisé pour l'analytique
Support du Lakehouse	Oui (architecture Medallion avec Delta Lake)	Oui (Iceberg ou Delta, mais plus récent et partiel)
Traitement streaming + batch	Oui (Structured Streaming)	Partiel (support streaming plus limité)
Environnement collaboratif	Notebooks, gestion de versions, support multi-langage (SQL, Python, Scala, R)	SQL-centric, notebooks via Snowsight mais fonctionnalités plus limitées
Performance sur SQL pur	Bonne, optimisable via Photon	Excellente (optimisé pour le SQL)
Orchestration de jobs	Jobs et Workflows intégrés + intégration facile avec Airflow	Orchestration disponible mais plus orientée batch analytique
Flexibilité pour pipeline custom	Haute (code-first)	Limitée (approche SQL-first)
Intégration avec AWS	Native et mature (Databricks sur AWS)	Native également, mais dépend moins des outils AWS
Adéquation avec besoin projet	Haute : pipeline ingestion, validation, transformation, gouvernance + visualisation	Moyenne : très bonne pour requêtage SQL, mais moins adaptée à la logique de processing orientée fichiers

TABLE 2.2 – Benchmark Databricks vs Snowflake dans le contexte du projet DataHubMSP

Ce benchmark met en évidence que, bien que Snowflake soit un excellent moteur SQL pour la BI, **Databricks répond mieux aux besoins de traitement de fichiers massifs, de validation schématique, d'orchestration et de gouvernance dans un contexte de Data Lakehouse**, comme celui du projet DataHubMSP. La richesse de son écosystème open-source, sa flexibilité de développement, et son alignement avec l'architecture Medallion ont conforté ce choix.

Conclusion

Les choix technologiques effectués dans le cadre du projet DataHubMSP ont été guidés par des critères de performance, de flexibilité, de compatibilité et de gouvernance. L'adoption d'AWS s'inscrit dans une stratégie multi-cloud définie par le client, tandis que le choix de S3 comme solution de stockage pour le Data Lake s'est appuyé sur une analyse comparative détaillée. Databricks, combiné à Delta Lake, a été retenu pour sa capacité à répondre aux exigences de traitement massif, de validation, de transformation et de fiabilité des données, tout en s'intégrant parfaitement à l'écosystème cloud choisi. Ces décisions ont permis de mettre en place une architecture moderne, évolutive et conforme aux standards du data engineering actuel.

Chapitre 3

ANALYSE ET ETUDE PREALABLE

Dans ce chapitre, nous présentons d’abord la solution existante (AS-IS) avant migration, puis la nouvelle solution mise en place dans le cadre du projet DataHubMSP et de la migration de l’application FleetCard vers AWS et Databricks (TO-BE).

3.1 Architecture existante (AS-IS)

3.1.1 Contexte de l’ancienne solution

Avant la migration vers une solution moderne basée sur le Cloud, l’application **FleetCard** reposait sur une infrastructure classique on-premise. Elle s’appuyait principalement sur une base de données **Oracle** hébergée sur une plateforme **Exadata**. Cette architecture, bien qu’efficace à ses débuts, présentait plusieurs limites en termes de flexibilité, de performance et d’évolutivité.

3.1.2 Description de l’architecture existante

L’organisation technique de la solution FleetCard avant la transformation peut être résumée comme suit :

- **Base de données Oracle Exadata** : utilisée pour le stockage des données transactionnelles et référentielles.
- **Chargement des données** : des fichiers plats étaient importés via des outils ETL ou directement à l’aide de **SQL Loader**.
- **Traitements PL/SQL** : les calculs des indicateurs, l’alimentation des datamarts et la génération des objets métiers étaient réalisés au travers de packages PL/SQL.
- **Exposition de la donnée** :
 - **BO** : utilisé pour construire des univers et produire des rapports standards à destination des métiers.
 - **Power BI** : utilisé ponctuellement pour des tableaux de bord ad hoc.
- **Manque d’automatisation et de traçabilité** :
 - Suivi manuel des arrivées de fichiers.
 - Vérification ponctuelle de la qualité des données sans mécanisme de contrôle systématique.
 - Difficultés d’accès aux indicateurs pour les utilisateurs métiers, nécessitant l’intervention des équipes techniques.

3.1.3 Illustration de l'architecture

La Figure ci-dessous illustre l'architecture en place avant le projet de transformation :




FIGURE 3.1 – Architecture précédente (FleetCard - Oracle Exadata, PL/SQL, BO/Power BI)

3.1.4 Limites et problématiques identifiées

Malgré sa stabilité, cette solution présentait plusieurs freins à la performance et à l'agilité des équipes métiers :

- **Scalabilité limitée** : l'infrastructure Exadata on-premise ne permettait pas d'adapter rapidement les capacités de calcul face aux variations de la charge.
- **Rigidité des traitements** : les processus codés en PL/SQL étaient complexes à maintenir et difficiles à auditer ou à modifier.
- **Faible automatisation** : l'absence de pipelines automatisés pour le traitement et la supervision des données induisait un risque d'erreur humaine et des délais de traitement accrus.
- **Visibilité réduite pour les métiers** : l'accès aux données analytiques dépendait fortement de l'intervention des équipes techniques, allongeant les délais de prise de décision.

Ces constats ont motivé la réflexion autour d'une nouvelle architecture plus moderne, évolutive et orientée Cloud, qui sera présentée dans la section suivante.

3.2 Architecture cible (TO-BE)

3.2.1 Introduction à la nouvelle solution

Dans le cadre de la modernisation de la plateforme FleetCard, une nouvelle architecture a été conçue autour de l'initiative **DataHubMSP**. L'objectif principal est de centraliser l'ensemble des sources de données au sein d'un écosystème cloud sécurisé, normalisé et automatisé, tout en garantissant une traçabilité complète et une haute qualité de la donnée.

La solution repose désormais sur les technologies **AWS** pour l'hébergement cloud et **Data-bricks** pour les traitements distribués et le pilotage des flux de données.

3.2.2 Phasage du projet DataHubMSP

La mise en œuvre de DataHubMSP a été découpée en **sept phases** successives permettant d'assurer un déploiement progressif, contrôlé et collaboratif entre les différentes équipes.




FIGURE 3.2 – Phasage du projet DataHubMSP

Voici le détail des différentes phases :

1. **Phase 1 – Mise en place de l'IaC** : Utilisation des building blocks standards TE pour le déploiement automatisé de l'infrastructure.
2. **Phase 2 – Spécification du STD** : Définition ou validation du contrat d'interface des objets à traiter dans les zones Bronze, Silver et Gold.
3. **Phase 3 – Validation des objets** : Revue collaborative du STD avec les équipes techniques et les représentants métiers.
4. **Phase 4 – Développements et intégration Data Galaxy** : Conception des pipelines Databricks, ingestion des données, et intégration automatique des métadonnées via le connecteur Data Galaxy.
5. **Phase 5 – Tests internes** : Exécution de tests techniques (unitaires et d'intégration) pour garantir la fiabilité des objets construits.
6. **Phase 6 – Recette fonctionnelle** : Réalisation des tests Silver/Gold par les utilisateurs métiers et ajustements éventuels avant validation finale.
7. **Phase 7 – MEP** : Déploiement progressif des objets dans les environnements de recette, puis de production.

Ce découpage méthodologique a permis de favoriser une montée en compétence progressive des équipes, une meilleure qualité de livraison et une maîtrise du planning projet.

3.2.3 Migration de l'application FleetCard vers AWS

Dans cette nouvelle architecture, l'application FleetCard a été complètement migrée vers l'environnement cloud AWS. L'ensemble des traitements historiques réalisés en PL/SQL sur Oracle Exadata ont été repensés et réimplémentés sous forme de pipelines Databricks.




FIGURE 3.3 – Migration de FleetCard vers l'écosystème AWS

Les principales étapes de cette migration sont les suivantes :

- **Extraction des données** : Accès aux tables Oracle Exadata pour l'extraction des données via SQL Loader ou des processus ETL existants.
- **Ingestion dans le Data Lake** : Les fichiers extraits sont transférés de manière sécurisée vers un bucket Amazon S3, en utilisant SAP Data Fabric.
- **Chargement automatisé dans Databricks** : Utilisation de la fonctionnalité Auto Loader pour ingérer automatiquement les fichiers dans la zone Bronze du Data Lake.
- **Réécriture des traitements** : Les calculs et transformations réalisés initialement en PL/SQL sont désormais codés en PySpark au sein de notebooks Databricks, puis déployés sous forme de jobs.
- **Maintien de la structure métier** : Les objets métier tels que les tables Silver/Gold ont été reconstruits à l'identique afin de préserver la compatibilité avec les rapports existants.

Grâce à cette nouvelle architecture, l'organisation bénéficie désormais d'un socle de données moderne, évolutif et automatisé, facilitant l'accès aux données, la gouvernance et l'innovation métier.

3.2.4 Architecture technique actuelle

La solution actuelle repose sur une architecture *cloud-native*, modulaire et scalable, structurée selon le schéma fonctionnel des trois couches Medaillon : **Bronze**, **Silver** et **Gold**. Cette organisation permet une gestion optimisée du cycle de vie des données, depuis leur ingestion jusqu'à leur exposition aux utilisateurs finaux.




FIGURE 3.4 – Figure 4 : Architecture fonctionnelle actuelle (Ingestion, DataHubMSP, Exposition)

Les principaux composants de cette architecture sont détaillés ci-dessous :

- **Ingestion des données :**
 - Utilisation du **SAP Data Fabric** pour transférer automatiquement les fichiers tiers dans le *Data Lake* (Amazon S3).
 - Exploitation de la fonctionnalité **Auto Loader** de Databricks pour détecter en temps réel les nouveaux fichiers et les charger dans la couche *Bronze*.
- **Traitement et standardisation via le DataHubMSP :**
 - **Bronze** : stockage des données brutes (non transformées) en format Delta, assurant une conservation complète de l'historique.
 - **Silver** : nettoyage, validation des schémas à partir des STD, enrichissement via des jointures avec des référentiels métiers.
 - **Gold** : génération de tables métiers agrégées prêtes à l'analyse (KPI, reporting).
- **Orchestration des traitements :**
 - Planification automatique des étapes via **Databricks Jobs** et **Workflows**.
 - Supervision des indicateurs clés (coût, performance, temps de traitement) directement dans l'environnement Databricks.
- **Exposition et visualisation des données :**
 - Mise à disposition des données via **Power BI**, grâce à un connecteur sécurisé permettant aux métiers de consulter les indicateurs sans connaissance technique.
 - Conservation de l'outil **BO** pour certains rapports existants nécessitant une compatibilité spécifique.
- **Sécurité et gouvernance des données :**
 - Utilisation de **AWS Secrets Manager** pour la gestion sécurisée des identifiants sensibles.
 - Mise en œuvre de contrôles d'accès avec **IAM** selon les rôles utilisateurs.

- Politique de sauvegarde et rétention conforme aux SLA : *RTO/RPO* de 24h et disponibilité garantie de 99,5%.

Cette architecture technique répond pleinement aux enjeux identifiés lors de l’analyse de l’ancienne solution :

- **Évolutivité** : l’architecture est capable de s’adapter dynamiquement à la volumétrie des données grâce à l’élasticité de Spark sur Databricks.
- **Traçabilité** : le format Delta permet un suivi des versions et des modifications avec la fonctionnalité **Time Travel**.
- **Automatisation complète** : du dépôt de fichiers à l’exposition des données, les processus sont pilotés sans intervention manuelle.
- **Accessibilité pour les métiers** : les utilisateurs disposent d’un accès simplifié via Power BI, sans nécessité de requêtes SQL complexes.
- **Compatibilité assurée** : les structures des objets FleetCard ont été conservées afin de garantir la continuité des rapports existants.

3.3 Analyse comparative et benchmark

Afin d’évaluer les apports de la nouvelle architecture mise en place dans le cadre du projet DataHubMSP, un benchmark entre la solution précédente (AS-IS) et la solution actuelle (TO-BE) a été réalisé. Cette analyse comparative permet de mettre en évidence les gains obtenus en termes de performance, de gouvernance, de flexibilité et d’expérience utilisateur.

Critère	Architecture AS-IS	Architecture TO-BE
Type d’hébergement	On-premise (Oracle Exadata)	Cloud (AWS + Databricks)
Traitement des données	PL/SQL (rigide, peu flexible)	Pipelines PySpark dans Databricks (modulaire et maintenable)
Ingestion des données	Manuelle via SQL Loader ou outils ETL	Automatisée via SAP Data Fabric, et Auto Loader
Stockage	Oracle	Data Lake S3 structuré en Bronze, Silver, Gold
Automatisation	Très faible, beaucoup de traitements manuels	Workflows Databricks pilotant toute la chaîne de traitement
Exposition des données	BO et Power BI (accès partiel, dépendance IT)	Power BI + BO (accès simplifié, connecteur direct)
Gouvernance des données	Faible traçabilité, suivi manuel	Historisation complète avec Delta Lake + Time Travel
Sécurité	Contrôles manuels d’accès, peu centralisés	IAM + AWS Secrets Manager + politiques de sauvegarde

TABLE 3.1 – Tableau comparatif entre l’architecture AS-IS et TO-BE

Ce benchmark met en évidence les nombreux avantages apportés par la migration vers une architecture cloud-native. Les capacités d'automatisation, de supervision et d'accessibilité ont été significativement améliorées, tout en réduisant la complexité technique pour les utilisateurs métiers.

Ces évolutions permettent également d'aligner la plateforme sur les standards actuels de la data gouvernance et de garantir une meilleure évolutivité pour les besoins futurs.

Conclusion du chapitre

L'analyse de l'architecture existante a permis d'identifier plusieurs limites techniques et fonctionnelles, justifiant la nécessité d'une refonte en profondeur. La mise en place de la solution DataHubMSP basée sur AWS et Databricks a apporté une réponse adaptée aux enjeux de scalabilité, de traçabilité et d'automatisation. Le benchmark comparatif met en évidence des gains significatifs en matière de performance, de gouvernance et d'accessibilité métier. Cette transition marque ainsi un tournant stratégique vers une plateforme moderne, durable et orientée data-driven. Le chapitre suivant s'attachera à présenter les outils et technologies utilisés pour concrétiser cette nouvelle architecture.

Chapitre 4

CONCEPTION ET ÉTUDE TECHNIQUE

Ce chapitre présente la conception technique des solutions mise en place pour le monitoring et le suivi des rejets. Il s'articule autour des notebooks développés sur Databricks pour le traitement des données, ainsi que des dashboards Power BI utilisés pour la visualisation des indicateurs clés. L'ensemble repose sur une modélisation adaptée des tables sources et finales, facilitant l'analyse des données et l'aide à la décision.

4.1 Suivi des fichiers

4.1.1 Notebook Databricks

Le notebook développé pour le suivi des fichiers joue un rôle essentiel dans le contrôle qualité des données en amont du pipeline analytique. Son objectif est de détecter automatiquement les fichiers manquants, en retard, vides ou corrompus, tout en validant certains attributs techniques tels que la présence d'un en-tête, le format du délimiteur ou encore l'encodage. En complément de ces vérifications, le notebook extrait des métadonnées pour chaque fichier, telles que la date et l'heure d'arrivée, la taille du fichier ou encore le nombre de lignes qu'il contient.

Le processus commence par le chargement d'une configuration paramétrée, définissant les répertoires à analyser et les règles d'évaluation. Le job scanne ensuite ces emplacements pour identifier les fichiers attendus. Il distingue les fichiers réellement présents, ceux qui sont absents ou arrivés en retard, ainsi que les fichiers supplémentaires ou non attendus. Une fois identifiés, les fichiers sont analysés individuellement pour extraire les métadonnées pertinentes. Une phase de validation est ensuite appliquée pour déterminer leur conformité. Chaque fichier est classé selon son état : valide, vide, corrompu, en retard, ou autre statut défini.

L'ensemble des informations collectées est centralisé dans une table dédiée nommée file tracking. Cette table regroupe à la fois les métadonnées techniques et le statut final de chaque fichier traité. Ce dispositif constitue une base fiable pour l'audit, le monitoring ou encore la mise en place d'alertes automatisées en cas d'anomalie.

4.1.2 Modélisation des données

Dans le cadre du suivi automatisé des fichiers, deux tables principales ont été conçues afin d'assurer une traçabilité complète et une flexibilité de configuration. L'une centralise les métadonnées collectées lors de l'arrivée et du traitement des fichiers, tandis que l'autre regroupe les paramètres de configuration définissant les attentes pour chaque fichier à surveiller.

La première table, **file_tracking**, constitue le cœur du dispositif de suivi. Elle est mise à jour à chaque exécution du notebook avec l'ensemble des informations détectées ou calculées pour chaque fichier analysé. On y retrouve notamment les dates d'arrivée, les volumes, les validations techniques effectuées (encodage, en-tête, délimiteur), ainsi que le statut final du fichier (valide, vide, corrompu, etc.). Cette table est essentielle pour toute opération d'audit, d'analyse ou d'alerte automatisée.

Colonne	Description
file_name_with_date	Nom du fichier avec la date d'arrivée intégrée dans son nom
file_name	Nom brut du fichier sans date ni chemin
arrival_time	Heure réelle d'arrivée du fichier
reception_day	Jour de réception prévu ou effectif du fichier
arrival_status	Statut de l'arrivée du fichier (ex. on_time , late , missing)
is_corrupted	Indique si le fichier est corrompu
is_empty	Indique si le fichier est vide
actual_size	Taille réelle du fichier
size_check	Résultat du contrôle de taille (OK, KO)
actual_line_count	Nombre réel de lignes
line_count_check	Contrôle du nombre de lignes
num_columns	Nombre de colonnes détectées
actual_delimiter	Délimiteur détecté
delimiter_check	Contrôle du délimiteur
actual_encoding	Encodage détecté
encoding_check	Contrôle de l'encodage
schema_validated	Validation du schéma (booléen)
processing_start_date	Début de traitement
processing_end_date	Fin de traitement
processing_duration	Durée de traitement
comment	Message ou commentaire d'erreur
row_insertion_time	Date d'insertion dans la table

TABLE 4.1 – Description des colonnes de la table de suivi des fichiers

La seconde table, **param_file_monitoring**, regroupe l'ensemble des paramètres nécessaires à la surveillance des fichiers. Elle définit pour chaque fichier les éléments attendus : nom, format, chemin, encodage, présence d'un en-tête, nombre de lignes ou colonnes attendu, taille approximative, et plage horaire de réception. Cette table permet une configuration souple et dynamique, rendant le système adaptable à différents types de flux et domaines fonctionnels.

Colonne	Description
file_name	Nom exact du fichier attendu
file_prefix	Préfixe d'identification (<i>full</i> ou <i>delta</i>)
file_format	Format du fichier (CSV, JSON, PARQUET)
description	Description fonctionnelle
fonctionnal_domain	Domaine fonctionnel du fichier
specificity	Spécificité éventuelle (nom dynamique, etc.)
source_system	Système source d'origine
file_path	Chemin d'arrivée prévu
std_path	Répertoire standardisé
expected_delimiter	Délimiteur attendu
expected_encoding	Encodage attendu
expected_header_presence	Présence attendue d'un en-tête (true/false)
expected_num_columns	Nombre de colonnes attendu
expected_num_rows	Nombre de lignes approximatif
expected_size	Taille attendue du fichier
empty_possible	Fichier autorisé à être vide (oui/non)
expected_arrival_time	Heure d'arrivée prévue
max_delay	Délai de retard toléré
mon-sun	Indicateurs de réception par jour de la semaine
job	Nom du job de traitement associé
chain	Chaîne de traitement associée
last_successful_run	Dernière exécution réussie
created_at	Date de création de la configuration
updated_at	Date de dernière mise à jour

TABLE 4.2 – Description des colonnes de la table de configuration des fichiers

4.1.3 Architecture de la modélisation

Afin d'assurer un suivi rigoureux et automatisé des fichiers entrants, une architecture de modélisation dédiée a été mise en place. Celle-ci repose sur une orchestration du traitement via un notebook Databricks, une configuration dynamique centralisée, et un système de stockage structuré des métadonnées issues des fichiers analysés. Cette architecture permet de gérer différents types de fichiers de manière évolutive, tout en garantissant la traçabilité, la validation et l'analyse des données en amont des traitements analytiques.




FIGURE 4.1 – Diagramme d'Activité du Notebook - Suivi des fichiers

Le schéma ci-dessus illustre le flux global d'exécution du notebook Databricks responsable du suivi de l'arrivée des fichiers. Ce job permet de vérifier automatiquement si les fichiers attendus sont présents, valides et correctement structurés, tout en générant des alertes en cas d'anomalie.

4.1.4 Dashboard Power BI

Le tableau de bord *01-Files_arrival_monitoring* a été conçu pour offrir une vision synthétique de l'arrivée des fichiers dans le Data Lake. Il permet d'identifier leur statut (à l'heure, en retard, manquant) ainsi que leur conformité aux spécifications attendues. Cet outil facilite le suivi quotidien des flux, notamment en ce qui concerne les retards, les écarts de structure et les volumes traités. Il est principalement alimenté par les données issues de la table `file_tracking`, enrichies par les paramètres de configuration définis dans `param_file_monitoring`.

Ce tableau de bord est destiné aux équipes de supervision et aux data engineers, en leur permettant d'anticiper les anomalies et de garantir la qualité des flux entrants. Il s'appuie sur un modèle relationnel combinant tables de suivi, de configuration, et des dimensions temporelles. Un second modèle dédié à la traçabilité technique complète le dispositif, permettant de suivre chaque étape du cycle de vie des fichiers (réception, décompression, traitement). Les informations liées à ces opérations sont centralisées dans les tables `trace_fichiers` et `trace_fichiers_dispatch`.




FIGURE 4.2 – Modèle sémantique - Suivi des fichiers 1/2




FIGURE 4.3 – Modèle sémantique - Suivi des fichiers 2/2

Le modèle relationnel présenté dans la figure constitue la base du tableau de bord 01-Files-arrival-monitoring. Il regroupe plusieurs tables provenant de différents traitements liés au suivi, au contrôle et à l'analyse des fichiers reçus.

Le cœur du modèle est constitué de la table `file_tracking`, enrichie par les métadonnées de configuration de `param_file_monitoring`. Des tables complémentaires comme `Invalid Files`, `Anomalous_Files` ou `unexpected_files` permettent d'identifier les anomalies ou écarts.

La table de dates `Calendar` est utilisée comme dimension temporelle commune, facilitant l'analyse des évolutions dans le temps. Le modèle inclut aussi des tables techniques comme `Last7Days` ou `FilteredReceptionDates` pour la gestion dynamique des plages temporelles.

Enfin, un second modèle est dédié à la traçabilité technique du cycle de vie des fichiers. Chaque jour, les fichiers sont d'abord reçus sous forme d'archives compressées (ZIP), puis une tâche automatique se charge de les décompresser avant de les placer dans les volumes correspondants pour traitement. Les tables `trace_fichiers` et `trace_fichiers_dispatch` permettent de suivre en détail ces opérations, en enregistrant les dates de réception, de début et de fin de traitement,

les chemins de copie, ainsi que des indicateurs de qualité tels que la corruption, le nombre de lignes extraites ou encore la taille finale des fichiers. Parmi les mesures principales utilisés dans ce dashboard, on retrouve :

- Total Arrived Files : nombre total de fichiers reçus sur une période donnée.
- Expected Files : nombre de fichiers attendus selon la configuration.
- Clean Files : fichiers reçus à temps, valides et non corrompus.
- Corrupted Files : fichiers identifiés comme endommagés ou contenant des erreurs.
- Invalid Schema Files : fichiers dont le nombre de colonnes diffère de celui attendu.
- Late Files / On time Files : indicateurs de ponctualité basés sur la date de réception par rapport à la date attendue.
- Missing Files : fichiers attendus mais non encore reçus.
- Pending Files : fichiers reçus mais non encore traités (ou avec traitement en cours).
- Failed Files : fichiers ayant échoué lors du traitement.
- Unexpected Files : fichiers non attendus dans la configuration.

4.2 Suivi global des rejets

4.2.1 Notebook Databricks

Ce notebook est conçu pour effectuer un suivi global des rejets en analysant les tables de quarantaine générées lors de l'ingestion des données. Il applique un ensemble de règles de validation afin d'identifier et de comptabiliser les lignes non conformes.

Le processus commence par l'initialisation des structures nécessaires au traitement, suivie de l'identification des tables de quarantaine à partir d'un mapping de colonnes. Pour chaque table identifiée, le notebook vérifie si elle contient des données récentes. Il s'assure également de la présence de la colonne technique `TECH_DT_CHARGEMENT`, indispensable pour déterminer les données à analyser depuis la dernière exécution.

Une fois les données filtrées, le notebook applique les règles de validation, en particulier :

- la détection de lignes contenant des clés primaires ou étrangères nulles (`PK_or_FK_isnull`),
- l'identification de formats invalides par rapport aux types attendus (`invalid_format`).

Les erreurs détectées sont ensuite agrégées sous forme de statistiques par table et par type d'erreur. Ces résultats sont enregistrés dans une table de synthèse dédiée. Ce processus permet une supervision efficace de la qualité des données et facilite l'identification des sources fréquentes de rejet.

4.2.2 Modélisation des données

Les résultats du processus d'analyse des rejets sont consolidés dans une table de synthèse nommée `quarantine_rows_summary`. Cette table centralise les informations issues de chaque exécution du notebook, permettant ainsi de suivre l'évolution des anomalies détectées au fil du temps.

Chaque ligne de cette table correspond à l'analyse d'une table de quarantaine donnée, à un instant donné. Elle inclut des statistiques globales comme le nombre total de lignes rejetées, ainsi que des détails sur les types d'erreurs identifiés (clés nulles ou formats invalides). De plus, des horodatages techniques permettent de tracer la date de traitement et d'éventuelles modifications ultérieures.

Colonne	Description
quarantine_table_name	Nom de la table de quarantaine analysée
total_rejected_rows	Nombre total de lignes rejetées
pk_fk_isnull	Indicateur de présence d'erreurs de clés nulles
invalid_format	Indicateur de présence d'erreurs de format
pk_fk_isnull_count	Nombre de lignes avec erreurs de clés nulles
invalid_format_count	Nombre de lignes avec erreurs de format
TECH_DT_CHARGEMENT_QUARANTINE	Date du dernier chargement analysé
CREATION_TIMESTAMP	Horodatage de création de l'entrée
MODIFICATION_TIMESTAMP	Horodatage de dernière modification

TABLE 4.3 – Description des colonnes de la table de synthèse

4.2.3 Architecture de la modélisation

L'architecture technique de cette modélisation repose sur une exécution périodique du notebook, orchestrée dans Databricks, qui analyse les données récentes des tables de quarantaine, applique les règles de validation, et alimente la table de synthèse. Cette table sert ensuite de source fiable pour les visualisations dans les tableaux de bord Power BI.




FIGURE 4.4 – Diagramme d'Activité du Notebook - Gestion des rejets de fichiers

Ce diagramme représente le flux de traitement des fichiers rejetés dans un pipeline de données. Le processus commence par la lecture du volume de données STD, suivi de l'extraction d'informations comme le nom de fichier et le schéma cible (table silver). Après typage et jointure avec la table de mapping, une table combinée est générée. Pour chaque table de quarantaine, les données sont filtrées par date, et la cause du rejet est identifiée. Deux types d'erreurs sont gérés : les erreurs de correspondance de données (data mismatch) et les clés primaires nulles. Les erreurs sont ensuite enregistrées pour analyse.

4.2.4 Dashboard Power BI

Le tableau de bord a été conçu pour fournir une vision claire et synthétique des rejets survenus lors du traitement des fichiers. Il permet d'identifier rapidement les anomalies, de suivre leur évolution dans le temps, et d'agir en conséquence. Ce tableau de bord est principalement alimenté par la table de production et constitue un outil essentiel pour les équipes opérationnelles et qualité, leur permettant de réagir de manière proactive afin d'optimiser les performances du processus.

La première page du tableau de bord, nommée *Rejection Metrics – Daily Snapshot*, présente un aperçu global des rejets observés au cours de la journée sélectionnée. Une barre de navigation permet d'accéder facilement aux autres volets du rapport, tandis qu'un filtre temporel offre la possibilité de sélectionner une date précise. Des cartes visuelles résument rapidement le statut des rejets détectés. En bas de la page, un tableau récapitule les fichiers traités au cours des sept derniers jours, facilitant ainsi l'analyse des évolutions sur une période courte.

Une deuxième page, *Quality Control – File Rejections*, propose une lecture plus détaillée des fichiers rejetés, avec un classement basé sur la qualité des rejets et leur degré d'urgence. Cette approche permet de prioriser les actions à mener en fonction du niveau de criticité, orientant les efforts des équipes vers les cas les plus sensibles.

Enfin, la page *Rejection Monitoring – Threshold & Type Analysis* constitue un espace interactif permettant une exploration ciblée des données. Grâce à une série de filtres dynamiques et de représentations statistiques, l'utilisateur peut affiner son analyse selon plusieurs critères. Un tableau synthétique regroupe les informations selon les filtres actifs, offrant une base solide pour la prise de décision.




FIGURE 4.5 – Modèle sémantique - Suivi des rejets

Le modèle de données du rapport repose sur une architecture structurée autour de quatre tables principales, interconnectées par des relations adaptées aux cas d'usage d'analyse de la qualité des fichiers.

Les calculs DAX implémentés dans le tableau de bord se répartissent entre tables calculées, colonnes calculées et mesures.

— Jours : génère une série de jours relatifs (J-0 à J-7) pour l'analyse sur une période glissante.

- NewTable : extrait uniquement les colonnes file_name et date de chargement pour le suivi journalier.
- Table_Dates_Job T4 : crée un calendrier entre la première date de rejet et aujourd’hui, avec un libellé formaté.
- Afficher1 : identifie si une ligne appartient aux 15 derniers jours pour filtrage conditionnel.
- rejection_type : catégorise la cause du rejet selon les erreurs détectées.
- Alerte_Rejets : affiche un message selon la présence ou non de rejets aujourd’hui.
- Alerte_Rejets_Nuit_Precedente : indique si des rejets ont eu lieu la veille.
- Dernière Date : retourne la date actuelle, utilisée comme référence dans d’autres mesures.
- Files_Number : calcule le nombre de fichiers uniques rejetés.
- Rejection Ratee : calcule le taux de rejet basé sur les lignes rejetées et le volume total en bronze.
- Rows_Number : totalise le nombre de lignes rejetées.
- TotalRows_Number : totalise les lignes traitées en bronze.
- ScoreQualité : convertit le taux de rejet en une alerte visuelle selon des seuils définis.

4.3 Suivi des jobs databricks

4.3.1 Notebook Databricks

Pour assurer un suivi rigoureux de l’exécution des jobs dans l’environnement Databricks, un notebook spécifique a été mis en place. Celui-ci s’exécute en fin de chaque pipeline de traitement et a pour rôle d’extraire et centraliser les informations de monitoring. À chaque passage, il collecte automatiquement des métadonnées techniques telles que les identifiants d’exécution (jobRunId, taskRunId), les statuts, les timestamps de démarrage et de fin, ainsi que les volumes de données traitées à chaque étape (bronze, silver, gold). Ces données sont ensuite stockées de manière structurée dans une table dédiée, garantissant une traçabilité complète des traitements. Ce mécanisme permet également de différencier la tâche de monitoring de la tâche métier réelle, en isolant clairement les entités techniques dans un processus distinct.

4.3.2 Modélisation des données

La modélisation repose principalement sur deux tables Delta. La première enregistre les informations issues des exécutions, incluant le nom technique de la tâche, le statut, la durée du traitement et les volumes manipulés. Cette table permet une lecture fine de la performance opérationnelle des jobs. Cependant, afin de contextualiser ces données d’un point de vue fonctionnel, une seconde table vient enrichir le modèle. Elle assure la correspondance entre les noms techniques des tâches et les entités métier auxquelles elles se rattachent, en précisant le domaine concerné, le nom global du job, ainsi que son identifiant unique. Grâce à cette modélisation, les données de suivi peuvent être exploitées dans les rapports Power BI avec une double lecture : à la fois technique et fonctionnelle. L’ensemble forme une base robuste pour le tableau de bord *MasterData Monitoring – Jobs*, facilitant l’identification rapide des anomalies d’exécution et le pilotage quotidien des traitements.

Colonne	Type / Description
taskName	string, nom technique de la tâche de monitoring
status	string, statut d'exécution du job
jobRunId	string, identifiant de l'exécution du job
taskRunId	string, identifiant de la tâche
jobStartTime	timestamp, début du job
jobEndTime	timestamp, fin du job
executionTime	string, durée d'exécution
bronzeCount	long, volume des données en bronze
silverCount	long, volume des données en silver
goldCount	long, volume des données en gold

TABLE 4.4 – Description des colonnes de la table des jobs

Remarque : la colonne **taskName** fait référence à la tâche de monitoring elle-même, et non à la tâche métier réelle exécutée. Cette différenciation est importante, car elle implique la mise en correspondance avec une table de mapping complémentaire.

Colonne	Description
taskName	nom technique de la tâche de monitoring
job	nom fonctionnel de la tâche métier
domain	domaine fonctionnel (ex. masterdata, transactions, etc.)
Job_Global	nom global du job
job_id	identifiant unique du job

TABLE 4.5 – Description des colonnes de la table de mapping

Cette table est essentielle pour enrichir les données de monitoring par des attributs fonctionnels, via une jointure sur **taskName**.

4.3.3 Architecture de la modélisation

Afin d'assurer une supervision efficace des différents processus d'intégration de données au sein de la plateforme Databricks, une architecture de monitoring robuste et centralisée a été mise en place. Celle-ci vise à garantir une visibilité complète sur l'exécution des pipelines de traitement, en couvrant aussi bien les flux liés aux données de référence que ceux concernant les transactions opérationnelles. Grâce à cette structure, il devient possible de détecter rapidement les anomalies, de mesurer la complétude des étapes de traitement. Ce dispositif contribue à renforcer la fiabilité globale du système de données et facilite la prise de décision pour les équipes techniques et métiers.




FIGURE 4.6 – Diagramme d’Activité du Notebook - Suivi des jobs databricks

Ce diagramme représente le flux de surveillance des jobs Databricks, divisé en trois grandes sections : les données de référence (Master Data), les transactions (Transactions), et la génération d’une table de correspondance (Mapping Table).

- Dans les sections "Master Data" et "Transactions", les jobs sont exécutés, monitorés, puis enregistrés dans des tables de suivi respectives.
- Ensuite, les informations des deux tables de monitoring sont lues, et les noms des tâches sont extraits.
- Ces tâches sont enrichies par une jointure avec un catalogue d’observabilité pour relier chaque nom de tâche à des métadonnées (job, domaine, ID...).
- Enfin, une table de correspondance est générée et stockée dans Databricks pour un suivi centralisé.

4.3.4 Dashboard Power BI

Le tableau de bord dédié au suivi des jobs Databricks se compose de trois pages principales offrant des niveaux d’analyse complémentaires.

La première page, *Main*, présente une vue d’ensemble de l’activité des jobs. L’utilisateur peut filtrer les données par date, statut, domaine ou état d’activation. Des cartes affichent les indicateurs clés tels que le nombre total de jobs exécutés, le nombre de tâches, la durée moyenne d’exécution, ainsi que les volumes maximums traités (bronze, silver, gold). Un graphique circulaire permet de visualiser la répartition des jobs par statut, tandis qu’une carte dédiée indique la date de dernière exécution.

La seconde page, *Details*, permet d'examiner en profondeur les exécutions individuelles. Elle reprend les mêmes filtres que la page précédente, avec en plus un segment interactif pour affiner l'analyse par statut. Un tableau centralise les principales informations par job : identifiants, durée, domaine, tâche, statut, date d'exécution, alertes associées, et volumes traités par couche.

Enfin, la page *Daily* fournit une vision journalière agrégée des traitements. Les utilisateurs peuvent y observer l'évolution des volumes traités (bronze, silver, gold) par domaine, ainsi que les écarts par rapport à la veille. Cette représentation facilite la détection rapide d'anomalies ou de variations inhabituelles dans les flux quotidiens.




FIGURE 4.7 – Modèle sémantique - Suivi des jobs databricks

Le modèle de données du dashboard MasterData Monitoring – Jobs repose sur une architecture semi-dénormalisée, construite autour de tables techniques et de tables de mapping fonctionnel. Il vise à fournir une vision consolidée des exécutions de traitements métiers (*jobs*) ainsi qu'un suivi détaillé de leur statut, durée et volumétrie.

Les tables implémentées se répartissent comme suit :

Tables principales

- **TableFusion** : Table centrale résultant de la fusion des sources `masterdata_monitoring` et `job_task_mapping`. Elle regroupe les métadonnées liées aux jobs (`job_id`, `taskName`, `domain`, `status`, `executionTime`, `isActive`, etc.) et constitue la base de la majorité des visualisations du rapport.
- **Jobs_Summary** : Table technique contenant des informations agrégées sur les exécutions des jobs, notamment les identifiants d'exécution (`jobRunId`), les dates de lancement (`Job_Start_Date`) ainsi que des indicateurs de durée et d'alertes.
- **Tables_Dates_Job** : Table de dates servant à alimenter les segments temporels du rapport via un formatage lisible (`JobDate_Label`).

Relations

Le modèle repose sur les relations suivantes :

- Une relation de type *many-to-one* entre [`Job_Start_Date`] et [`Date`], permettant l'analyse temporelle des exécutions par le biais de segments date.
- Une relation de type *many-to-many* entre [`jobRunId`] et [`jobRunId`], assurant l'alignement des informations de mapping avec les exécutions effectives. Cette relation permet de croiser les données d'exécution consolidées avec les métadonnées fonctionnelles des jobs.

Ce schéma relationnel permet ainsi d'établir des correspondances précises entre chaque exécution.

4.4 Suivi des transactions

4.4.1 Notebook Databricks

Le notebook mis en place pour ce suivi repose sur l'exploitation directe de tables techniques disponibles dans l'environnement Databricks, plus précisément au sein du catalogue. Ces tables sont alimentées automatiquement par les différentes étapes du pipeline de traitement de données et permettent de suivre l'exécution, la complétude et la cohérence des traitements à chaque niveau.

Quatre tables principales sont interrogées par le notebook : `t1plus_monitoring` pour la réception initiale des fichiers en zone Bronze, `t2_monitoring` pour les traitements intermédiaires, `t3_monitoring` pour la transformation vers la zone Silver, et `t4_monitoring` pour la validation finale en zone Gold. Ces tables fournissent des indicateurs essentiels tels que les volumes attendus et traités, les timestamps de passage d'une zone à une autre, ainsi que le statut global de chaque étape.

Le notebook interroge ces tables, récupère les métriques pertinentes, et les structure de manière à faciliter leur exploitation dans Power BI. Aucune transformation complexe n'est appliquée côté Databricks, la logique métier étant directement intégrée dans la modélisation Power BI. Cette approche garantit un accès rapide, fiable et actualisé aux données de monitoring, tout en assurant une séparation claire entre traitement technique et visualisation.

4.4.2 Dashboard Power BI

Le tableau de bord **Transactions Monitoring** a été conçu pour assurer un suivi opérationnel précis et continu des fichiers de transactions transitant par une chaîne de traitement multi-niveaux composée des zones *Bronze*, *Silver* et *Gold*. Chaque fichier représente un lot de données collectées à partir de différentes sources (applications métiers, flux batch, extractions planifiées, etc.) et suit un processus structuré d'intégration, de transformation et de validation orchestré sur la plateforme Databricks.

Ce dashboard centralise les principaux indicateurs techniques et fonctionnels permettant de valider la complétude et la cohérence du traitement de chaque fichier à chaque étape du pipeline. Il s'appuie sur des tables de monitoring spécifiques à chaque niveau de traitement et offre une visualisation claire de l'état d'avancement et de la qualité des données traitées.

Parmi ses fonctionnalités principales, le tableau de bord permet de :

- Vérifier la bonne réception des fichiers attendus en fonction de la date et du pays concerné, afin de détecter les éventuels retards ou absences ;
- Suivre l'évolution du traitement des fichiers en comparant les volumes attendus avec les volumes effectivement traités dans les différentes zones (*Bronze*, *Silver*, *Gold*) ;
- Identifier rapidement les écarts ou anomalies de traitement à travers un système de statuts visuels (**OK** / **KO**) facilitant la lecture et l'analyse ;
- Filtrer les résultats selon des dimensions clés telles que le code pays, le type de traitement ou le numéro de fichier, pour affiner l'analyse et faciliter le diagnostic.

Ce tableau de bord constitue un outil stratégique pour les équipes techniques et fonctionnelles impliquées dans le traitement des données. Il permet de détecter rapidement les incidents, d'assurer la qualité des données en amont des usages analytiques, et de garantir la fiabilité globale du flux de données quotidien. En fournissant une visibilité consolidée sur l'ensemble du pipeline, il contribue à l'industrialisation des processus de supervision et au renforcement du contrôle qualité des traitements batch.




FIGURE 4.8 – Modèle sémantique - Suivi des transactions

Le modèle sémantique repose sur des relations entre les tables de faits (issues du monitoring des niveaux T1+, T2, T3, T4) et des tables de dimensions (calendriers personnalisés et légende de statut). Ces relations permettent de garantir la cohérence des filtres appliqués dans Power BI ainsi qu'une navigation fluide entre les visuels.

Les mesures et colonnes calculées DAX utilisées dans le tableau de bord *Transactions Monitoring* permettent de transformer les données issues des tables de monitoring (T1+, T2, T3, T4) en indicateurs visuels exploitables.

- Légende Statut : table manuelle associant des emojis aux statuts des fichiers, pour une visualisation synthétique .
- Tables de dates : générées dynamiquement à partir des dates présentes dans chaque table de monitoring, enrichies d'un libellé Job_Date_Label.
- Colonnes calculées (T1+) :
 - Extraction du code pays (2 lettres) et du numéro de fichier depuis le nom.
 - Conversion en entier pour les traitements numériques.
 - Représentation visuelle du statut sous forme d'emoji selon la valeur du champ **status**.
- Mesures principales (T1+) :
 - **expect_count_sum_T1** : somme des lignes attendues.
 - **file count** : nombre de fichiers traités.
 - **Nombre de lignes** : nombre de lignes valides.
 - **Nombre_Erreurs_T1+** : fichiers avec un statut différent de "OK".
 - **Nombre_OK_T1+** : fichiers avec un statut "OK".
 - **Taux de succès (%)** : pourcentage de traitements réussis.
- Modèle répliqué : ces calculs sont reproduits de manière homogène pour les tables T2, T3 et T4, en adaptant simplement les noms de colonnes.

4.4.3 Relations entre tables

Les relations entre les tables de monitoring et les dimensions du modèle sont construites selon le même schéma logique pour les quatre niveaux (T1+ à T4) :

- T1+ Monitoring :
 - Relation de statut avec `Légende Statut[Emoji]` via `Statut_T1`.
- T2 Monitoring :
 - Relation temporelle avec `Table_Dates_Job_T2[Date]`.
 - Relation de statut via `Statut_T2`.
- T3 Monitoring :
 - Relation temporelle avec `Table_Dates_Job_T3[Date]`.
 - Relation de statut via `Statut_T3`.
- T4 Monitoring :
 - Relation temporelle avec `Table_Dates_Job_T4[Date]`.
 - Relation de statut via `Statut_T4`.

Les relations temporelles permettent de filtrer dynamiquement les données par date, tandis que les relations de statut facilitent l’affichage visuel avec des emojis et la classification des traitements en « OK » ou « KO ».

4.5 Conclusion

Ce chapitre a présenté l’architecture de monitoring mise en place dans Databricks et son intégration dans Power BI pour le suivi des traitements de fichiers. Grâce à l’utilisation de notebooks, de tables techniques et de dashboards interactifs, le dispositif permet de détecter rapidement les anomalies, de valider la complétude des traitements, et d’assurer une supervision fiable des pipelines de données. Cette approche renforce la qualité des flux et facilite le pilotage quotidien par les équipes techniques.

Chapitre 5

RÉALISATION ET VALIDATION DE LA SOLUTION

Ce chapitre décrit la mise en œuvre pratique de la solution, en détaillant les outils utilisés et les contributions spécifiques. Il présente également les résultats obtenus et la validation de la solution développée.

5.1 Outils utilisés

5.1.1 Environnement de développement

5.1.1.1 Databricks

Databricks est une plateforme unifiée d'ingénierie de données basée sur Apache Spark, Databricks permet de développer des notebooks de traitement, d'automatiser le monitoring des fichiers et de produire des tables de suivi. Elle offre un environnement collaboratif et scalable pour orchestrer les différentes étapes du pipeline de données.



FIGURE 5.1 – Logo de Databricks[9]

5.1.1.2 Amazon S3 (AWS)

Amazon Simple Storage Service (S3) est un service de stockage objet hautement scalable proposé par AWS. Il a été utilisé pour stocker les fichiers à différents niveaux (Bronze, Silver, Gold), facilitant ainsi la traçabilité, le contrôle qualité et la gestion du cycle de vie des données.



FIGURE 5.2 – Logo Amazon Simple Storage Service[2]

5.1.1.3 Power BI

Power BI est un outil de visualisation interactif permettant de créer des tableaux de bord connectés aux sources de données. Il offre des rapports dynamiques pour le suivi des indicateurs clés, l'analyse métier et la détection rapide des anomalies.



FIGURE 5.3 – Logo Power BI[17]

5.1.2 Langages

5.1.2.1 Structured Query Language

SQL (Structured Query Language) est utilisé pour interroger, transformer et manipuler les données stockées dans les tables de suivi. Il a servi à appliquer des agrégations, des jointures, des filtres et à extraire les informations pertinentes pour le reporting et l'analyse.



FIGURE 5.4 – Logo SQL

5.1.2.2 PySpark

PySpark est l'API Python de Apache Spark. Elle a été utilisée pour écrire des traitements distribués et scalables dans les notebooks Databricks. PySpark permet de traiter efficacement de grands volumes de données et d'appliquer des règles de contrôle qualité, de validation et de classification.



FIGURE 5.5 – Logo Pyspark[18]

5.1.2.3 Data Analysis Expressions

DAX est un langage utilisé dans Power BI pour créer des mesures, colonnes calculées et tables personnalisées. Il permet de produire des calculs dynamiques comme les taux de rejet, les scores qualité ou encore les alertes conditionnelles.



FIGURE 5.6 – Logo DAX[17]

5.2 Résultats

5.2.1 Tables générées sur Databricks

5.2.1.1 Suivi de l'arrivée des fichiers

La table `file_tracking` est l'une des tables centrales de la solution de monitoring. Elle regroupe les métadonnées essentielles de chaque fichier traité quotidiennement dans le pipeline, quel que soit son domaine ou son type. Chaque ligne correspond à un fichier, avec son nom, sa date de réception, son statut d'arrivée (OK, KO, manquant), et les volumes attendus ou réellement traités.

A_1 file_name_with_date	A_2 arrival_status	E_1 schema_validated	E_2 is_corrupted	E_3 is_empty	V_1 actual_line_count	V_2 line_count_check	V_3 size_check	A_3 reception_date	P_1 processing_start_date	P_2 processing_end_date	A_4 comment	A_5 actual_delimiter	A_6 delimiter_check	A_7
1	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
2	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
3	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
4	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
5	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
6	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
7	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
8	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
9	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
10	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
11	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
12	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
13	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
14	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
15	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
16	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
17	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
18	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
19	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
20	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
21	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
22	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
23	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
24	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
25	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
26	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
27	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
28	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
29	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
30	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
31	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
32	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
33	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
34	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
35	pending	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)
36	received	(null)	(null)	(null)	(null)	(null)	(null)	2025-05-02	(null)	(null)	(null)	(null)	(null)	(null)

FIGURE 5.7 – Extrait de la table `file_tracking` sur Databricks


Cette table est utilisée comme source principale pour les tableaux de bord liés à l'arrivée des fichiers (*Files Arrival Monitoring*) et joue un rôle clé dans la détection précoce des anomalies de réception.

5.2.1.2 Suivi des fichiers rejetés

La table `quarantine_monitoring` regroupe les lignes de données ayant été mises en quarantaine lors des traitements, suite à des contrôles de qualité ou de conformité. Elle permet d'identifier précisément quelles données ont été rejetées, pour quel fichier, à quelle date, et pour quelle raison.

5.2.1.4 Suivi des transactions

La table `t1plus_monitoring` contient les données de suivi des fichiers au niveau du traitement T1+. Elle permet de contrôler le bon déroulement des opérations en comparant les volumes attendus avec les volumes réellement chargés à chaque étape (*Bronze*, *Silver*, *Gold*), et en associant un statut de validation à chaque fichier.



transaction_id	transaction_type	file_name	volume_size	expected_count	bronze_count	silver_count	gold_count	status	file_location	TECH_DT_CHANGE
1	T1	Transaction_T1Plus0001	3333	3333	3333	3333	3333	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
2	T1	Transaction_T1Plus0002	5750	5750	5750	5750	5750	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
3	T1	Transaction_T1Plus0003	1000179	1000179	1000179	1000179	1000179	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
4	T1	Transaction_T1Plus0004	620108	620108	620108	620108	620108	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
5	T1	Transaction_T1Plus0005	620170	620170	620170	620170	620170	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
6	T1	Transaction_T1Plus0006	3755	3755	3755	3755	3755	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
7	T1	Transaction_T1Plus0007	41519	41519	41519	41519	41519	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
8	T1	Transaction_T1Plus0008	89	89	89	89	89	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
9	T1	Transaction_T1Plus0009	105	105	105	105	105	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
10	T1	Transaction_T1Plus0010	36003	36003	36003	36003	36003	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
11	T1	Transaction_T1Plus0011	3264	3264	3264	3264	3264	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
12	T1	Transaction_T1Plus0012	80733	80733	80733	80733	80733	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
13	T1	Transaction_T1Plus0013	9114	9114	9114	9114	9114	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
14	T1	Transaction_T1Plus0014	191621	191621	191621	191621	191621	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
15	T1	Transaction_T1Plus0015	22337	22337	22337	22337	22337	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
16	T1	Transaction_T1Plus0016	161036	161036	161036	161036	161036	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
17	T1	Transaction_T1Plus0017	39625	39625	39625	39625	39625	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
18	T1	Transaction_T1Plus0018	845020	845020	845020	845020	845020	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
19	T1	Transaction_T1Plus0019	449	449	449	449	449	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
20	T1	Transaction_T1Plus0020	72763	72763	72763	72763	72763	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
21	T1	Transaction_T1Plus0021	248152	248152	248152	248152	248152	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
22	T1	Transaction_T1Plus0022	11	11	11	11	11	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
23	T1	Transaction_T1Plus0023	95348	95348	95348	95348	95348	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
24	T1	Transaction_T1Plus0024	10302	10302	10302	10302	10302	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
25	T1	Transaction_T1Plus0025	12217	12217	12217	12217	12217	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
26	T1	Transaction_T1Plus0026	3890	3890	3890	3890	3890	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
27	T1	Transaction_T1Plus0027	174	174	174	174	174	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
28	T1	Transaction_T1Plus0028	7201	7201	7201	7201	7201	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
29	T1	Transaction_T1Plus0029	71	71	71	71	71	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
30	T1	Transaction_T1Plus0030	68	68	68	68	68	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
31	T1	Transaction_T1Plus0031	13423	13423	13423	13423	13423	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
32	T1	Transaction_T1Plus0032	2869	2869	2869	2869	2869	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
33	T1	Transaction_T1Plus0033	55538	55538	55538	55538	55538	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
34	T1	Transaction_T1Plus0034	0	0	0	0	0	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
35	T1	Transaction_T1Plus0035	5403	5403	5403	5403	5403	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
36	T1	Transaction_T1Plus0036	17091	17091	17091	17091	17091	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00
37	T1	Transaction_T1Plus0037	82	82	82	82	82	OK	2023-05-15 10:32:47	2023-04-18T15:19:57+00:00

FIGURE 5.10 – Extrait de la table `t1plus_monitoring` sur Databricks

Cette table constitue une source principale pour les visualisations du dashboard « Transactions Monitoring », en fournissant des indicateurs sur la complétude et la conformité des traitements quotidiens par fichier. Elle est essentielle pour détecter rapidement les anomalies ou retards dans la chaîne de traitement.

5.2.2 Dashboards Power BI

Les données traitées et stockées dans Databricks ont été exploitées dans Power BI afin de créer des tableaux de bord interactifs facilitant l'analyse, le suivi et la prise de décision. Grâce à sa connectivité native avec l'environnement Databricks, Power BI permet une actualisation fluide des rapports et une exploration dynamique des métriques clés. Les tableaux de bord construits offrent une vue synthétique et opérationnelle sur plusieurs volets du projet.

5.2.2.1 Dashboard 01 - Suivi de l'arrivée des fichiers

Le tableau de bord Power BI consacré au suivi des fichiers rejetés est divisé en plusieurs pages, chacune ciblant un aspect spécifique du contrôle qualité. Cette organisation thématique permet d'analyser les rejets selon différents critères comme le type d'erreur, la répartition temporelle ou le domaine fonctionnel. Les visualisations sont interactives et filtrables, ce qui facilite l'identification des anomalies critiques. L'utilisateur peut rapidement cibler une date, un fichier ou un environnement particulier afin de comprendre les causes des erreurs.

Ce tableau de bord joue un rôle clé dans la supervision opérationnelle. Il permet de détecter les principales causes de rejet, telles que les clés primaires nulles ou les formats de données incorrects, tout en évaluant leur fréquence et leur impact. Les indicateurs disponibles aident les équipes à suivre les taux de rejet, repérer les pics inhabituels et déclencher des actions correctives plus rapidement, contribuant ainsi à fiabiliser l'ensemble des flux de données.




FIGURE 5.11 – Vue d'ensemble des arrivées de fichiers

La première page du tableau de bord présente une vue d'ensemble sur l'état d'arrivée des fichiers dans les volumes cibles. Des cartes synthétisent les principaux indicateurs : nombre total de fichiers reçus, reçus à temps, en retard, attendus, corrompus ou manquants.

- Total Arrived Files
- On Time Files
- Late Files
- Pending Files
- Corrupted Files
- Missing Files

Une table complémentaire affiche les métadonnées (statut, date et heure de réception) pour chaque fichier. L'analyse peut être affinée via deux filtres : un sélecteur de domaine (ex. **masterData**, **Transactions**) et un filtre temporel. Cette page permet une surveillance rapide et efficace dès la phase d'ingestion.

Page 2 – Suivi global de l'arrivée et de la décompression des fichiers MasterData




FIGURE 5.12 – Vue d'ensemble de la décompression des fichiers MasterData

Cette page propose une vue d'ensemble sur l'arrivée des fichiers compressés ainsi que leur décompression quotidienne dans les volumes correspondants. Elle permet de vérifier que chaque fichier attendu est bien extrait et transféré dans le bon répertoire.

Un **slicer de dates** permet de sélectionner un jour spécifique. Pour chaque jour sélectionné, un **button slicer** affiche dynamiquement la liste des fichiers **.zip** arrivés. Une **table de détail** présente les fichiers extraits depuis chaque archive, en indiquant leur taille (en Mo), le nombre de lignes, et la date de leur copie dans les volumes.

Des **cartes KPI** synthétisent :

- La taille du fichier **.gz** sélectionné.
- Le nombre total de fichiers qu'il contient.

Enfin, un **graphique de type area chart** permet de visualiser l'évolution de la taille des fichiers **.gz** sur les 30 derniers jours, facilitant ainsi l'identification d'éventuelles anomalies ou pics inhabituels dans les volumes de données.

Page 3 – Contrôle de conformité des fichiers




FIGURE 5.13 – Suivi des fichiers inattendus et à schéma invalide

Cette page est dédiée au contrôle qualité des fichiers reçus, en mettant en évidence les anomalies liées à la conformité attendue des fichiers, notamment les fichiers inattendus et ceux qui ne respectent pas le schéma défini.

Un **slicer de dates** et un **button slicer par domaine** (ex. masterData, Transactions) permettent de filtrer dynamiquement les indicateurs et les tableaux selon les besoins d'analyse.

Les **indicateurs clés** suivants sont affichés sous forme de cartes :

- Total arrived files : Nombre total de fichiers reçus pour la période sélectionnée.
- Unexpected files : Fichiers non attendus selon la configuration.
- Invalid schema files : Fichiers reçus avec une structure de colonnes non conforme.
- Clean files : Fichiers conformes, sans anomalies détectées.

Deux tables de détail complètent cette vue :

- La première liste les **fichiers inattendus**, en précisant le type d'anomalie détectée, la date de réception et le chemin du fichier.
- La seconde décrit les **fichiers à schéma invalide**, avec le nombre de colonnes observé, le nombre attendu, la date de réception, et le chemin du fichier.

The screenshot shows a web interface titled "CGI Last 7-days History". It has four navigation buttons: "Home", "Files", "Anomalous", and "7 days". Below is a table with columns for "File name" and days "J-0" through "J-7". Each cell contains a green checkmark (indicating successful arrival) or a red 'X' (indicating a failure or absence). The table lists 13 different file names, all of which show a consistent pattern of success or failure across the 7-day period.

File name	J-0	J-1	J-2	J-3	J-4	J-5	J-6	J-7
FP_DWH_ACQUEREUR	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_AVIS_PAIEMENT_R	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_BIN_EMETTEUR	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_C_COMPOSANT_RISTOURNE	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_C_ECHEANCIER	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_C_ELEMENT_PRODUIT_SERVICE	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_C_ELT_PROD_SRVC_PARAM_SOUSCRIT	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_C_PCOM_DETENU_CCP	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_C_RELATION_PRODUIT_SERVICE	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_C_SCOM_SOUSCRIT	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_C_STRUCT_RISTOU_RESO_ACCEPTEUR	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_C_STRUCTURE_RISTOURNE	✗	✓	✓	✓	✓	✓	✗	✗
FP_DWH_C_STRUCTURE_TARIFAIRE	✗	✓	✓	✓	✓	✓	✗	✗

FIGURE 5.14 – Suivi journalier des fichiers sur 7 jours

Cette page permet un suivi granulaire de l’arrivée des fichiers sur une période glissante des **7 derniers jours**, y compris le jour en cours (J-0). Elle offre une vue transversale permettant de détecter rapidement les retards ou absences de fichiers.

L’utilisateur peut sélectionner un fichier spécifique à travers un **slicer dynamique**, afin d’analyser son comportement quotidien. Pour chaque jour, le tableau indique si le fichier a bien été reçu, ou s’il est manquant.

Cette visualisation s’avère particulièrement utile pour :

- détecter les fichiers à comportement instable ou intermittent ;
- identifier les absences récurrentes sur certains jours ;
- renforcer le pilotage opérationnel à court terme.

5.2.2.2 Dashboard 02 - Suivi des fichiers rejetés

Ce tableau de bord est spécifiquement conçu pour le suivi opérationnel des fichiers rejetés durant les différentes phases du pipeline d’intégration de données. Il centralise les informations issues des traitements de mise en quarantaine et fournit une visibilité complète sur la qualité des données chargées.

Parmi les éléments mis en évidence figurent :

- les types d’erreurs ayant provoqué un rejet (par exemple : clé primaire absente, données mal formatées, types incompatibles, etc.) ;
- les volumes de lignes rejetées par fichier, date ou domaine fonctionnel ;
- la distribution des rejets selon la source d’alimentation (applications, systèmes amont) ;
- les taux de rejet globaux et spécifiques, calculés en fonction du nombre total de lignes traitées.

Grâce à des visualisations dynamiques — telles que des cartes, graphiques en barres empilées, matrices temporelles ou jauges de seuil critique — ce dashboard permet une lecture rapide des anomalies, avec la possibilité de filtrer par fichier, date, nature du rejet ou environnement technique.

Page 1 – Métriques de rejets




FIGURE 5.15 – Métriques de rejets

Cette page offre une vue synthétique sur les rejets de fichiers, permettant d'identifier rapidement les anomalies et de suivre leur répartition par type de fichier et dans le temps. Elle intègre des indicateurs clés tels que le taux de rejet, le nombre de fichiers concernés, le volume de lignes rejetées et l'état global du jour.

Les principaux composants sont :

- Un **sélecteur de date** pour filtrer les résultats par jour.
- Un **filtre par fichier** pour cibler l'analyse.
- Des **cartes de synthèse** indiquant le taux de rejet, le nombre de fichiers, et les lignes rejetées.
- Un **graphique à barres** visualisant le taux de rejet par fichier.
- Une **matrice de suivi journalier**, affichant les rejets sur les 7 derniers jours par fichier.

Page 2 – Contrôle de qualité




FIGURE 5.16 – Contrôle de qualité

Cette page permet d’analyser plus en profondeur la qualité des fichiers traités, en mettant en avant leur taux de rejet ainsi qu’un score qualité calculé pour chaque fichier. Elle permet aussi d’examiner l’évolution des rejets dans le temps et de prioriser les actions à mener selon l’urgence.

Cette page regroupe plusieurs éléments interactifs facilitant l’analyse des rejets :

- Filtres principaux :
 - **file_name** : permet de cibler un fichier spécifique.
 - Historique 15 jours : filtre optionnel pour restreindre l’analyse à la période récente.
- Tableau Qualité par fichier :
 - Colonnes : **file_name**, **Rejection_Ratee**, **ScoreQualité**.
 - Objectif : identifier les fichiers avec un fort taux de rejet.
- Tableau journalier des rejets :
 - Colonnes : date de traitement, nom du fichier, lignes rejetées, urgence.
 - Objectif : fournir un suivi détaillé jour par jour.
- Graphique de zone empilée :
 - Affiche l’évolution des lignes rejetées dans le temps.

Page 3 – Suivi des rejets




FIGURE 5.17 – Suivi des rejets

Cette page permet d’explorer les lignes rejetées à travers plusieurs dimensions et d’appliquer des filtres avancés pour mieux comprendre la nature et la répartition des rejets. Elle combine des visualisations synthétiques (jauge, graphique en anneau) avec un tableau de détails, facilitant à la fois l’analyse rapide et le diagnostic précis. Cette page propose plusieurs éléments pour analyser la nature et la gravité des rejets :

- Filtres principaux :
 - **Job_Date_Label** : permet de filtrer par date ou “Today”.
 - **file_name**, **silver**, **quarantaine** : affinent l’analyse selon le fichier, la table d’origine ou la catégorie de rejet.
- Jauge de rejet critique :
 - Mesure : **Total_rejected_rows**.

- Objectif : comparer le volume total rejeté à un seuil critique.
- Graphique en anneau :
 - Affiche la répartition des rejets selon le type (`rejection_type`).
- Tableau détaillé :
 - Colonnes : `file_name`, `quarantaine`, `rejection_type`, `Total_rejected_rows`.
 - Objectif : fournir une lecture précise des lignes rejetées par origine et cause.

5.2.2.3 Dashboard 03 - Suivi des jobs databricks

Le dashboard MasterData Monitoring – Jobs a pour objectif principal de fournir une visibilité claire et consolidée sur l'exécution des différents traitements de données (jobs) dans le cadre de la gestion des Master Data. Il permet aux équipes opérationnelles et techniques de suivre en temps réel la performance, la fréquence et la fiabilité des jobs critiques. Ce dashboard est alimenté par les données issues des tables centrales datahubmsp_masterdata_monitoring et job_task_mapping, enrichies par d'autres sources telle que Jobs_Summary, permettant des calculs de durée, de statut, et de volumes traités par job.

Page 1 – Page Principal




FIGURE 5.18 – Page principal

Cette page fournit une vue d'ensemble des exécutions de jobs. Elle permet de suivre rapidement le volume de jobs traités, leur statut, ainsi que leur durée moyenne. Elle offre des filtres interactifs pour faciliter la navigation et l'analyse par domaine, statut ou période. Elle permet de suivre l'exécution des jobs Databricks à travers différents indicateurs et filtres :

- Filtrage par date : via `JobDate_Label` (table `Table_Dates_Job`) pour ajuster dynamiquement l'analyse.
- Cartes de synthèse :
 - Nombre de jobs (`job_id`)
 - Nombre de tâches (`taskName`)
 - Durée moyenne des jobs (`Avg_Job_Duration_Label`)
- Filtres déroulants :
 - `status`, `isActive`, `domain`
- Graphique en secteurs : répartition des jobs selon leur statut.

Page 2 – Détails




FIGURE 5.19 – Page des détails

La page des détails offre une vue détaillée et filtrable des exécutions de jobs. Elle permet d'analyser les traitements ligne par ligne en croisant des informations techniques (durée, exécution, statuts) et métier (domaines, tâches, alertes). Cette page permet une analyse détaillée des exécutions de jobs via plusieurs filtres et indicateurs :

- Segment de date : filtre temporel basé sur JobDate_Label (Table_Dates_Job).
- Carte – Dernière Exécution : indique la date de la dernière exécution de job (Last Execution).
- Tableau de suivi :
 - Colonnes : Job, jobRunID, Job_Duration_Label, status, domain, isActive, etc.

Page 3 – Suivi quotidien




FIGURE 5.20 – Page de suivi quotidien

La page de suivi quotidien propose une visualisation synthétique de l'évolution journalière des volumes de traitements par type (*bronze*, *silver*, *gold*), permettant de détecter rapidement

toute variation inhabituelle ou rupture de tendance dans les jobs exécutés. Elle est destinée au suivi quotidien des flux et à la détection proactive d'anomalies.

Cette page permet de suivre l'évolution quotidienne des volumes de traitement par statut et domaine :

- Segment de date : basé sur JobDate_Label (Table_Dates_Job) pour filtrer les données par jour.
- Filtres :
 - Boutons de statut (**status**)
 - Menus déroulants sur job et domain (TableFusion)
- Carte – Dernière exécution : affiche la dernière date de job exécuté.
- Tableau de volumes :
 - Colonnes : domain, bronzeCount, silverCount, goldCount
 - Écarts quotidiens : Daily_Bronze_Diff, Daily_Silver_Diff, Daily_Gold_Diff
 - Objectif : détecter les variations journalières de volumes.

5.2.2.4 Dashboard 04 - Suivi des transactions

Le tableau de bord Transactions Monitoring est structuré en **quatre pages**, conçues de manière homogène pour garantir une navigation cohérente et intuitive. Chaque page se concentre sur un périmètre spécifique (environnement, domaine fonctionnel, type de fichier), tout en s'appuyant sur une même logique de visualisation :

- Un **en-tête** intégrant les filtres principaux (date, statut, dernière réception) ;
- Un **tableau central** affichant les fichiers, leurs volumes par niveau (*Bronze, Silver, Gold*) et leur statut ;
- Une **section de synthèse** avec les totaux par statut (T_OK, T_KO, Total) ;
- Des **filtres complémentaires** (code pays, numéro de fichier) ;
- Un **tableau d'assistance au filtrage**.

Cette uniformité facilite la lecture, accélère l'analyse et renforce l'efficacité du suivi opérationnel sur l'ensemble des flux traités.

Page – Aperçu du tableau de bord




FIGURE 5.21 – Aperçu du tableau de bord

Cette page offre une vue complète sur l'état de traitement des fichiers T1+. Elle s'articule autour d'un segment de date (`Job_Date_label`), d'une carte indiquant la dernière exécution, et d'un tableau principal listant les fichiers, leurs volumes par niveau (`bronze`, `silver`, `gold`), ainsi que leur statut.

Des filtres supplémentaires (codes pays et numéro de fichier) permettent d'affiner l'analyse. Trois cartes de synthèse indiquent le nombre total de fichiers, les traitements réussis (OK) et les erreurs. Un tableau d'assistance au filtrage facilite la navigation parmi les fichiers.

Remarque : Les pages `T2 Overview`, `T3 Overview` et `T4 Overview` suivent exactement la même structure, en s'appuyant sur leurs propres tables de suivi.

5.3 Mise en production et exploitation de la solution

À l'issue des phases de conception, de développement et de validation, la solution a été déployée en environnement de production. Les dashboards Power BI sont désormais connectés en direct aux tables générées via Databricks, assurant une actualisation régulière et automatique des données.

L'équipe métier utilise quotidiennement ces tableaux de bord pour assurer un suivi opérationnel des traitements, détecter les anomalies et anticiper d'éventuels dysfonctionnements. L'ergonomie, la structuration cohérente des pages et les indicateurs clés présentés ont permis une prise en main rapide par les utilisateurs.

Une phase de maintenance continue est assurée afin de :

- ajuster les filtres ou les visuels selon les retours utilisateurs ;
- intégrer de nouvelles sources ou règles de gestion si nécessaire ;
- surveiller la qualité des données et la performance des traitements.

Cette démarche garantit la pérennité de la solution et son adaptation aux évolutions des besoins métiers.

5.4 Conclusion

Ce chapitre a détaillé les différentes étapes de mise en œuvre de la solution de monitoring, depuis le choix des technologies jusqu'à l'exploitation des résultats. Grâce à l'utilisation de Databricks pour le traitement et la génération des tables, combinée à Power BI pour la visualisation, une architecture robuste et dynamique a été établie. Les tableaux de bord livrés permettent aujourd'hui un suivi opérationnel précis des fichiers, des rejets et des jobs, tout en facilitant la détection proactive des anomalies. L'adoption de ces outils par les équipes métiers valide leur utilité et leur intégration dans les processus quotidiens. La solution reste évolutive, avec une maintenance continue assurant son adaptation aux nouveaux besoins et à l'évolution des flux de données.

Conclusion et Perspectives

Ce projet de fin d'études, réalisé au sein de CGI Rabat, a porté sur la conception et le développement d'un système automatisé de suivi et de gestion des fichiers, déployé sur le Cloud AWS et s'appuyant sur l'écosystème Databricks pour les traitements de données, ainsi que Power BI pour la visualisation analytique. Face à l'augmentation du volume des fichiers échangés quotidiennement entre systèmes métiers, et aux enjeux croissants liés à la qualité, à la fiabilité et à la traçabilité des données, cette solution a répondu à un besoin concret et prioritaire pour les équipes opérationnelles.

La solution conçue offre une couverture complète du cycle de vie des fichiers, depuis leur arrivée jusqu'à leur validation ou leur mise en quarantaine. Elle permet non seulement de détecter les anomalies en temps réel, mais également d'en comprendre les causes via des tableaux de bord clairs, interactifs et orientés métier. Le découpage de la solution en plusieurs notebooks de traitement et tableaux de bord spécifiques a permis d'adresser les différents types de fichiers traités dans l'environnement de production, tout en maintenant une cohérence fonctionnelle autour d'un objectif central : le monitoring des flux.

Sur le plan technique, ce projet a été l'occasion de mobiliser plusieurs compétences en ingénierie des données, notamment la manipulation de gros volumes via PySpark, l'utilisation de structures de stockage cloud distribuées, et l'exploitation d'outils de data visualisation avancée. L'ensemble des développements a été mené dans un cadre agile, avec des livraisons itératives, une communication continue avec l'équipe métier, et une mise en production progressive des composants construits.

Enfin, ce projet nous a permis de prendre conscience de l'importance stratégique de la donnée dans la prise de décision, et du rôle clé que jouent les ingénieurs data dans la conception de solutions robustes, évolutives et orientées utilisateur. En assurant la supervision des traitements critiques, en facilitant l'accès à des indicateurs fiables et en accompagnant les équipes dans leur quotidien opérationnel, la solution développée s'inscrit pleinement dans une logique de modernisation, de qualité et d'autonomie data-driven pour l'entreprise.

Plusieurs perspectives d'évolution peuvent être envisagées pour enrichir et étendre la solution développée. L'intégration de systèmes d'alerte en temps réel permettrait d'accélérer la prise en charge des incidents critiques. Par ailleurs, une généralisation du système à d'autres périmètres fonctionnels ou à l'ensemble des flux d'entreprise contribuerait à une surveillance plus globale. Enfin, l'adoption de techniques d'intelligence artificielle, comme la détection automatique de comportements anormaux ou la recommandation d'actions correctives, ouvrirait la voie à un monitoring prédictif, plus intelligent et proactif.

Webographie et Bibliographie

- [1] AWS - Amazon Web Services. <https://aws.amazon.com/fr/>.
- [2] AWS S3 - Amazon Web Services. <https://aws.amazon.com/s3/>.
- [3] Azure Cloud. <https://azure.microsoft.com/en-us/>.
- [4] CGI Au maroc. <https://www.cgi.com/maroc/fr-fr>.
- [5] CGI Company Profile on CRM Consulting. <https://crm.consulting/company/cgi/>.
- [6] Cloud Computing. <https://www.atlassian.com/microservices/cloud-computing>.
- [7] Cloud Deployment Model. <https://www.atlassian.com/microservices/cloud-computing>.
- [8] Data Engineering. <https://k21academy.com/microsoft-azure/dp-203/data-engineering/>.
- [9] Databricks. <https://www.databricks.com/>.
- [10] Documentation Microsoft Teams. <https://learn.microsoft.com/fr-fr/microsoftteams/>.
- [11] Documentation officielle de Databricks. <https://docs.databricks.com/>.
- [12] GCP - Google Cloud Platform Cloud. <https://cloud.google.com/>.
- [13] La méthode Agile. <https://www.usemotion.com/blog/agile-methodology>.
- [14] L'Architecture Medallion. <https://premishnoi.medium.com/databricks-the-medallion-architecture-a1ea27311feb>.
- [15] Le processus SCRUM. <https://www.pm-partners.com.au/insights/the-agile-journey-a-scrum-overview/>.
- [16] Les modèles de Services du Cloud. <https://www.redhat.com/en/topics/cloud-computing/public-cloud-vs-private-cloud-and-hybrid-cloud>.
- [17] Power BI - Microsoft. <https://powerbi.microsoft.com/fr-fr/>.
- [18] Pyspark on Databricks. <https://docs.databricks.com/aws/en/pyspark/>.

[19] Site officiel de CGI. <https://www.cgi.com/fr>.

[20] Spark - Apache Software Foundation. <https://spark.apache.org/>.