



المدرسة الوطنية للعلوم التطبيقية - آسفي
ⵜⴰⵎⴰⵔⵜ ⵜⴰⵏⵔⴰⵢⵜ ⵜⴰⵖⴰⵏⵏⵜ ⵜⴰⵙⴰⵍⴰⵏⵜ - ⵓⵙⴼⵉ
Ecole Nationale des Sciences Appliquées - SAFI
National School of Applied Sciences - SAFI

PARTENAIRES DU PROJET



Organisme d'accueil



Mission client

UNIVERSITÉ CADI AYYAD
ÉCOLE NATIONALE DES SCIENCES APPLIQUÉES DE SAFI

Filière : Ingénierie des Données et Intelligence Artificielle

Mémoire de Projet de Fin d'Études

Pour l'obtention du diplôme d'Ingénieur d'État en Informatique

Conception et Déploiement d'une Cloud Data Platform *Architecture Lakehouse sur AWS EKS*

Rédigé et soutenu par :
Mohammed Dahiry

Sous la direction de :

Pr. EZZAHAR Jamal

Encadrant académique – ENSA Safi

M. EL GHALLAOUI Zine Labidine

Encadrant professionnel – SEVENAPP

Membres du Jury :

Pr. EZZAHAR Jamal

Pr. MADIAFI Mohammed

Pr. HARZALLA Driss

Pr. BENDAIDA Fatiha

Stage effectué chez **SEVENAPP** – Mission client : **EQDOM**
Période : Mars 2026 au Juillet 2026 • Soutenance : 26 Juin 2026

ANNÉE UNIVERSITAIRE 2025–2026

Dédicace

Dédicace

À mes très chers parents.

À ma mère, qui a œuvré pour ma réussite par son amour, son soutien, tous les sacrifices consentis et ses précieux conseils. Pour toute son assistance et sa présence dans ma vie, qu'elle reçoive à travers ce travail, aussi modeste soit-il, l'expression de mes sentiments les plus sincères et de mon éternelle gratitude.

À mon père, qui peut être fier et trouver ici le résultat de longues années de sacrifices et de privations pour m'aider à avancer dans la vie. Puisse Dieu faire en sorte que ce travail porte ses fruits. Merci pour les valeurs nobles, l'éducation et le soutien permanent que tu m'as apportés.

À mes frères, Salim et Anass, je dédie ce travail avec tous mes vœux de bonheur, de santé et de réussite. Vous m'avez soutenu depuis le début, et je vous en remercie pleinement.

À mes grands-pères, mes grands-mères, mes tantes et mon oncle, je ne vous remercierai jamais assez pour l'aide, le soutien et les prières que vous m'avez apportés.

À mes collègues de la promotion 2025/2026 du cycle d'ingénieur à l'ENSA.

À tous mes amis, pour votre soutien, votre présence et vos précieux encouragements.

Au Pr. EZZAHAR Jamal, mon encadrant académique, ainsi qu'à tous mes enseignants, je vous remercie d'avoir partagé avec moi votre passion pour l'enseignement. J'ai grandement apprécié votre soutien, votre implication et votre expérience tout au long de mon cursus.

À toute personne qui a cru en moi.

Je dédie ce travail.

Mohammed Dahiry

Remerciements

Remerciements

Je tiens tout d'abord à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce Projet de Fin d'Études.

Je remercie sincèrement mon encadrant académique, **Pr. EZZAHAR Jamal**, pour son suivi, sa disponibilité, ses orientations méthodologiques et ses précieux conseils tout au long de ce travail.

J'adresse également mes remerciements les plus sincères à **M. EL GHALLAOUI Zine Labidine** ainsi qu'à l'équipe **SEVENAPP**, pour leur accueil, leur accompagnement et la confiance accordée durant cette mission en tant que consultant Data auprès de **EQDOM**.

Je remercie les interlocuteurs chez **EQDOM** pour le contexte métier partagé, les échanges enrichissants et les éclairages apportés sur les enjeux data du secteur financier.

Que le corps professoral, le staff administratif et le secrétariat du département informatique de l'**ENSAS** trouvent ici mes vifs remerciements pour tout le travail effectué durant mes années de formation d'ingénieur d'État.

Que les membres du jury trouvent ici l'expression de ma reconnaissance pour avoir accepté d'évaluer mon travail.

Enfin, que tous ceux qui ont contribué à l'accomplissement de ce travail trouvent ici l'expression de mes remerciements les plus sincères.

Mohammed Dahiry

Résumé

Ce rapport présente la conception et la mise en place progressive d'une **Cloud Data Platform** moderne, réalisée dans le cadre d'un stage chez **SEVENAPP** en mission de **consultant Data** chez **EQDOM**. Le projet répond à un besoin de centralisation, de fiabilisation et d'exploitation industrielle des données afin de soutenir les usages analytiques, décisionnels et futurs cas d'usage data-driven de l'entreprise.

La solution proposée repose sur une infrastructure cloud établie autour d'une architecture **Lakehouse** déployée sur **AWS EKS**. Cette infrastructure permet d'héberger les services nécessaires à l'ingestion, au stockage, au traitement, à la transformation et à l'exposition des données dans un environnement scalable, sécurisé et exploitable. Elle constitue un socle technique unifié pour remplacer les échanges dispersés par une chaîne de traitement gouvernée, traçable et orientée production.

Les sources de données prises en charge couvrent principalement les bases opérationnelles de l'écosystème métier, notamment la **base Informix CBS**, la **base ONE** et la **base SmartStream**, ainsi que des fichiers métiers de formats variés tels que **CSV**, **XLSX**, **XLS** et autres fichiers structurés. Ces données sont intégrées à travers le pipeline data défini dans les spécifications fonctionnelles et techniques du projet. Elles transitent progressivement par les différentes zones du **Data Lake**, selon une logique de structuration et de qualité adaptée aux besoins BI.

Le pipeline cible permet d'alimenter le Data Lake, de préparer les données pour les **jobs BI**, puis de les transformer et les modéliser à l'aide de **dbt** et **Apache Spark**. Les traitements visent à produire des jeux de données fiables, historisés, documentés et prêts à l'analyse. Une attention particulière est portée à la protection des informations sensibles : les données confidentielles sont hashées à l'aide d'algorithmes avancés afin de préserver leur confidentialité et d'éviter toute exposition non maîtrisée.

Le projet intègre également une dimension d'exploitation indispensable à une plateforme data professionnelle. Les volets **monitoring**, **logging** et **dashboarding** permettent de suivre l'état de santé de l'infrastructure, d'observer l'exécution des pipelines, de centraliser les journaux applicatifs et de fournir des tableaux de bord facilitant le pilotage opérationnel. Ainsi, la plateforme ne se limite pas au stockage des données : elle propose un environnement complet pour industrialiser les flux, sécuriser les traitements et soutenir les besoins analytiques d'EQDOM.

Mots-clés : Cloud Data Platform, Lakehouse, Data Lake, AWS EKS, pipeline data, Informix CBS, ONE, SmartStream, fichiers métiers, BI, dbt, Apache Spark, monitoring, logging, dashboarding, sécurité des données.

Abstract

This report presents the design and progressive implementation of a modern **Cloud Data Platform**, carried out during an internship at **SEVENAPP** as a **Data Consultant** on assignment at **EQDOM**. The project addresses the need to centralize, secure and industrialize data flows in order to support analytical, decision-making and future data-driven use cases within the organization.

The proposed solution is based on an established cloud infrastructure built around a **Lakehouse** architecture deployed on **AWS EKS**. This infrastructure hosts the services required for data ingestion, storage, processing, transformation and exposure in a scalable, secure and operationally manageable environment. It provides a unified technical foundation that replaces fragmented data exchanges with a governed, traceable and production-oriented processing chain.

The platform targets several business data sources, mainly operational databases from the enterprise ecosystem, including the **Informix CBS database**, the **ONE database** and the **SmartStream database**, as well as business files in various formats such as **CSV**, **XLSX**, **XLS** and other structured files. These data sources are integrated through the data pipeline defined in the project's functional and technical specifications. Data progressively flows through the different zones of the **Data Lake**, following a structured approach aligned with quality, traceability and BI requirements.

The target pipeline feeds the Data Lake, prepares data for **BI jobs**, and enables transformation and modeling using **dbt** and **Apache Spark**. The processing layer is designed to produce reliable, historical, documented and analysis-ready datasets. Particular attention is given to the protection of sensitive information : confidential fields are hashed using advanced algorithms to preserve data confidentiality and prevent uncontrolled exposure.

The project also includes essential operational capabilities required for a professional data platform. The **monitoring**, **logging** and **dashboarding** layers make it possible to supervise infrastructure health, observe pipeline execution, centralize application logs and provide dashboards for operational follow-up. As a result, the platform is not limited to data storage ; it delivers a complete environment for industrializing data flows, securing processing activities and supporting EQDOM's analytical needs.

Keywords : Cloud Data Platform, Lakehouse, Data Lake, AWS EKS, data pipeline, Informix CBS, ONE, SmartStream, business files, BI, dbt, Apache Spark, monitoring, logging, dashboarding, data security.

ملخص

يقدم هذا التقرير تصميم وتنفيذ منصة بيانات سحابية حديثة، تم إنجازها في إطار تدريب لدى شركة SEVENAPP ضمن مهمة استشارية في مجال البيانات لفائدة EQDOM. يهدف المشروع إلى توحيد مصادر البيانات، تحسين موثوقية تدفقاتها، وتوفير أساس منظم يدعم التحليل واتخاذ القرار وحالات الاستعمال المستقبلية المعتمدة على البيانات. تعتمد المنصة المقترحة على بنية تحتية سحابية قائمة على معمارية Lakehouse منشورة فوق AWS EKS. وتوفر هذه البنية بيئة قابلة للتوسع وأمنة لاستيعاب البيانات، تخزينها، معالجتها، تحويلها، ثم إتاحتها للاستعمالات التحليلية والمهنية. كما تشكل هذه المنصة قاعدة تقنية موحدة تسمح بتعويض التبادلات المتفرقة بسلسلة معالجة منظمة، قابلة للتتبع وموجهة نحو الاستغلال الإنتاجي.

تشمل مصادر البيانات المستهدفة قواعد تشغيلية أساسية مثل قاعدة Informix CBS ، قاعدة ONE ، وقاعدة SmartStream ، إضافة إلى ملفات مهنية بصيغ متعددة مثل CSV و XLSX و XLS وغيرها من الملفات الهيكلية. تمر هذه البيانات عبر خط معالجة محدد في المواصفات الوظيفية والتقنية للمشروع، ثم يتم إدخالها تدريجياً إلى مناطق Data

Lake وفق منطق يراعي الجودة، التتبع، ومتطلبات ذكاء الأعمال.

يسمح خط المعالجة المستهدف بتغذية Data Lake ، تحضير البيانات لأعمال BI ، ثم تحويلها ونمذجتها باستعمال dbt و Apache Spark . وتهدف هذه المعالجات إلى إنتاج بيانات موثوقة، مؤرخة، موثقة، وجاهزة للتحليل. كما يتم إيلاء أهمية خاصة لحماية المعطيات الحساسة، حيث يتم تجزئة الحقول السرية باستعمال خوارزميات متقدمة من أجل الحفاظ على سريتها ومنع أي تعرض غير مضبوط لها.

يتضمن المشروع كذلك جوانب تشغيلية أساسية لمنصة بيانات احترافية، من خلال logging و monitoring و dashboarding . وتسمح هذه المكونات بمتابعة صحة البنية التحتية، مراقبة تنفيذ خطوط المعالجة، تجميع السجلات التطبيقية، وتوفير لوحات قيادة تساعد على التتبع التشغيلي. وبذلك لا تقتصر المنصة على تخزين البيانات فقط، بل تقدم بيئة متكاملة لتصنيع تدفقات البيانات، تأمين المعالجات، ودعم الاحتياجات التحليلية لدى EQDOM .

الكلمات المفتاحية - منصة بيانات سحابية، Lakehouse ، Data Lake ، AWS EKS ، خط معالجة البيانات، Informix ، ONE ، SmartStream ، ملفات مهنية، BI ، dbt ، Apache Spark ، monitoring ، logging ، dashboarding ، أمن البيانات.

Table des matières

Dédicace	1
Remerciements	2
Résumé	3
Abstract	4
Résumé en arabe	5
Liste des abréviations	11
Introduction générale	13
1 CONTEXTE GÉNÉRAL DU PROJET	15
1.1 Organisme d'accueil : SEVENAPP	15
1.1.1 Fiche signalétique	16
1.1.2 Domaines d'intervention	16
1.1.3 Références clients	17
1.1.4 Organigramme simplifié	18
1.2 Contexte client : EQDOM	18
1.2.1 Présentation du client	18
1.2.2 Fiche signalétique	19
1.2.3 Aperçu historique	19
1.2.4 Organigramme simplifié	20
1.2.5 Réseau d'agences	20
1.2.6 Enjeux data du contexte financier	21
1.2.7 Motivation de la mission	21
1.3 Cadre du projet	22
1.4 Problématique	22
1.5 Méthodologie de conduite	23
1.6 Planification du projet	24
1.7 Apports attendus	25
Conclusion du chapitre 1	25
2 ÉTAT DE L'ART	26
2.1 Évolution des plateformes de données	27

2.2	Architecture Lakehouse et modèle médaillon	27
2.3	Kubernetes et approche cloud-native	28
2.4	Pattern Operator	29
2.5	Ingestion batch et streaming	30
2.6	Transformation distribuée et orchestration	30
2.7	Virtualisation SQL et Business Intelligence	31
2.8	Infrastructure as Code et CI/CD	31
2.9	Observabilité	32
	Conclusion du chapitre 2	32
3	ANALYSE ET SPÉCIFICATION DES BESOINS	33
3.1	Problématique	33
3.2	Objectifs du projet	33
3.3	Périmètre fonctionnel	34
3.4	Exigences non fonctionnelles	35
3.5	Acteurs et responsabilités	36
3.5.1	Diagrammes de compréhension fonctionnelle et technique	36
3.6	Scénario de référence du pipeline data	41
3.7	Contraintes de réalisation	41
	Conclusion du chapitre 3	42
4	CONCEPTION DE LA SOLUTION	43
4.1	Architecture globale	43
4.2	Déploiement physique sur AWS EKS	43
4.2.1	Landing zone	43
4.2.2	Node groups	44
4.3	Stratégie des namespaces Kubernetes	44
4.4	Conception du pipeline médaillon	44
4.5	Sécurité et gouvernance technique	45
4.6	Observabilité, logging et dashboarding	45
4.7	Organisation technique des livrables	45
	Conclusion du chapitre 4	46
5	RÉALISATION ET MISE EN ŒUVRE	47
5.1	Stack technologique implémentée	47
5.2	État d'avancement par phase	47
5.3	Phase 1 — Landing zone et socle Kubernetes	48
5.4	Phase 2 — Stockage Lakehouse et métastore	49
5.5	Phase 3 — Ingestion, Kafka et CDC	49
5.6	Phase 4 — Spark, dbt et Airflow	49
5.7	Phase 5 — Serving avec Dremio	50
5.8	Phase 6 — Exposition sécurisée Cloudflare	50
5.9	Phase 7 — Monitoring, logging et dashboarding	50
5.10	Automatisation, CI/CD et cycle de vie	50
5.11	Traçabilité avec le cahier des charges	51
5.12	Difficultés rencontrées et mitigations	51

5.13 Plan de finalisation	51
Conclusion du chapitre 5	52
6 CONCLUSION ET PERSPECTIVES	53
6.1 Bilan du projet	53
6.2 Limites	53
6.3 Perspectives	53
6.4 Apports personnels	53
A Architecture Decision Records (synthèse)	55
B Checklist des phases (soutenance)	56
Bibliographie	57

Table des figures

1.1	Logo SEVENAPP	15
1.2	Domaines d'intervention de SEVENAPP	16
1.3	Exemples de références clients de SEVENAPP	17
1.4	Organigramme simplifié de SEVENAPP	18
1.5	Logo EQDOM	18
1.6	Organigramme simplifié d'EQDOM	20
1.7	Carte schématique des villes couvertes par les agences EQDOM	21
1.8	Taxonomie de la problématique data du projet	23
1.9	Démarche agile appliquée au projet	23
1.10	Diagramme de Gantt du projet	24
2.1	Architecture générale de la plateforme Data Lakehouse sur Kubernetes	26
2.2	Évolution des architectures de données vers le Lakehouse	27
2.3	Organisation du Lakehouse selon le modèle médaillon	28
2.4	Architecture infrastructure de la plateforme Data Lakehouse	28
2.5	Rôle de Kubernetes dans l'isolation et l'orchestration des composants	29
2.6	Principe de fonctionnement du pattern Operator	29
2.7	Modes d'ingestion batch et streaming vers la couche Bronze	30
2.8	Pipeline data end-to-end de la plateforme	30
2.9	Chaîne de transformation et d'orchestration des traitements	31
2.10	Exposition SQL et consommation BI des données Gold	31
2.11	Chaîne Infrastructure as Code et CI/CD	32
2.12	Piliers d'observabilité de la plateforme	32
3.1	Diagramme de flux de données de la plateforme	37
3.2	Diagramme d'activités du pipeline data	38
3.3	Diagramme d'infrastructure cloud cible	40
4.1	Architecture logique en couches de la Cloud Data Platform	43
4.2	Flux de données médaillon cible	44

Liste des tableaux

1.1	Fiche signalétique de SEVENAPP	16
1.2	Fiche signalétique d'EQDOM	19
1.3	Répartition des agences EQDOM par ville	20
1.4	Planification synthétique du projet	24
2.1	Comparaison synthétique des architectures data	27
2.2	Operators mobilisés dans le projet	29
3.1	Sources de données retenues dans le périmètre	34
3.2	Exigences fonctionnelles principales	34
3.3	Exigences non fonctionnelles	35
3.4	Acteurs du système	36
3.5	Critères d'acceptation du scénario de référence	41
4.1	Namespaces <code>platform-*</code> alignés avec le cahier des charges	44
4.2	Rôle des couches médaillon	45
4.3	Conception de l'observabilité	45
5.1	Stack technologique principale	47
5.2	Matrice d'avancement et livrables par phase	48
5.3	DAGs Airflow livrés	49
5.4	Réalisation de l'observabilité	50
5.5	Exemples de traçabilité exigence → artefact	51
A.1	Synthèse des ADR	55
B.1	Jalons opérationnels (<code>docs/phases/PHASE_CHECKPOINTS.md</code>)	56
B.2	Preuves recommandées pour la démonstration	56

Liste des abréviations

Sigle	Signification
ADR	Architecture Decision Record
API	Application Programming Interface
AWS	Amazon Web Services
BI	Business Intelligence
CBS	Core Banking System
CDC	Change Data Capture
CI/CD	Intégration / Déploiement continu
CMK	Customer Managed Key (clé KMS)
CNPG	CloudNativePG (opérateur PostgreSQL)
CRD	Custom Resource Definition
CSV	Comma-Separated Values
DAG	Directed Acyclic Graph (Airflow)
DBT	Data Build Tool
Dremio	Plateforme SQL lakehouse pour l'exploration et la consommation des données
EBS	Elastic Block Store
ECR	Elastic Container Registry
EKS	Elastic Kubernetes Service
ELB	Elastic Load Balancer
ESN	Entreprise de Services du Numérique
ETL	Extract, Transform, Load
ELT	Extract, Load, Transform
Grafana	Plateforme de visualisation, de supervision et de dashboarding
HMS	Hive Metastore
IaC	Infrastructure as Code
IAM	Identity and Access Management
Informix CBS	Base CBS hébergée sur IBM Informix
IRSA	IAM Roles for Service Accounts
K8s	Kubernetes
KMS	Key Management Service
KPI	Key Performance Indicator

Sigle	Signification
Lakehouse	Architecture combinant les principes du Data Lake et du Data Warehouse
Fluent Bit	Agent léger de collecte, de filtrage et de transfert des logs
MinIO	Stockage objet compatible avec l'API S3
MVP	Minimum Viable Product
NAT	Network Address Translation
NiFi	Apache NiFi, outil d'ingestion, d'orchestration et de routage des flux de données
OIDC	OpenID Connect
OLTP	Online Transaction Processing
ONE	Source de données opérationnelle intégrée au pipeline data
OpenObserve	Plateforme d'observabilité pour la centralisation, la recherche et l'analyse des logs
PFE	Projet de Fin d'Études
Power BI	Outil de Business Intelligence et de restitution décisionnelle
Prometheus	Système de collecte de métriques et de supervision
PSA	Pod Security Admission
RBAC	Role-Based Access Control
R2	Cloudflare R2 (stockage objet)
S3	Simple Storage Service
SLA	Service Level Agreement
Spark	Apache Spark, moteur distribué de traitement et de transformation des données
SmartStream	Source de données opérationnelle intégrée au pipeline data
SoW	Statement of Work (cahier des charges)
SQL	Structured Query Language
XLS	Format de fichier tableur Microsoft Excel historique
XLSX	Format de fichier tableur Microsoft Excel moderne

Introduction générale

Dans un contexte où la donnée devient un actif stratégique, la capacité à la collecter, la fiabiliser, la transformer et l'exposer de manière gouvernée constitue un enjeu majeur pour les organisations financières.

Les organisations financières exploitent aujourd'hui des volumes de données de plus en plus importants, issus de systèmes transactionnels, d'applications métier, de fichiers opérationnels et d'outils analytiques. Cette richesse informationnelle devient cependant difficile à valoriser lorsque les données restent dispersées dans plusieurs silos, lorsque les traitements sont exécutés par des scripts isolés, ou lorsque l'absence d'observabilité rend les incidents difficiles à diagnostiquer. Dans ce contexte, la mise en place d'une plateforme de données industrialisée constitue un levier stratégique pour fiabiliser la collecte, structurer la transformation et accélérer l'accès aux indicateurs décisionnels.

Le présent Projet de Fin d'Études s'inscrit dans cette problématique. Réalisé dans le cadre d'un stage chez **SEVENAPP**, en mission de consultant Data auprès de **EQDOM**, il porte sur la conception et la mise en œuvre d'une **Cloud Data Platform** moderne, déployée sur **AWS EKS**, fondée sur une architecture **Lakehouse** et structurée selon le modèle **médaille** : Bronze, Silver et Gold.

L'objectif du projet n'est pas seulement d'assembler des outils open source. Il s'agit de construire un socle reproductible, sécurisé et exploitable, capable de couvrir l'ensemble du cycle de vie de la donnée : ingestion batch et streaming, stockage objet, catalogage, transformations distribuées, orchestration, exposition SQL/BI, supervision et automatisation de l'infrastructure. Le projet accorde également une attention particulière aux contraintes opérationnelles : gestion des secrets, isolation Kubernetes, optimisation des coûts, traçabilité des choix d'architecture et capacité à maintenir un environnement fiable et industrialisable.

La solution proposée repose sur un ensemble cohérent de technologies : Terraform pour l'Infrastructure as Code, Cloudflare R2 pour le backend d'état Terraform, Amazon EKS pour l'orchestration Kubernetes, MinIO pour le stockage S3-compatible, Apache Iceberg et Hive Metastore pour la couche Lakehouse, Kafka/Strimzi et Debezium pour la capture de changements, Spark et dbt pour les transformations, Airflow pour l'orchestration, Dremio pour la virtualisation SQL, puis Prometheus, Grafana, Fluent Bit et OpenObserve pour l'observabilité.

Ce rapport présente successivement le contexte professionnel et méthodologique du projet, l'état de l'art des architectures data modernes, l'analyse des besoins, la conception retenue, la réalisation technique de la plateforme, ainsi que les limites et perspectives d'évolution. Les phases encore dépendantes d'un déploiement complet sur compte cloud sont intégrées

comme trajectoire d'industrialisation, afin de fournir une vision complète et défendable de la plateforme cible.

Organisation du mémoire

- le chapitre 1 présente l'organisme d'accueil, le contexte client et la méthodologie de travail ;
- le chapitre 2 introduit les concepts et technologies nécessaires à la compréhension de la solution ;
- le chapitre 3 formalise les besoins fonctionnels et non fonctionnels ;
- le chapitre 4 décrit la conception globale et les choix d'architecture ;
- le chapitre 5 détaille la réalisation technique et l'état d'avancement ;
- le chapitre 6 conclut le travail et propose les perspectives d'amélioration.

1 CONTEXTE GÉNÉRAL DU PROJET

Ce chapitre présente le cadre professionnel du Projet de Fin d'Études, l'organisme d'accueil, le contexte client et la démarche de conduite adoptée. Il permet de situer la contribution technique dans un environnement réel de transformation digitale et de data engineering.

1.1 Organisme d'accueil : SEVENAPP

SEVENAPP, opérant sous la marque **Seven**, est une entreprise de services numériques spécialisée dans l'accompagnement des organisations autour de la transformation digitale, de la data et de l'intelligence artificielle. Son positionnement consiste à intervenir comme partenaire technologique auprès d'acteurs publics et privés, en mettant à disposition des consultants capables de concevoir, industrialiser et documenter des solutions numériques.



FIGURE 1.1 – Logo SEVENAPP

Dans le cadre de ce stage, le rôle occupé est celui de **consultant Data**. La mission s'inscrit dans une logique d'ingénierie : comprendre un besoin de plateforme, proposer une architecture, produire une implémentation reproductible, documenter les choix et préparer une démonstration technique.

1.1.1 Fiche signalétique

TABLE 1.1 – Fiche signalétique de SEVENAPP

Élément	Description
Dénomination	SEVENAPP, opérant sous la marque Seven
Nature	Entreprise de Services du Numérique orientée Digital, Data et Intelligence Artificielle
Date de création	2018
Siège	Casablanca, Maroc
Positionnement	Accompagnement des organisations dans la transformation digitale, l'industrialisation des produits data et l'intégration de solutions innovantes
Domaines d'expertise	Consulting, Digital, Data, Intelligence Artificielle, plateformes banking, Data Lakehouse et IA générative
Effectif public communiqué	Plus de 45 consultants et experts
Rôle dans le projet	Organisme d'accueil du stage et cadre de réalisation de la mission de consultant Data auprès d'EQDOM

1.1.2 Domaines d'intervention

Les activités de l'organisme d'accueil peuvent être regroupées autour de trois axes :

- **transformation digitale** : modernisation des processus, intégration d'applications et accompagnement métier ;
- **data engineering** : pipelines, plateformes, gouvernance, ingestion, transformation et exposition des données ;
- **intelligence artificielle** : exploitation avancée des données, automatisation et cas d'usage analytiques.




FIGURE 1.2 – Domaines d'intervention de SEVENAPP

1.1.3 Références clients

La diversité des références clients de SEVENAPP illustre son positionnement transversal auprès d'acteurs financiers, d'organismes publics et d'entreprises issues de secteurs variés. Ces missions couvrent notamment la refonte de parcours digitaux, la mise en place de solutions CRM, la structuration de dispositifs data, l'automatisation de processus et l'accompagnement à la gouvernance des données.



FIGURE 1.3 – Exemples de références clients de SEVENAPP

1.1.4 Organigramme simplifié




FIGURE 1.4 – Organigramme simplifié de SEVENAPP

1.2 Contexte client : EQDOM

1.2.1 Présentation du client

EQDOM est un acteur marocain du financement et du crédit à la consommation. Son activité repose sur la gestion de parcours clients, de dossiers de financement, de données opérationnelles et d'indicateurs de pilotage. Dans ce type d'environnement, la donnée joue un rôle central : elle alimente l'analyse du risque, le suivi commercial, la conformité, le reporting interne et les tableaux de bord décisionnels.



FIGURE 1.5 – Logo EQDOM

1.2.2 Fiche signalétique

TABLE 1.2 – Fiche signalétique d’EQDOM

Élément	Description
Dénomination sociale	EQDOM
Forme juridique	Société anonyme à Conseil d’Administration
Date de création	Septembre 1974
Siège social	127, Boulevard Zerktouni, Casablanca
Secteur d’activité	Crédit à la consommation et financement automobile
Produits principaux	Prêts personnels, crédit automobile, financement d’équipement et solutions de crédit affecté
Réseau commercial	24 agences réparties dans les principales villes du Royaume, complétées par des intermédiaires agréés et des partenaires distributeurs
Contexte de la mission	Client final de la mission Data portée par SEVENAPP, avec un besoin de modernisation et de fiabilisation des flux de données

1.2.3 Aperçu historique

EQDOM est considérée comme l’une des premières sociétés marocaines spécialisées dans le financement et le crédit à la consommation. Créée en 1974 à l’initiative de la Société Nationale d’Investissement et de la Caisse de Dépôt et de Gestion, elle avait initialement pour vocation de faciliter l’acquisition de biens d’équipement par les ménages marocains et de soutenir le développement du secteur de l’électroménager.

L’entreprise a connu une première étape structurante en 1978 avec son introduction à la Bourse de Casablanca. À partir des années 1990, EQDOM a engagé une dynamique d’élargissement de son activité, marquée par la diversification de ses produits et l’extension progressive de son réseau d’agences. Cette évolution lui a permis de passer d’un positionnement centré sur le financement d’équipement à une offre plus large couvrant les prêts personnels, le crédit automobile et les solutions de financement affecté.

Dans les années 2000, l’entreprise a renforcé son ancrage dans le secteur financier marocain à travers son adossement à un groupe bancaire de référence. Plus récemment, l’évolution du paysage bancaire marocain et les opérations de réorganisation actionnariale ont inscrit EQDOM dans une nouvelle phase de transformation. Dans ce contexte, la donnée devient un levier essentiel pour améliorer le pilotage commercial, fiabiliser le reporting, suivre les risques et accompagner la digitalisation des parcours clients.

1.2.4 Organigramme simplifié




FIGURE 1.6 – Organigramme simplifié d'EQDOM

1.2.5 Réseau d'agences

EQDOM s'appuie sur un réseau de distribution directe afin d'assurer une présence de proximité auprès de ses clients, de ses partenaires automobiles et des organismes conventionnés. La documentation institutionnelle consultée indique un total de **24 agences** réparties dans les principales villes du Royaume.

TABLE 1.3 – Répartition des agences EQDOM par ville

Ville	Agences	Ville	Agences
Casablanca	6	Rabat	3
Marrakech	2	Tanger	2
Settat	1	Fès	1
Salé	1	Oujda	1
Agadir	1	Safi	1
Tétouan	1	Meknès	1
El Jadida	1	Kénitra	1
Béni Mellal	1	Total	24




FIGURE 1.7 – Carte schématique des villes couvertes par les agences EQDOM

1.2.6 Enjeux data du contexte financier

Le contexte financier impose des exigences particulières :

- **fiabilité** : les traitements doivent produire des résultats cohérents et vérifiables ;
- **traçabilité** : les données doivent pouvoir être suivies depuis la source jusqu'à l'indicateur ;
- **sécurité** : les accès aux infrastructures et aux interfaces doivent être contrôlés ;
- **scalabilité** : la plateforme doit pouvoir absorber l'évolution des volumes et des usages ;
- **observabilité** : les erreurs, lenteurs et indisponibilités doivent être détectables rapidement.

1.2.7 Motivation de la mission

La mission consiste à proposer une base technique permettant de centraliser les flux de données et de les organiser sous forme de Lakehouse. Le projet n'a pas vocation à remplacer immédiatement tous les systèmes existants ; il fournit un socle reproductible et extensible sur lequel des cas d'usage métiers peuvent ensuite être branchés progressivement.

Le scénario de démonstration retenu s'appuie sur des données représentatives, notamment des tables clients et des données budgétaires d'agences. Ce choix permet d'illustrer la chaîne complète : ingestion depuis une source PostgreSQL, capture CDC, écriture Bronze, transformations Silver/Gold et exposition SQL.

Le secteur du crédit et du financement exige des systèmes d'information fiables, auditables et capables de produire rapidement des indicateurs opérationnels. Les données doivent être disponibles pour les équipes analytiques tout en respectant des contraintes de sécurité, de

traçabilité et de gouvernance. Cette exigence justifie l'intérêt d'une plateforme de données structurée, automatisée et observable.

1.3 Cadre du projet

Le projet consiste à concevoir et déployer une **Cloud Data Platform** sur AWS EKS, adaptée aux besoins d'un environnement financier manipulant des données opérationnelles, analytiques et décisionnelles. La plateforme vise à couvrir le cycle de vie complet des données : ingestion depuis les systèmes sources, stockage dans un Lakehouse, transformation en couches analytiques, orchestration des traitements, exposition SQL/BI et supervision.

Le cadrage fonctionnel et technique retient une approche progressive : bâtir d'abord un socle cloud sécurisé et reproductible, puis y intégrer les services nécessaires au pipeline data, à la gouvernance, à l'observabilité et à la consommation des données par les équipes BI. Les livrables principaux regroupent ainsi les éléments nécessaires à la mise en place, à l'exploitation et à la démonstration de la plateforme :

- les modules Terraform de la landing zone AWS ;
- les manifests Kubernetes et Helm des différentes phases ;
- les scripts de déploiement, destruction, préparation des secrets et construction d'image ;
- les DAGs Airflow et jobs Spark/dbt ;
- la documentation d'exploitation, de traçabilité et de maintenance.

1.4 Problématique

Dans un contexte financier, les données proviennent de systèmes hétérogènes : bases opérationnelles, applications métiers, fichiers bureautiques et flux applicatifs. Cette diversité complique leur centralisation, leur historisation et leur exploitation analytique. Les équipes métier ont besoin de données fiables, sécurisées et disponibles pour le pilotage, tandis que les équipes techniques doivent garantir la traçabilité des traitements, la reproductibilité des déploiements et la supervision de bout en bout.

La problématique du projet peut donc être formulée ainsi :

Comment concevoir une plateforme data cloud, sécurisée, observable et extensible, capable d'ingérer des sources hétérogènes, de structurer les données dans un Lakehouse et de les exposer aux usages BI et analytiques, tout en assurant la traçabilité, la gouvernance et la maîtrise opérationnelle des traitements ?

Cette problématique se décline en plusieurs axes complémentaires, représentés dans la figure 1.8.




FIGURE 1.8 – Taxonomie de la problématique data du projet

1.5 Méthodologie de conduite

La démarche adoptée suit une approche itérative inspirée de Scrum. Le projet a été découpé en phases techniques cohérentes, chacune produisant un incrément exploitable : socle cloud, stockage, ingestion, compute, serving, exposition, observabilité et automatisation.




FIGURE 1.9 – Démarche agile appliquée au projet

TABLE 1.4 – Planification synthétique du projet

Sprint	Phase	Livrables principaux
Sprint 1	Socle cloud	VPC, EKS, KMS, IAM, backend R2, CI Terraform, namespaces Kubernetes.
Sprint 2	Stockage	MinIO, CloudNativePG, Hive Metastore, secrets, stockage gp3.
Sprint 3	Ingestion	Kafka Strimzi, topics, KafkaConnect, Debezium, NiFi.
Sprint 4	Compute	Image Spark Iceberg, SparkApplication, dbt, Airflow et DAGs.
Sprint 5	Serving / sécurité	Dremio, source Hive, Cloudflare Tunnel et exposition des interfaces.
Sprint 6	Observabilité	Prometheus, Grafana, Fluent Bit, OpenObserve, ServiceMonitors et documentation finale.

1.6 Planification du projet

Diagramme de Gantt du projet

Planification de la Cloud Data Platform – mars à juillet 2026




FIGURE 1.10 – Diagramme de Gantt du projet

1.7 Apports attendus

Le projet apporte une base technique réutilisable pour construire une plateforme data moderne :

- une infrastructure cloud décrite par code et reconstruisible ;
- une architecture Lakehouse compatible avec les standards open source ;
- une organisation par phases qui facilite le déploiement progressif ;
- une documentation permettant d’expliquer les choix techniques et les limites du MVP ;
- une trajectoire claire vers l’industrialisation : GitOps, monitoring avancé, data quality et BI métier.

Conclusion du chapitre

Ce chapitre a situé le projet dans son contexte professionnel et méthodologique. Le chapitre suivant présente les concepts techniques et l’état de l’art nécessaires à la compréhension de l’architecture retenue.

2 ÉTAT DE L'ART

Ce chapitre présente les fondements techniques sur lesquels repose la solution. Il ne s'agit pas d'une simple liste d'outils, mais d'une analyse des concepts qui structurent les plateformes de données modernes : Lakehouse, architecture médaillon, Kubernetes, operators, ingestion temps réel, transformation distribuée, virtualisation SQL et observabilité. L'objectif est de relier chaque concept à son rôle concret dans la plateforme cible.




FIGURE 2.1 – Architecture générale de la plateforme Data Lakehouse sur Kubernetes

La figure 2.1 synthétise l'architecture cible du projet. Les sources de données alimentent une couche d'ingestion composée de NiFi, Debezium et Kafka. Les données sont ensuite stockées dans un Lakehouse fondé sur MinIO, Iceberg et Hive Metastore. Les traitements Spark et dbt produisent les couches analytiques, Airflow orchestre les workflows, Dremio expose les données en SQL et Power BI les consomme côté métier. Les briques d'observabilité, de sécurité, d'Infrastructure as Code et de CI/CD permettent de rendre l'ensemble exploitable, reproductible et gouverné.

2.1 Évolution des plateformes de données

Les premières architectures décisionnelles reposaient principalement sur des entrepôts de données centralisés. Ces solutions offraient de bonnes performances analytiques, mais elles étaient coûteuses, rigides face aux données semi-structurées et difficiles à faire évoluer rapidement. Les data lakes ont ensuite permis de stocker de grands volumes de données brutes à moindre coût, généralement sur stockage objet. En contrepartie, ils ont introduit de nouveaux défis : gouvernance insuffisante, qualité variable, absence de transactions fiables et difficulté à exposer les données aux utilisateurs métiers.

Les architectures **Lakehouse** répondent à cette tension en combinant la flexibilité du data lake avec certaines garanties du data warehouse. Elles s'appuient sur des formats de tables ouverts, comme Apache Iceberg, qui apportent un catalogue, une évolution de schéma, des snapshots, une meilleure isolation des écritures et une exploitation efficace par plusieurs moteurs de calcul. Dans le cadre du projet, ce modèle est pertinent car il permet d'unifier stockage brut, transformation analytique et consommation BI sans multiplier les silos.




FIGURE 2.2 – Évolution des architectures de données vers le Lakehouse

TABLE 2.1 – Comparaison synthétique des architectures data

Critère	Data Warehouse	Data Lake	Lakehouse
Type de données	Structurées	Brutes, variées	Structurées et semi-structurées
Coût de stockage	Élevé	Faible	Faible à modéré
Gouvernance	Forte	Variable	Renforcée par catalogue et formats ouverts
Évolution de schéma	Contrôlée mais rigide	Souple mais risquée	Souple avec métadonnées transactionnelles
Cas d'usage	BI classique	Archivage, exploration	BI, ML, streaming, batch

2.2 Architecture Lakehouse et modèle médaillon

Le modèle **médaille** organise les données selon leur niveau de qualité et de préparation. La couche Bronze conserve les données brutes et historisées, ce qui permet de rejouer les traitements en cas d'erreur. La couche Silver applique les règles de nettoyage, de typage, de déduplication et de standardisation. La couche Gold produit des tables orientées usages métiers : indicateurs, agrégats, référentiels analytiques et jeux de données prêts pour la BI.

Dans ce projet, Apache Iceberg fournit la structure transactionnelle du Lakehouse, tandis que MinIO apporte le stockage objet compatible S3. Hive Metastore joue le rôle de catalogue central afin que Spark, dbt et Dremio partagent la même représentation des tables.

Cette séparation entre stockage, catalogue et moteurs de calcul évite l'enfermement dans un entrepôt propriétaire et facilite l'évolution de la plateforme.




FIGURE 2.3 – Organisation du Lakehouse selon le modèle médaille

2.3 Kubernetes et approche cloud-native

Kubernetes s'est imposé comme standard d'orchestration des applications conteneurisées. Dans une plateforme data, il permet de déployer de manière homogène des composants hétérogènes : bases de données, brokers Kafka, jobs Spark, orchestrateurs, services SQL et outils d'observabilité. Chaque composant est empaqueté sous forme de conteneur, puis exécuté dans un cluster qui gère le placement, le redémarrage, l'exposition réseau et la montée en charge.

L'intérêt de Kubernetes repose sur quatre axes. La **portabilité** permet d'adapter la plateforme à AWS, à un autre cloud ou à un environnement on-premise. L'**isolation** structure les responsabilités grâce aux namespaces, RBAC, quotas et NetworkPolicies. L'**élasticité** permet de dimensionner les traitements selon la charge. L'**automatisation** facilite l'exploitation au moyen d'operators et de manifests déclaratifs.




FIGURE 2.4 – Architecture infrastructure de la plateforme Data Lakehouse

La figure 2.4 détaille la vue infrastructure de la plateforme. Les sources externes et les utilisateurs accèdent à l'environnement au travers d'une couche de sécurité Zero Trust portée par Cloudflare. Le socle cloud AWS regroupe le réseau, le cluster EKS, le stockage persistant, les identités IAM/IRSA, le chiffrement KMS et la gestion des secrets. Les services data sont ensuite déployés dans Kubernetes : ingestion, Kafka, MinIO, Spark, Airflow, dbt, Dremio, Hive Metastore et observabilité. La partie DevOps/DataOps montre que GitHub Actions, Terraform, Ansible et GitOps servent à automatiser le provisionnement, les déploiements et la maintenance. Enfin, la zone EKS met en évidence les namespaces et ressources communes, ce qui illustre la séparation des responsabilités techniques dans le cluster.




FIGURE 2.5 – Rôle de Kubernetes dans l'isolation et l'orchestration des composants

2.4 Pattern Operator

Un **operator** Kubernetes étend l'API du cluster au moyen de Custom Resource Definitions (CRD). Au lieu de déployer manuellement chaque objet technique, l'équipe décrit l'état souhaité dans une ressource déclarative. Le contrôleur de l'operator observe ensuite l'état réel, détecte les écarts et applique les actions nécessaires : création de pods, configuration, sauvegardes, montée de version ou réparation.

Cette logique est particulièrement utile pour les composants stateful et complexes. Déployer Kafka, PostgreSQL, MinIO ou Spark à la main demande de maîtriser de nombreuses règles d'exploitation. Les operators encapsulent cette expertise et rendent les déploiements plus reproductibles. Ils ne remplacent pas la compréhension technique, mais réduisent fortement les opérations répétitives et les risques d'erreur.




FIGURE 2.6 – Principe de fonctionnement du pattern Operator

TABLE 2.2 – Operators mobilisés dans le projet

Operator	Rôle	Couche
CloudNativePG	Déploiement et gestion de clusters PostgreSQL	Source / Metastore
MinIO Operator	Gestion d'un tenant de stockage objet compatible S3	Stockage
Strimzi	Déploiement de Kafka, topics et KafkaConnect	Ingestion
Spark Operator	Soumission de traitements Spark comme ressources Kubernetes	Calcul
Cloudflare Operator	Publication contrôlée des services via tunnels Zero Trust	Sécurité / Exposition

2.5 Ingestion batch et streaming

Une plateforme de données doit couvrir plusieurs modes d'ingestion. Les fichiers CSV/XLSX sont fréquents dans les processus opérationnels et nécessitent une ingestion batch robuste : contrôle du format, validation, routage et enrichissement. Les bases transactionnelles, quant à elles, doivent pouvoir alimenter la plateforme sans exports complets répétés. La **Change Data Capture** répond à ce besoin en capturant les insertions, mises à jour et suppressions directement depuis le journal de transaction.

Le couple **Kafka + Debezium** constitue une solution standard pour ce cas d'usage. Kafka sert de buffer durable et découple la source des consommateurs. Debezium transforme les changements de PostgreSQL ou Informix en événements exploitables. Apache NiFi complète l'ensemble en offrant une interface orientée flux pour les scénarios fichier ou semi-structurés. Les données convergent ensuite vers la couche Bronze, où elles restent rejouables et traçables.




FIGURE 2.7 – Modes d'ingestion batch et streaming vers la couche Bronze

2.6 Transformation distribuée et orchestration

Apache Spark est retenu pour les traitements distribués, notamment l'écriture de tables Iceberg et la consommation de flux Kafka. Sa capacité à paralléliser les traitements permet d'absorber des volumes importants tout en conservant une logique de transformation programmable en SQL ou PySpark. dbt complète Spark en introduisant une approche déclarative des transformations SQL, avec un modèle de projet versionné, testable et compréhensible par les profils data.

Airflow joue le rôle d'orchestrateur. Il permet de planifier les traitements, de suivre leur exécution et de structurer les dépendances entre ingestion Bronze, transformation Silver et production Gold. Dans la solution, les DAGs Airflow soumettent des ressources SparkApplication, ce qui conserve une séparation claire entre orchestration et calcul : Airflow décide quand exécuter, Spark exécute le traitement, dbt formalise une partie des transformations analytiques.




FIGURE 2.8 – Pipeline data end-to-end de la plateforme

La figure 2.8 présente le flux fonctionnel de bout en bout. Les sources de données, qu'elles

soient relationnelles, fichiers ou API, alimentent d'abord la couche d'ingestion. NiFi couvre les flux batch et fichiers, Debezium capture les changements des bases via CDC, puis Kafka sert de tampon durable et découple les producteurs des consommateurs. Les données arrivent ensuite dans le Lakehouse, où MinIO fournit le stockage objet et Iceberg structure les couches Bronze, Silver et Gold. La transformation s'effectue avec Spark pour les traitements distribués et dbt pour la modélisation SQL, les tests et la documentation. Enfin, Dremio expose les tables au travers d'une couche SQL et Power BI les consomme pour les tableaux de bord. Les outils d'observabilité suivent l'ensemble du parcours afin de surveiller les métriques, les logs, les alertes et la traçabilité.



FIGURE 2.9 – Chaîne de transformation et d'orchestration des traitements

2.7 Virtualisation SQL et Business Intelligence

Dremio est utilisé comme couche de virtualisation SQL. Son rôle est de permettre l'interrogation des tables Iceberg sans déplacer les données vers un entrepôt propriétaire. Les analystes peuvent ainsi accéder aux données au moyen d'un moteur SQL, tandis que le stockage principal reste dans le Lakehouse. Cette approche réduit les duplications, simplifie la gouvernance et facilite l'exposition progressive des jeux de données Gold.

La couche BI, représentée par Power BI dans l'architecture cible, consomme les datasets publiés par Dremio. Les rapports peuvent être construits à partir de vues sémantiques, d'agrégats Gold ou de requêtes contrôlées. Le point essentiel est la séparation des responsabilités : le Lakehouse conserve les données, Dremio sert de couche d'accès SQL et Power BI porte la visualisation métier.



FIGURE 2.10 – Exposition SQL et consommation BI des données Gold

2.8 Infrastructure as Code et CI/CD

L'Infrastructure as Code constitue un pilier du projet. Terraform décrit les ressources cloud : réseau, cluster, IAM, clés KMS, ECR et scaling. Le choix d'un backend Cloudflare R2 pour l'état Terraform permet de séparer la gestion de l'état du compte AWS déployé, ce qui réduit le couplage opérationnel. Les manifests Kubernetes, charts Helm et configurations applicatives complètent cette logique déclarative côté cluster.

La CI/CD avec GitHub Actions permet d'exécuter les contrôles, les plans Terraform et les déploiements. L'authentification OIDC évite l'usage de clés AWS statiques longues durées, ce qui constitue une bonne pratique de sécurité. L'ensemble forme une chaîne reproductible : le code décrit l'infrastructure, la pipeline vérifie les changements, puis le déploiement applique les versions validées.




FIGURE 2.11 – Chaîne Infrastructure as Code et CI/CD

2.9 Observabilité

Une plateforme de données n'est exploitable que si elle est observable. Les métriques indiquent l'état technique des composants : CPU, mémoire, disponibilité des pods, performances Kafka, état PostgreSQL ou exécution des jobs Spark. Les logs donnent le détail des événements applicatifs et facilitent l'analyse des incidents. Les dashboards et alertes permettent enfin d'identifier rapidement les défaillances et d'enclencher les actions correctives.

Le projet s'appuie sur Prometheus, Grafana, Fluent Bit et OpenObserve. Prometheus collecte les métriques, Grafana les visualise, Fluent Bit transporte les logs et OpenObserve centralise leur exploration. Cette combinaison couvre à la fois le monitoring technique, la traçabilité des traitements et le suivi opérationnel des services exposés.




FIGURE 2.12 – Piliers d'observabilité de la plateforme

Conclusion du chapitre

L'état de l'art montre que la solution retenue s'inscrit dans les standards actuels du data engineering cloud-native : formats ouverts, orchestration Kubernetes, séparation stockage/calcul, pipelines reproductibles et observabilité intégrée. L'architecture globale présentée dans ce chapitre relie ces principes à une implémentation concrète : ingestion multi-source, stockage Lakehouse, transformation distribuée, exposition BI, sécurité, automatisation et supervision. Ces principes guident l'analyse des besoins présentée au chapitre suivant.

3 ANALYSE ET SPÉCIFICATION DES BESOINS

Ce chapitre formalise la problématique, les objectifs et les exigences de la Cloud Data Platform. L’analyse se base sur le cahier des charges du projet, les guides techniques fournis et l’état réel du dépôt d’implémentation. Elle vise à établir un lien clair entre les besoins exprimés, les choix de conception et les artefacts livrés.

3.1 Problématique

Les systèmes d’information financiers produisent des données à forte valeur, mais souvent réparties dans plusieurs environnements : bases opérationnelles, exports bureautiques et fichiers métier. Dans le périmètre du projet, les sources à prendre en charge sont clairement identifiées : **PostgreSQL pour la base ONE, Informix CBS, SmartStream**, ainsi que des **fichiers métiers CSV, XLS et XLSX**. Cette dispersion entraîne plusieurs difficultés :

- la consolidation des données nécessite des traitements manuels ou semi-automatisés ;
- les transformations ne sont pas toujours versionnées, testées ou rejouables ;
- les données brutes et les données préparées ne sont pas clairement séparées ;
- les incidents de pipeline sont difficiles à diagnostiquer sans centralisation des logs et métriques ;
- le passage d’un prototype à un socle industrialisé demande une infrastructure reproductible.

La problématique peut donc être formulée ainsi :

Comment concevoir et mettre en œuvre une plateforme de données cloud-native, reproductible et sécurisée, capable d’ingérer des données batch et streaming, de les structurer selon une architecture Lakehouse médaillon, puis de les exposer à des usages analytiques tout en assurant supervision, traçabilité et maîtrise des coûts ?

3.2 Objectifs du projet

Le projet poursuit quatre objectifs complémentaires :

1. **Objectif infrastructure** : créer une landing zone AWS/EKS modulaire et automatisée par Terraform.
2. **Objectif data engineering** : mettre en place un pipeline Bronze–Silver–Gold fondé sur MinIO, Iceberg, Spark et dbt.

3. **Objectif opérationnel** : fournir des scripts de déploiement, de destruction, de bootstrap et de validation par phase.
4. **Objectif gouvernance** : documenter les choix d'architecture, les exigences, la sécurité, les limites et les perspectives d'industrialisation.

3.3 Périmètre fonctionnel

Le périmètre fonctionnel de la plateforme couvre deux familles de sources. La première correspond aux bases de données opérationnelles, dont les changements doivent pouvoir être capturés ou ingérés sans imposer d'exports manuels répétés. La seconde correspond aux fichiers métiers, souvent utilisés dans les processus de reporting ou de consolidation ponctuelle.

TABLE 3.1 – Sources de données retenues dans le périmètre

Famille	Source	Rôle dans la plateforme
Base opérationnelle	PostgreSQL – base ONE	Source applicative ingérée vers la couche Bronze, avec possibilité de capture des changements via CDC.
Base opérationnelle	Informix – base Informix CBS	Source applicative à intégrer au Lakehouse pour centraliser les données opérationnelles et analytiques.
Base opérationnelle	SmartStream	Source historique ou métier à connecter à la plateforme selon les besoins d'ingestion.
Fichiers métiers	CSV, XLS, XLSX	Exports métier ou fichiers de consolidation intégrés en batch vers la couche Bronze.

TABLE 3.2: Exigences fonctionnelles principales

ID	Exigence	Priorité
EF-01	Provisionner une infrastructure AWS comprenant VPC, EKS, IAM, KMS, ECR et backend Terraform distant.	Essentielle
EF-02	Créer les namespaces Kubernetes de la plateforme avec isolation réseau, quotas et stockage chiffré.	Essentielle
EF-03	Déployer une couche de stockage Lakehouse basée sur MinIO, Iceberg et Hive Metastore.	Essentielle
EF-04	Prendre en charge les sources bases de données du périmètre : PostgreSQL pour la base ONE, Informix CBS et SmartStream.	Essentielle
EF-05	Capturer ou ingérer les changements des bases sources, notamment PostgreSQL/ONE via Debezium, et publier les événements dans Kafka lorsque le mode CDC est retenu.	Essentielle

ID	Exigence	Priorité
EF-06	Ingérer des fichiers métiers CSV, XLS et XLSX vers la couche Bronze à l'aide de traitements batch.	Importante
EF-07	Transformer les données Bronze en Silver puis Gold avec dbt-spark.	Essentielle
EF-08	Orchestrer les traitements au moyen de DAGs Airflow versionnés.	Essentielle
EF-09	Exposer les tables analytiques via Dremio pour les requêtes SQL et la BI.	Importante
EF-10	Publier les interfaces web par Cloudflare Zero Trust.	Souhaitable
EF-11	Collecter les métriques, logs et dashboards nécessaires à l'exploitation.	Essentielle
EF-12	Préparer une trajectoire GitOps avec ArgoCD.	Optionnelle

3.4 Exigences non fonctionnelles

TABLE 3.3 – Exigences non fonctionnelles

Axe	Exigence
Sécurité	Principe du moindre privilège, IRSA, KMS, secrets hors Git, accès EKS restreint, exposition par tunnel sécurisé.
Reproductibilité	Infrastructure et composants décrits par code : Terraform, Helm, manifests Kubernetes et scripts Bash.
Maintenabilité	Organisation par phases, documentation d'exploitation, séparation entre modules Terraform et manifests applicatifs.
Scalabilité	Node groups spécialisés, capacité de montée en charge du compute et architecture extensible à plusieurs sources.
Coût	Dimensionnement <code>dev</code> , destruction automatisée, NAT unique en MVP et scaling planifié du node group compute.
Observabilité	Supervision des ressources, logs centralisés, dashboards et alertes sur les services critiques.
Traçabilité	Correspondance entre cahier des charges, exigences, décisions d'architecture et fichiers du dépôt.

3.5 Acteurs et responsabilités

TABLE 3.4 – Acteurs du système

Acteur	Responsabilités
Data Engineer	Déploiement de la plateforme, ingestion des sources, développement des jobs Spark/dbt, maintenance des DAGs.
Analyste BI	Exploration des tables Gold via Dremio et création de tableaux de bord métier.
Administrateur Cloud/SRE	Supervision du cluster, gestion des incidents, coûts, accès, logs et métriques.
Encadrant technique	Validation de l'architecture, revue des choix, contrôle de l'alignement avec le cahier des charges.

3.5.1 Diagrammes de compréhension fonctionnelle et technique

Les diagrammes suivants complètent la lecture des responsabilités en montrant comment les acteurs, les sources et les composants techniques interagissent dans la plateforme. Ils servent de transition entre l'analyse des besoins et le scénario de référence du pipeline data.




FIGURE 3.1 – Diagramme de flux de données de la plateforme

Ce flux met en évidence deux chemins d'entrée : les bases opérationnelles et les fichiers métiers. Les flèches pleines représentent le chemin principal de la donnée : capture ou extraction, publication dans Kafka, écriture dans Bronze, transformation vers Silver, publication Gold, puis exposition SQL dans Dremio et Power BI. Les flèches en pointillés représentent les relations de pilotage et de supervision : Airflow orchestre les traitements, tandis que Grafana et les logs suivent l'état des jobs, la qualité et les SLA.




FIGURE 3.2 – Diagramme d'activités du pipeline data

Le diagramme d'activités décrit la logique de traitement attendue. Les relations indiquées sur les flèches précisent le rôle de chaque transition : lancement planifié ou manuel, qualification de la source, lecture du flux ou du fichier, contrôle qualité, publication dans le catalogue et supervision continue. Les retours vers la correction représentent les reprises nécessaires lorsqu'une source ou une transformation n'est pas conforme.




FIGURE 3.3 – Diagramme d'infrastructure cloud cible

La vue infrastructure montre la séparation entre le socle cloud, les services data et l'exploitation. Les relations annotées indiquent le sens des dépendances : Cloudflare sécurise l'accès, AWS fournit le réseau privé, IAM/IRSA/KMS portent les identités et secrets, le stockage fournit les volumes et objets, puis EKS déploie les pods dans les namespaces. Les flux data passent de Kafka vers MinIO/Iceberg, puis vers Spark/dbt et Dremio. Les flèches en pointillés décrivent les relations d'exploitation : Terraform et GitHub Actions provisionnent, tandis que Prometheus, Grafana et les logs supervisent les traitements et services.

3.6 Scénario de référence du pipeline data

Le scénario de référence sert de fil conducteur au projet. Il illustre le fonctionnement attendu d'un pipeline complet :

1. une source du périmètre alimente la plateforme : base PostgreSQL/ONE, Informix CBS, SmartStream ou fichier métier CSV/XLS/XLSX ;
2. pour une source base de données, Debezium ou un connecteur adapté capture les changements et les publie dans un topic Kafka lorsque le mode streaming est utilisé ;
3. pour une source fichier, un traitement batch valide le format et écrit les données dans la couche Bronze ;
4. un job Spark consomme le flux Kafka ou les données batch et écrit une table Iceberg Bronze ;
5. des modèles dbt transforment la donnée en tables Silver puis Gold ;
6. Dremio interroge les tables Gold et les rend disponibles pour la BI ;
7. Prometheus, Grafana, Fluent Bit et OpenObserve permettent de suivre l'exécution.

TABLE 3.5 – Critères d'acceptation du scénario de référence

Composant	Critère de validation
Sources bases / Debezium	Une modification issue de PostgreSQL/ONE, Informix CBS ou SmartStream peut être capturée ou ingérée selon le connecteur retenu.
Fichiers métiers	Un fichier CSV, XLS ou XLSX conforme est validé puis chargé vers la couche Bronze.
Kafka	Le topic attendu existe et contient les messages produits.
Spark / Iceberg	Le job Spark écrit une table Bronze visible dans le catalogue Hive.
dbt	Les modèles Silver et Gold s'exécutent sans erreur et produisent des tables requêtables.
Dremio	Les tables Gold sont accessibles par requête SQL.
Observabilité	Les métriques et logs du pipeline sont consultables dans Grafana et OpenObserve.

3.7 Contraintes de réalisation

Le projet est soumis à plusieurs contraintes :

- **contrainte de coût** : l'environnement cible est un environnement **dev**, dimensionné pour démontrer la solution sans reproduire tous les coûts d'une production ;
- **contrainte de secrets** : les credentials AWS, Cloudflare, R2 et GitHub ne peuvent pas être versionnés ;

- **contrainte de temps** : certaines phases sont livrées sous forme d'artefacts prêts à déployer et nécessitent une validation finale sur cluster ;
- **contrainte de périmètre** : les données réelles EQDOM et certains aspects de production, comme les sauvegardes avancées ou la haute disponibilité complète, sont hors MVP.

Conclusion du chapitre

L'analyse des besoins met en évidence un périmètre clair : construire une plateforme de données cloud-native complète dans sa conception, automatisée dans son déploiement et extensible vers un contexte de production. Le chapitre suivant décrit l'architecture retenue pour répondre à ces exigences.

4 CONCEPTION DE LA SOLUTION

Ce chapitre présente l'architecture cible de la Cloud Data Platform. La conception reprend la logique en sept couches décrite dans les spécifications, puis la projette sur AWS EKS, Kubernetes et les artefacts du dépôt.

4.1 Architecture globale

La plateforme comporte sept couches logiques [1, 2] : sources, ingestion, stockage, calcul, virtualisation, présentation et observabilité. Elle est hébergée sur **AWS EKS** en environnement **dev**, avec un design compatible avec une évolution multi-cloud ou on-premise grâce à Kubernetes, MinIO et Iceberg.




FIGURE 4.1 – Architecture logique en couches de la Cloud Data Platform

4.2 Déploiement physique sur AWS EKS

4.2.1 Landing zone

La landing zone est composée d'un VPC multi-AZ, de sous-réseaux privés et publics, d'un NAT Gateway unique en environnement **dev**, de clés KMS dédiées et d'un cluster EKS managé. Les modules Terraform `vpc`, `kms`, `iam`, `eks`, `ecr` et `lambda-scaling` isolent les responsabilités et permettent une évolution contrôlée.

4.2.2 Node groups

Deux groupes de nœuds séparent les contraintes stateful et compute :

- **stateful-ng** : workloads persistants comme MinIO, PostgreSQL, Hive et Kafka ;
- **compute-ng** : workloads élastiques comme Spark, Airflow, Dremio, observabilité et jobs ponctuels.

Cette séparation rend possible le **scale-to-zero** du compute sans arrêter les services de stockage, ce qui répond à la contrainte d'optimisation des coûts.

4.3 Stratégie des namespaces Kubernetes

TABLE 4.1 – Namespaces **platform-*** alignés avec le cahier des charges

Namespace	Workloads prévus
platform-ingestion	Strimzi Kafka, Kafka Connect, Debezium, NiFi
platform-storage	MinIO Operator, MinIO Tenant, PostgreSQL source
platform-metastore	Hive Metastore, PostgreSQL HMS
platform-compute	Spark Operator, SparkApplication, dbt jobs
platform-orchestr	Airflow, base metadata Airflow
platform-serving	Dremio, services SQL/BI
platform-monitoring	Prometheus, Alertmanager, Grafana
platform-logging	Fluent Bit, OpenObserve
platform-security	cert-manager, Cloudflare Operator, secrets d'exposition

Chaque namespace reçoit une **ResourceQuota**, une **NetworkPolicy** de base et un niveau Pod Security Admission adapté. Cette stratégie limite le blast radius et facilite l'explication de l'architecture au jury.

4.4 Conception du pipeline médaille

Le pipeline est conçu autour d'un flux principal PostgreSQL → Kafka → Iceberg, complété par une ingestion fichiers. La séparation Bronze/Silver/Gold permet d'organiser la qualité et la finalité des données.




FIGURE 4.2 – Flux de données médaille cible

TABLE 4.2 – Rôle des couches médaillon

Couche	Rôle
Bronze	Données brutes, historisées, proches de la source, écrites en Iceberg pour conserver la traçabilité.
Silver	Données nettoyées, typées, dédoublées et prêtes pour les jointures métier.
Gold	Agrégats orientés analyse, indicateurs stabilisés et tables consommables par BI.

4.5 Sécurité et gouvernance technique

La sécurité est intégrée dès la conception :

- **identité** : OIDC GitHub vers AWS et IRSA pour les controllers Kubernetes ;
- **chiffrement** : clés KMS distinctes pour EBS, secrets et logs ;
- **réseau** : API EKS privée par défaut, NetworkPolicies et exposition UI via Cloudflare Tunnel ;
- **secrets** : templates versionnés, valeurs réelles générées localement et exclues de Git ;
- **traçabilité** : ADR et matrice SPEC_ALIGNMENT.md.

4.6 Observabilité, logging et dashboarding

L'observabilité est conçue comme une couche transversale, et non comme un ajout final. Les métriques Kubernetes et applicatives sont collectées par Prometheus ; Grafana fournit les dashboards techniques ; Fluent Bit route les logs vers OpenObserve ; les ServiceMonitors ciblent les composants critiques.

TABLE 4.3 – Conception de l'observabilité

Pilier	Mise en œuvre prévue
Métriques	kube-prometheus-stack, métriques Kubernetes, Spark Operator, MinIO, CNPG, Strimzi, Airflow et Dremio.
Logs	Fluent Bit en DaemonSet, enrichissement Kubernetes, sortie OpenObserve, recherche par namespace/pod/job.
Dashboards	Grafana pour santé cluster, ressources, Kafka, PostgreSQL, Spark, Airflow et stockage ; Power BI pour indicateurs métier Gold.
Alerting	Alertmanager pour alertes techniques : pods crashloop, PVC presque pleins, jobs échoués, connecteurs CDC indisponibles.

4.7 Organisation technique des livrables

Listing 4.1 – Organisation technique des livrables

```
plateforme-data/
  terraform/modules/{vpc,kms,iam,eks,ecr,lambda-scaling}
```

```
terraform/environments/dev/  
bootstrap/phase-2..phase-10/  
docker/spark-iceberg/  
dags/  
scripts/bootstrap-phase*.sh  
docs/specs/, docs/phases/, docs/02-architecture-decision-records.md  
rapport/
```

Conclusion du chapitre

La conception articule une architecture Lakehouse, un socle EKS sécurisé, un pipeline médaillon et une observabilité transverse. Le chapitre suivant détaille l'état d'implémentation réel et les phases prévues pour finaliser la démonstration.

5 RÉALISATION ET MISE EN ŒUVRE

Ce chapitre présente la réalisation technique du projet. Il décrit les artefacts produits, l'organisation du dépôt, l'état d'avancement par phase et les validations nécessaires pour passer du MVP technique à une plateforme pleinement exécutée sur un environnement cloud. L'objectif est de montrer que la solution ne se limite pas à une architecture théorique : elle est matérialisée par des modules Terraform, des manifests Kubernetes, des scripts d'exploitation, des DAGs et des jobs data.

5.1 Stack technologique implémentée

TABLE 5.1 – Stack technologique principale

Domaine	Technologies / artefacts
Cloud	AWS VPC, EKS, EBS, ECR, KMS, Lambda, EventBridge
IaC	Terraform, backend Cloudflare R2, GitHub Actions OIDC
Kubernetes	Namespaces, RBAC, StorageClass gp3, NetworkPolicies, Helm
Stockage	MinIO Operator, MinIO Tenant, Apache Iceberg, Hive Metastore
Ingestion	Strimzi Kafka, KafkaConnect, Debezium, NiFi, Spark file ingestion
Calcul	Spark 3.5, Iceberg runtime, dbt-spark, Spark Operator
Orchestration	Airflow KubernetesExecutor, DAGs versionnés
Serving	Dremio Nautilus, source Hive, intégration Power BI prévue
Sécurité	cert-manager, KMS, IRSA, Cloudflare Tunnel, secrets templates
Observabilité	kube-prometheus-stack, Grafana, Fluent Bit, OpenObserve, ServiceMonitors
Cycle de vie	scripts <code>fasttrack</code> , <code>teardown</code> , phases de bootstrap, ArgoCD optionnel

5.2 État d'avancement par phase

TABLE 5.2: Matrice d'avancement et livrables par phase

Ph.	Périmètre	Artefacts disponibles	Statut
1	Landing zone AWS/EKS	Modules Terraform VPC, KMS, IAM, EKS, ECR; bootstrap namespaces, quotas, storage, réseau.	Implémenté
2	Stockage et métastore	cert-manager, MinIO, CNPG pg-source/pg-hms, Hive Metastore, secrets exemples.	Implémenté
3	Ingestion CDC	Strimzi, Kafka dev/prod, topics, KafkaConnect Debezium, NiFi.	Implémenté
4	Compute et orchestration	Docker Spark Iceberg, SparkApplications, Airflow, DAGs, dbt models.	Implémenté
5	Serving SQL/BI	Dremio Helm values, source Hive JSON, documentation Power BI.	Artefacts prêts
6	Exposition sécurisée	Cloudflare Operator, ClusterTunnel, TunnelBindings Airflow/Dremio/Grafana/NiFi.	Artefacts prêts
7	Observabilité	kube-prometheus-stack, OpenObserve, Fluent Bit, ServiceMonitors.	Implémenté
8	CI/CD	GitHub Actions Terraform plan/apply, OIDC AWS, backend R2.	Implémenté
9	Optimisation coûts	Module Lambda scaling <code>compute-ng</code> , EventBridge cron.	Optionnel
10	GitOps	ArgoCD values, AppProject, Applications exemples.	Préparé

Lecture du statut : *Implémenté* signifie que le code, les manifests et les scripts sont présents dans le dépôt. *Artefacts prêts* signifie que les fichiers nécessaires existent, mais que l'exécution finale dépend de paramètres externes comme les secrets Cloudflare, le domaine ou les ressources cloud. *Préparé* signifie que la structure est disponible et peut être adaptée à un processus d'industrialisation.

5.3 Phase 1 — Landing zone et socle Kubernetes

La première phase construit la fondation de la plateforme. Terraform provisionne le VPC, les sous-réseaux, le cluster EKS, les clés KMS, les rôles IAM et le registre ECR. Les choix majeurs sont documentés par les ADR : séparation des node groups, NAT unique en environnement `dev`, état Terraform sur R2 et accès EKS restreint.

Listing 5.1 – Artefacts Phase 1

```
terraform/modules/{vpc,kms,iam,eks,ecr}
terraform/environments/dev/
bootstrap/{namespaces,storage-classes,resource-quotas,network-policies}
scripts/bootstrap-cluster.sh
```

Le script `bootstrap-cluster.sh` applique ensuite les ressources Kubernetes transverses : namespaces, StorageClass `gp3` chiffrée, quotas et politiques réseau.

5.4 Phase 2 — Stockage Lakehouse et métastore

La phase 2 installe les composants persistants nécessaires au Lakehouse. Le script `bootstrap-phase2.sh` installe `cert-manager` dans `platform-security`, puis MinIO Operator, le tenant MinIO, Cloud-NativePG et Hive Metastore.

1. **MinIO** fournit le stockage objet compatible S3.
2. **CNPG** opère les bases PostgreSQL : source de démonstration et base du Hive Metastore.
3. **Hive Metastore** joue le rôle de catalogue pour les tables Iceberg.
4. **cert-manager** prépare les besoins TLS des opérateurs et services.

Cette phase matérialise le socle Bronze/Silver/Gold : les données peuvent être déposées dans des buckets ou chemins dédiés, puis référencées sous forme de tables Iceberg.

5.5 Phase 3 — Ingestion, Kafka et CDC

La phase 3 couvre l'ingestion événementielle et les flux de données entrants. Strimzi déploie Kafka ; les topics suivent la logique médaillon ; KafkaConnect embarque Debezium pour capturer les changements PostgreSQL ; NiFi sert à l'ingestion visuelle ou semi-structurée.

Listing 5.2 – Extrait conceptuel du flux CDC

```
PostgreSQL pg-source
-> Debezium KafkaConnector
-> topic cdc.pg.public.agency_budget
-> Spark bronze writer
-> Iceberg table lakehouse.bronze.cdc_pg_public_agency_budget
```

Le dépôt propose une variante `dev` légère de Kafka et une variante `prod` plus proche d'une haute disponibilité. Ce choix permet une maintenance réaliste tout en conservant une trajectoire d'industrialisation.

5.6 Phase 4 — Spark, dbt et Airflow

La phase 4 implémente la partie centrale du pipeline data. L'image Spark Iceberg regroupe Spark, les connecteurs Iceberg/S3, les dépendances Python et le projet dbt. Les `SparkApplication` sont soumises par Airflow ou appliquées directement sur Kubernetes, ce qui permet de conserver une orchestration déclarative et reproductible.

TABLE 5.3 – DAGs Airflow livrés

DAG	Fréquence	Rôle
<code>bronze_streaming</code>	@once	Soumet le job Spark long-running Kafka → Bronze Iceberg.
<code>bronze_files_daily</code>	Quotidien	Ingestion de fichiers CSV/XLSX depuis la zone landing vers Bronze.
<code>silver_gold_dbt</code>	Horaire	Exécute dbt pour produire les modèles Silver et Gold.

Les modèles dbt disponibles démontrent la transformation d'une table budgétaire d'agence vers un staging Silver puis un agrégat Gold mensuel. Cette structure reste extensible à d'autres domaines métier.

5.7 Phase 5 — Serving avec Dremio

Dremio constitue la couche de virtualisation SQL. Les valeurs Helm configurent un coordinateur, un exécutateur et le stockage distribué sur MinIO. Le fichier `source-hive.json` prépare la connexion au Hive Metastore et aux propriétés `s3a`.

Dans le scénario cible, Dremio permet :

- de requêter les tables Iceberg sans déplacer les données ;
- d'exposer une interface SQL aux analystes ;
- de connecter Power BI à la couche Gold via ODBC ou Arrow Flight.

5.8 Phase 6 — Exposition sécurisée Cloudflare

La phase 6 prépare l'accès sécurisé aux interfaces web : Airflow, Dremio, Grafana et NiFi. Le dépôt contient les manifests `ClusterTunnel` et `TunnelBinding`, mais l'activation finale dépend de secrets créés dans le dashboard Cloudflare Zero Trust.

Cette approche évite d'exposer directement des LoadBalancers publics et s'aligne avec une logique Zero Trust : authentification, politiques d'accès et publication DNS contrôlée.

5.9 Phase 7 — Monitoring, logging et dashboarding

La phase 7 est essentielle pour un projet data professionnel. Elle couvre les trois besoins suivants :

TABLE 5.4 – Réalisation de l'observabilité

Besoin	Réalisation prévue dans le dépôt
Monitoring	<code>kube-prometheus-stack</code> , Prometheus, Grafana, métriques Kubernetes et ServiceMonitors.
Logging	Fluent Bit collecte les logs des pods et les pousse vers OpenObserve.
Dashboarding technique	Grafana pour ressources cluster, santé des opérateurs, Spark, Kafka, CNPG, MinIO et Airflow.
Dashboarding métier	Power BI ou Dremio pour les agrégats Gold ; Grafana possible pour des KPIs opérationnels.

Les ServiceMonitors présents ciblent notamment Spark Operator, CloudNativePG, MinIO Tenant et Strimzi. Les dashboards finaux sont à importer ou personnaliser après déploiement complet, mais l'infrastructure de collecte est déjà structurée.

5.10 Automatisation, CI/CD et cycle de vie

Le dépôt fournit plusieurs scripts pour réduire la charge opérationnelle :

- `fasttrack-infra.sh` : applique Terraform, configure `kubeconfig` et enchaîne les phases ;
- `bootstrap-phase*.sh` : déploie chaque couche dans l'ordre requis ;
- `prepare-phase*-secrets.sh` : génère des secrets locaux gitignorés ;
- `build-spark-image.sh` : construit et pousse l'image Spark vers ECR ;
- `teardown-infra.sh` : supprime Helm releases, PVC, LoadBalancers et détruit l'environnement dev.

GitHub Actions prend en charge le `terraform plan/apply` avec OIDC, ce qui évite de stocker des clés AWS longues durées dans GitHub.

5.11 Traçabilité avec le cahier des charges

La traçabilité est formalisée dans `docs/specs/SPEC_ALIGNMENT.md`. Ce fichier relie les exigences des documents PDF aux artefacts concrets du dépôt. Il sert de support de soutenance pour montrer que chaque décision est reliée à une phase, un module, un manifest ou un script.

TABLE 5.5 – Exemples de traçabilité exigence → artefact

Exigence	Artefact
État Terraform sur R2	<code>terraform/bootstrap,</code> <code>backend.tf,</code> <code>tf-init-local.sh</code>
Namespaces du SoW	<code>bootstrap/namespaces/namespaces.yaml</code>
Kafka / CDC	<code>bootstrap/phase-3/manifests/kafka/</code>
Pipeline Spark/dbt/Airflow	<code>docker/spark-iceberg/,</code> <code>bootstrap/phase-4/, dags/</code>
Observabilité	<code>bootstrap/phase-7/helm/,</code> <code>ServiceMonitor</code> <code>manifests</code>

5.12 Difficultés rencontrées et mitigations

- **Complexité EKS** : l'ordre de déploiement a été matérialisé dans des scripts par phase et dans `PHASE_CHECKPOINTS.md`.
- **Coûts AWS** : le projet introduit un `teardown` complet, un NAT unique en dev et un `compute node group` scalable à zéro.
- **Secrets** : les secrets réels ne sont pas versionnés ; seuls des exemples et scripts de génération sont fournis.
- **État Terraform** : R2 impose une gestion prudente du verrouillage ; le backend utilise `use_lockfile` et la CI limite la concurrence.
- **Validation E2E** : le code est prêt, mais la démonstration complète dépend d'un compte AWS/Cloudflare configuré et de ressources suffisantes.

5.13 Plan de finalisation

Pour transformer l'implémentation en démonstration complète sur un compte cloud, les étapes restantes sont :

1. appliquer Terraform sur l'environnement dev et exécuter `fasttrack-infra.sh -with-all` ;
2. construire et pousser l'image Spark Iceberg dans ECR ;
3. configurer Cloudflare Tunnel et les hostnames des UIs ;
4. lancer le smoke test PostgreSQL → Kafka → Iceberg → dbt → Dremio ;
5. importer ou créer les dashboards Grafana prioritaires ;
6. capturer les preuves de soutenance : pods, DAGs, topics, tables Iceberg, requêtes Dremio, logs OpenObserve et dashboards.

Conclusion du chapitre

La réalisation couvre le socle infrastructure, la majorité des composants data et l’observabilité attendue par le cahier des charges. Les phases encore dépendantes de secrets et d’un déploiement cloud réel sont documentées comme trajectoire de finalisation, ce qui permet de présenter un projet cohérent, traçable et techniquement défendable.

6 CONCLUSION ET PERSPECTIVES

6.1 Bilan du projet

Ce Projet de Fin d'Études, conduit chez **SEVENAPP** en mission **consultant Data** chez **EQDOM**, a permis de concevoir et d'implémenter progressivement une **Cloud Data Platform** alignée sur un cahier des charges académique exigeant : architecture Lakehouse médaillon, Kubernetes operators, Infrastructure as Code, sécurité, observabilité et optimisation des coûts.

Les apports principaux :

- une **landing zone AWS/EKS** modulaire (Terraform, IRSA, KMS, deux node groups) ;
- une **chaîne data bout en bout** documentée et préparée (CDC, Iceberg, dbt, Dremio, Power BI) ;
- une **industrialisation** par scripts, CI/CD et ADR ;
- une **traçabilité** explicite pour la maintenance (`SPEC_ALIGNMENT.md`) ;
- une **couche d'observabilité** couvrant monitoring, logging et dashboarding technique.

6.2 Limites

- Environnement **dev** unique ; haute disponibilité production (NAT multi-AZ, backups CNPG/Barman) non déployée ;
- Ansible et ArgoCD restent des extensions ou scaffolds ;
- validation E2E et jeux de données réels EQDOM hors périmètre strict du MVP académique ;
- TLS production (Let's Encrypt / ACME) à durcir au-delà du MVP cert-manager.

6.3 Perspectives

- Passage en **prod** : multi-NAT, sauvegardes, politiques de rétention Iceberg ;
- Activation `lambda_scaling_enabled` pour optimisation des coûts ;
- Intégration Power BI, dashboards métier et catalogues de données EQDOM ;
- GitOps ArgoCD et dépôt d'applications dédié ;
- Renforcement qualité : tests automatisés pipeline, Data Quality (Great Expectations), alerting fonctionnel sur fraîcheur et complétude des données.

6.4 Apports personnels

Ce stage a consolidé les compétences en **data engineering cloud-native** : Terraform, Kubernetes operators, streaming CDC et architecture médaillon — compétences directement transférables aux projets de transformation data du secteur financier.

Mohammed Dahiry

A Architecture Decision Records (synthèse)

Résumé des ADR du dépôt (`docs/02-architecture-decision-records.md`).

ADR	Décision	Justification courte
001	2 node groups	Scale compute à 0 sans toucher stateful
002	1 NAT gateway	Coût MVP ; SPOF documenté
003	3 CMK KMS	Rotation et audit par usage
004	Access entries EKS	Plus de aws-auth ConfigMap
005	API EKS privée	Défense en profondeur
006	IRSA uniquement	Blast radius minimal
007	State sur R2	Hors compte AWS
008	Prefix delegation CNI	Plus de pods par nœud
009	PSA baseline	Sécurité pods par défaut
010	use_lockfile	Pas de DynamoDB sur R2

TABLE A.1 – Synthèse des ADR

B Checklist des phases (soutenance)

#	Script	Validation minimale
1	<code>bootstrap-cluster.sh</code>	<code>kubectl get nodes</code> Ready ; 9 NS
2	<code>bootstrap-phase2.sh</code>	MinIO, CNPG Ready, Hive up
3	<code>bootstrap-phase3.sh</code>	Kafka Ready ; connector RUNNING
4	<code>bootstrap-phase4.sh</code>	Spark SA ; Airflow web UI
5	<code>bootstrap-phase5.sh</code>	Dremio coordinator Ready
6	<code>bootstrap-phase6.sh</code>	Tunnel CONNECTED
7	<code>bootstrap-phase7.sh</code>	Grafana ; logs dans OpenObserve
8	GitHub Actions	<code>terraform plan/apply</code> via OIDC
9	<code>lambda_scaling_enabled</code>	EventBridge déclenche le scaling <code>compute-ng</code>
10	<code>bootstrap-phase10.sh</code>	ArgoCD UI accessible ; Applications synchronisables

TABLE B.1 – Jalons opérationnels (docs/phases/PHASE_CHECKPOINTS.md)

Preuve soutenance	Commande ou écran attendu
Namespaces	<code>kubectl get ns -l app.kubernetes.io/part-of=dataplatfom</code>
CDC Kafka	<code>kubectl -n platform-ingestion get kafkaconnector,kafkatopic</code>
Spark / Airflow	Airflow DAGs visibles ; <code>kubectl -n platform-compute get sparkapplications</code>
Tables Iceberg	Requête Dremio sur <code>lakehouse.bronze, silver, gold</code>
Monitoring	Grafana : cluster, pods, Kafka, Spark, CNPG, MinIO
Logging	OpenObserve : logs filtrés par namespace, pod et DAG/job

TABLE B.2 – Preuves recommandées pour la démonstration

Bibliographie

- [1] Mohammed DAHIRY. *Cloud Data Platform Architecture – End-of-Studies Project Statement of Work*. Specifications_Doc_for_PFE.pdf. 2026.
- [2] Mohammed DAHIRY. *Cloud Data Platform – Guide complet Phase 1*. cloud-data-platform-guide.pdf. 2026.